UNIVERSIDAD DE ESPECIALIDADES UNE · PLANTEL CENTRO

Ingeniería en Computación · Optativa III: Ciencia de Datos · 9.º semestre

Radiografía socioeconómica de México

Escolaridad, ingreso y brecha de género

Informe técnico final del Proyecto Integrador de Ciencia de Datos
Encuesta Nacional de Ocupación y Empleo (ENOE), 4.º trimestre de 2025 · INEGI

Equipo 1

Juan Evelio Culin Grajeda
Angel Yireh Garcia Jara
Luis Andre Gutierrez Zuñiga

Documento que explica el proyecto completo: pregunta, datos, limpieza, ingeniería de datos, métodos estadísticos, resultados, interpretación, limitaciones y guía para reproducirlo.

Octubre de 2026

Resumen

Este trabajo documenta el Proyecto Integrador de Ciencia de Datos del Equipo 1: un ciclo completo de descubrimiento de conocimiento en bases de datos (KDD) aplicado a la Encuesta Nacional de Ocupación y Empleo (ENOE) del INEGI, 4.º trimestre de 2025 (419,038 registros). La pregunta de investigación es cuánto aumenta el ingreso laboral por cada año adicional de escolaridad en México, cómo cambia esa relación entre las 32 entidades federativas y si existe una brecha salarial significativa entre hombres y mujeres con la misma escolaridad.

Los datos se limpiaron con reglas documentadas y probadas, se validaron contra siete cifras oficiales del INEGI (las siete coinciden), se almacenaron en un modelo relacional (SQLite) y en uno documental (MongoDB) y se analizaron con técnicas que respetan el diseño muestral complejo de la encuesta (bootstrap de Rao-Wu con 1,000 réplicas). Se encontró además que el «ingreso cero» del archivo no significa ausencia de ingreso: 22 % de los ocupados solo declara un rango de salarios mínimos y 13 % no especifica.

Resultados. Cada año de escolaridad aumenta el ingreso por hora 5.1 % (IC 95 %: 5.0 a 5.3) y el rendimiento es prácticamente igual en estados ricos y pobres ($p = 0.91$). La brecha de género es de 3.7 % por hora y de 26.9 % por mes; la diferencia mensual se debe sobre todo a que las mujeres trabajan 24.1 % menos horas pagadas. Entre personas comparables la brecha por hora ronda 8 % y se concentra en la parte baja de la distribución. La informalidad laboral es de 55.0 %, varía de 33 % (Coahuila) a 80 % (Oaxaca) y cae de 87 % a 38 % conforme aumenta la escolaridad.

Los resultados describen **asociaciones**, no efectos causales; el documento discute las limitaciones (selección, medición del ingreso, un solo trimestre) y la forma en que se evaluó la robustez de cada conclusión.

Palabras clave: ENOE; escolaridad; ingreso por hora; brecha de género; informalidad laboral; diseño muestral complejo; bootstrap de Rao-Wu; Oaxaca-Blinder; SQLite; MongoDB.

Índice

1. Introducción 5
1.1 Contexto y motivación 5
1.2 Pregunta de investigación 5
1.3 Objetivos 5
1.4 Métricas de éxito 5
1.5 Alcance 6
1.6 Cómo leer este documento 6
2. Marco conceptual: lo que hay que entender 7
2.1 El ciclo KDD 7
2.2 La ENOE y su diseño muestral 7
2.3 Las variables laborales 9
2.4 Estadística en palabras sencillas 9
2.5 Ingeniería de datos 13
3. Datos (KDD fase 1: Selección) 14
3.1 Fuente y archivos 14
3.2 Llave de persona y unión de tablas 14
3.3 Variables utilizadas 14
3.4 Validación externa: ¿las cifras coinciden con las oficiales? 15
4. Preprocesamiento (KDD fase 2: limpieza) 16
4.1 Bitácora de limpieza: del archivo crudo al universo de estudio 16
4.2 Datos faltantes y códigos especiales 17
4.3 El problema del «ingreso cero» 17
4.4 Imputación del ingreso a partir del rango (grupo B) 20
4.5 Valores atípicos 20
4.6 Muestras de análisis 21
4.7 Pruebas automáticas de calidad de los datos (15 «expectativas») 22
5. Transformación e ingeniería de datos (KDD fase 3) 23
5.1 Variables derivadas 23
5.2 Arquitectura del proyecto 23
5.3 Almacén relacional: SQLite con esquema en estrella 24
5.4 Almacén documental: MongoDB 26
5.5 Reproducibilidad y pruebas 28
5.6 Mapa del código 29
6. Metodología estadística (KDD fase 4: análisis) 31
6.1 Poblaciones y muestras 31
6.2 Definiciones operativas 31
6.3 Inferencia con el diseño muestral complejo 32
6.4 Estimadores y pruebas por objetivo 33
6.5 El sesgo de división: por qué no se interpreta el modelo con horas 33
6.6 Decisiones del analista y su sensibilidad 34
6.7 Verificación del método 34
7. Resultados 35
7.1 Panorama: la muestra salarial 35
7.2 Rendimiento de la escolaridad (objetivo 1) 36
7.3 Correlación escolaridad-ingreso por entidad (métrica M2) 38

7.4 Brecha salarial de género por nivel de instrucción (métrica M1) 40
7.5 Brecha entre personas comparables: la escalera de controles 42
7.6 La brecha a lo largo de la distribución 45
7.7 Robustez: ¿cambian las conclusiones si cambian las decisiones? 45
7.8 Heterogeneidad: ¿en qué grupos es mayor la brecha? 47
7.9 La brecha de género por entidad federativa 48
7.10 Informalidad laboral y escolaridad (objetivo 3) 49
7.11 Diagnósticos del modelo 51
8. Discusión 52
8.1 Hallazgos principales 52
8.2 Evaluación de las métricas de éxito 53
8.3 Interpretación integrada 53
8.4 Implicaciones y recomendaciones 53
8.5 Limitaciones 54
8.6 Trabajo futuro 54
9. Conclusiones 55
Anexo A. Glosario 56
Anexo B. Guía para reproducir el proyecto 58
B.1 Requisitos 58
B.2 Instalación y datos 58
B.3 Ejecución 58
B.4 Qué produce cada paso 59
B.5 Solución de problemas 59
Anexo C. Resultados por entidad federativa 60
Anexo D. Preguntas frecuentes de la defensa 62
Anexo E. Guion de exposición 66
Anexo F. Referencias 67

1. Introducción

1.1 Contexto y motivación

La educación suele considerarse la principal vía de movilidad social, pero el mercado laboral mexicano combina una alta informalidad (más de la mitad de las personas ocupadas) con diferencias persistentes de ingreso entre regiones y entre mujeres y hombres. Saber cuánto «paga» un año adicional de estudio, si ese pago es parejo en todo el país y si mujeres y hombres con la misma preparación reciben el mismo ingreso son preguntas que orientan decisiones de política educativa, laboral y de igualdad de género.

La **Encuesta Nacional de Ocupación y Empleo (ENOE)** del INEGI es la principal fuente de información del mercado laboral mexicano: es una encuesta continua que cada trimestre entrevista a cientos de miles de personas y, mediante factores de expansión, permite estimar cifras para todo el país y para cada entidad federativa. Sus microdatos son públicos y anonimizados.

1.2 Pregunta de investigación

> **Pregunta**
>
> ¿Cuánto aumenta el ingreso laboral por cada año adicional de escolaridad en México, cómo cambia esa relación entre entidades federativas y existe una brecha salarial significativa entre hombres y mujeres con la misma escolaridad?

1.3 Objetivos

Objetivo general. Cuantificar la relación entre escolaridad e ingreso laboral y la brecha salarial de género en la población ocupada de México, por entidad federativa, a partir de los microdatos de la ENOE.

Objetivos específicos.

1. Estimar la correlación y el retorno de un año adicional de escolaridad sobre el ingreso por hora en cada una de las 32 entidades, comparando estados de mayor y menor ingreso.
2. Determinar si existe una diferencia estadísticamente significativa de ingreso por hora entre hombres y mujeres con el mismo nivel de instrucción.
3. Identificar las entidades con mayor tasa de informalidad laboral y medir su relación con la escolaridad promedio.

1.4 Métricas de éxito

El protocolo del proyecto fijó tres métricas verificables, cuyo cumplimiento se evalúa en la sección 8.2:

1. **M1.** Brecha salarial de género (%) en el ingreso por hora para cada nivel de instrucción, con intervalo de confianza del 95 % y prueba de hipótesis (significativa si $p < 0.05$).
2. **M2.** Coeficiente de correlación escolaridad-ingreso (Spearman) para las 32 entidades, con intervalo de confianza por bootstrap, y un ranking de estados defendible.

3. **M3.** Tablero con al menos cuatro visualizaciones interpretables por una persona no especialista, alimentado por un pipeline que carga datos limpios a una base NoSQL (MongoDB) consultable por entidad.

1.5 Alcance

El estudio es **descriptivo y asociativo**: mide cuánto se asocia la escolaridad con el ingreso y cuánto difieren los ingresos de mujeres y hombres, pero no estima efectos causales (no se puede asegurar que estudiar un año más *cause* un aumento de 5 %, porque quienes estudian más pueden diferir en habilidades, redes o contexto familiar). Se analiza un solo trimestre (4.º de 2025) y a las personas ocupadas de 15 años y más (15 a 65 años para el análisis salarial).

1.6 Cómo leer este documento

Este trabajo está pensado para que cualquier persona con conocimientos básicos de estadística —y no solo quien lo hizo— entienda **qué se hizo, por qué y qué significa cada resultado**:

- Los recuadros **«En palabras sencillas»** explican cada concepto sin tecnicismos.
- La **sección 2** explica los conceptos (la encuesta, el diseño muestral, los métodos estadísticos, las bases de datos); las **secciones 3 a 6** explican qué se hizo; la **7** muestra qué se encontró; la **8** lo interpreta.
- Los **anexos** incluyen un glosario, la guía para reproducir todo, preguntas frecuentes para la defensa y un guion de exposición.
- Todas las cifras de este documento se leen automáticamente de los archivos de resultados del proyecto (`results/`), por lo que coinciden con el cuaderno, el tablero y la presentación.

2. Marco conceptual: lo que hay que entender

Antes de ver qué se hizo conviene entender las ideas que sostienen el análisis. Esta sección las explica en lenguaje sencillo, de lo general (el método de trabajo) a lo particular (cada técnica).

2.1 El ciclo KDD

KDD (*Knowledge Discovery in Databases*) es el proceso completo que convierte datos crudos en conocimiento útil. No es solo «correr un modelo»: la mayor parte del trabajo está antes (elegir y limpiar los datos) y después (interpretar y comunicar). Tiene cinco fases, que corresponden a las semanas del curso:



Figura 1. Las cinco fases del ciclo KDD y qué se hizo en cada una.

Tabla 1. Fases del ciclo KDD y su correspondencia con el documento.

Fase	Semana	Qué se hace	Dónde está
1. Selección	1	Elegir la fuente y el subconjunto de datos relevantes	Sección 3
2. Preprocesamiento	4	Limpiar: faltantes, duplicados, tipos, valores atípicos e imposibles	Sección 4
3. Transformación	4 · 6 · 7	Crear variables, unir tablas y almacenarlas (relacional y documental)	Sección 5
4. Minería / Análisis	2 · 3 · 5	Estadística, pruebas de hipótesis, regresión, visualización	Secciones 6 y 7
5. Interpretación	5	Extraer conocimiento, comunicarlo y recomendar	Secciones 8 y 9

2.2 La ENOE y su diseño muestral

¿Qué es la ENOE?

Es una encuesta del INEGI que se levanta de manera continua en las viviendas del país. Cada trimestre el INEGI publica una base de **microdatos**: archivos en los que cada fila es una persona (tabla SDEMT, sociodemográfica y laboral) o un cuestionario (tablas COE1T y COE2T, ocupación y empleo). En el 4.º

trimestre de 2025 la tabla SDEMT trae **419,038 personas** y 115 columnas. Cada vivienda se entrevista hasta cinco veces consecutivas (panel rotativo, variable `n_ent`).

Diseño probabilístico, estratificado y por conglomerados

No se entrevista a una muestra «al azar simple» de personas: sería carísimo recorrer el país. En su lugar se usa un diseño **bietápico, estratificado y por conglomerados**: primero se agrupan áreas parecidas en **estratos**, luego se sortean **Unidades Primarias de Muestreo (UPM)**, que son conjuntos de viviendas, y dentro de ellas se eligen viviendas y personas. En este trimestre hay 724 estratos y 21,194 UPM.

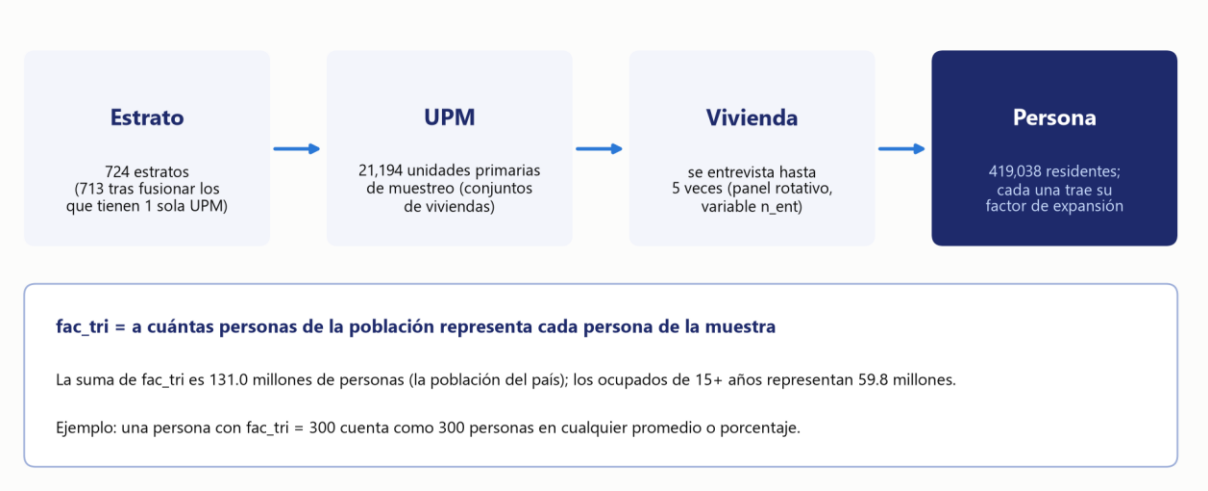


Figura 2. Niveles del diseño muestral de la ENOE y significado del factor de expansión (fac_tri).

El factor de expansión: por qué cada persona pesa distinto

Cada persona de la base trae un número, `fac_tri`, que indica **a cuántas personas de la población representa**. Las personas de algunas zonas se entrevistan con mayor o menor probabilidad, y el factor corrige eso: la suma de `fac_tri` en toda la base es 131.0 millones de personas (la población del país) y la de las personas ocupadas de 15 años y más es 59.8 millones. Por eso **todos los promedios, porcentajes y totales de este trabajo están ponderados**: un promedio sin ponderar describiría a la muestra, no al país.

Efecto de diseño: la muestra «vale» menos de lo que parece

Las personas de una misma UPM se parecen entre sí (viven en la misma zona, tienen empleos similares), así que aportan menos información que personas elegidas al azar en todo el país. El **efecto de diseño** (*deff*) mide cuánto más grande es la varianza real que la de una muestra aleatoria simple: para la tasa de informalidad es de 4.8, de modo que los 190,187 ocupados de la base equivalen a unas 40 mil observaciones independientes. Ignorarlo haría que los intervalos de confianza fueran aproximadamente la mitad de anchos de lo que deberían y que todo pareciera «significativo».

> **En palabras sencillas**
>
> Imagina que cada persona encuestada es un «representante» de cientos de personas que no fueron entrevistadas. Por eso hay que contar a cada representante tantas veces como personas representa (ponderar). Y como los representantes de una misma zona se parecen, tener 190 mil entrevistas no equivale a 190 mil opiniones totalmente independientes: equivale a unas 40 mil.

2.3 Las variables laborales

Tabla 2. Variables laborales y sus definiciones.

Concepto	Definición
Persona ocupada	Persona de 15+ años que trabajó al menos una hora la semana de referencia (`clase2 = 1`).
Ingreso mensual (`ingocup`)	Ingreso mensual de la ocupación principal, en pesos. Vale 0 si la persona no dio un monto exacto (ver sección 4.3).
Horas trabajadas (`hrsocup`)	Horas trabajadas la semana pasada.
Ingreso por hora	`ingocup / (hrsocup × 4.3)`; 4.3 es el número de semanas por mes que usa el INEGI. Coincide con la variable `ing_x_hrs` del INEGI (error relativo < 0.01 %).
Salario mínimo (`salario`)	Salario mínimo mensual de la zona de la persona: $8,364 (zona general) o $12,596 (frontera norte).
Escolaridad (`anios_esc`, `niv_ins`)	Años de escolaridad aprobados y nivel de instrucción (primaria incompleta, primaria completa, secundaria completa, medio superior y superior).
Informalidad (`emp_ppal`)	Empleo informal en la ocupación principal. **TIL1** = personas ocupadas en empleo informal ÷ personas ocupadas de 15+ años, definición oficial del INEGI.
Entidad (`cve_ent`)	Clave de la entidad federativa, 1 a 32.

2.4 Estadística en palabras sencillas

Cada técnica se explica con la misma estructura: *la idea*, *cómo se calcula* y *cómo se lee*.

Logaritmo natural y media geométrica

La idea. El ingreso por hora tiene una «cola larga»: la mayoría gana poco y unas pocas personas ganan muchísimo, lo que distorsiona los promedios. Con el logaritmo natural, esa cola se acorta y la distribución se vuelve casi simétrica (la asimetría pasa de 3.1 a 0.06).

Cómo se calcula. Se trabaja con ln(ingreso por hora). Una propiedad útil: la diferencia entre dos logaritmos es, aproximadamente, una diferencia porcentual (ln 110 − ln 100 = 0.095 ≈ 10 %). El promedio de los logaritmos, devuelto a pesos con la exponencial, es la **media geométrica**.

Cómo se lee. Cuando se dice «las mujeres ganan 3.7 % menos por hora» se comparan las medias geométricas de ingreso por hora de mujeres y hombres.

Correlación de Spearman

La idea. Mide si dos variables «suben juntas»: si las personas con más escolaridad tienden a tener más ingreso, sin importar la forma exacta de la relación ni los valores extremos.

Cómo se calcula. Se reemplaza cada valor por su *lugar* (rango) entre todos los valores (el más bajo es 1) y se calcula la correlación de Pearson entre los rangos. Los empates reciben el rango medio. En este proyecto cada persona cuenta tantas veces como su `fac_tri` (rangos medios ponderados). El ejemplo siguiente usa seis personas ilustrativas.

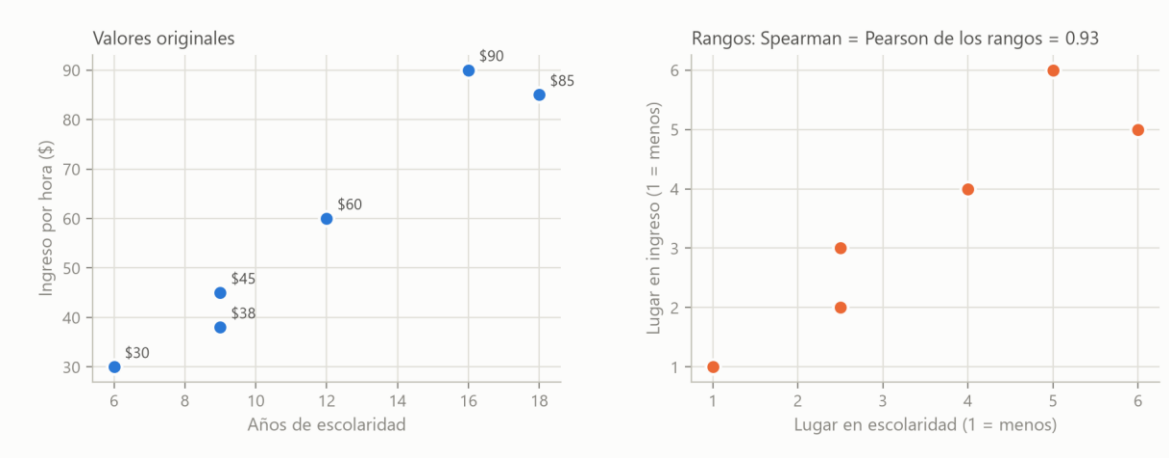


Figura 3. Ejemplo ilustrativo (seis personas): al convertir los valores en rangos, la correlación de Spearman resulta 0.93.

Cómo se lee. Va de −1 (relación inversa perfecta) a +1 (perfecta), y 0 significa que no hay relación monótona. Como referencia común, alrededor de 0.1 es débil, 0.3 moderada y 0.5 fuerte. La correlación nacional entre escolaridad e ingreso por hora es 0.34 (moderada).

Regresión lineal y ecuación de Mincer

La idea. Una regresión estima cuánto cambia una variable (aquí, el ingreso) cuando cambia otra (los años de escolaridad), *manteniendo constantes* las demás (edad, sexo, entidad...). La **ecuación de Mincer** (1974) es el modelo clásico de la economía laboral para medir el rendimiento de la educación.

$$\ln(\text{ingreso por hora}) = \alpha + \beta \cdot \text{años de escolaridad} + \gamma_1 \cdot \text{edad} + \gamma_2 \cdot \text{edad}^2 + \delta \cdot \text{mujer} + \text{efectos de entidad y de localidad} + \text{error}$$

Cómo se lee. El coeficiente β mide cuánto aumenta el *logaritmo* del ingreso por cada año de escolaridad; el aumento porcentual es 100 × (e^β − 1). Si β = 0.0501, un año más de estudio se asocia con +5.1 % de ingreso por hora; dos años, con $(1.051)^2 - 1 = +10.5$ %. La edad entra al cuadrado porque el ingreso sube con la experiencia y luego se aplana.

Brecha salarial de género

La idea y el cálculo. Se compara el ingreso medio geométrico de mujeres y hombres:

$$\text{brecha (\%)} = 100 \times [\ 1 - (\text{ingreso medio geométrico de las mujeres} \div \text{ingreso medio geométrico de los hombres})\ ]$$

Ejemplo con los datos. Los hombres ganan en promedio geométrico $52.53 por hora y las mujeres $50.60: la brecha es 1 − 50.60/52.53 = 3.7 %. Un valor negativo indicaría que las mujeres ganan más.

Pruebas de hipótesis, valor p e intervalo de confianza

La idea. Como trabajamos con una muestra, toda diferencia observada podría deberse al azar. Una **prueba de hipótesis** plantea una *hipótesis nula* (H_0: no hay brecha) y calcula el **valor p**: la probabilidad de observar una diferencia tan grande como la que vimos *si en realidad no hubiera brecha*. Si $p < 0.05$ (nivel $\alpha = 5$ %) se rechaza H_0 y se dice que la diferencia es **estadísticamente significativa**.

El **intervalo de confianza (IC) del 95 %** da un rango de valores plausibles para la cantidad real: si el estudio se repitiera muchas veces, el 95 % de los intervalos construidos así contendría el valor verdadero. Si el intervalo **no incluye el 0**, la diferencia es significativa; si lo incluye, no se puede afirmar que exista.

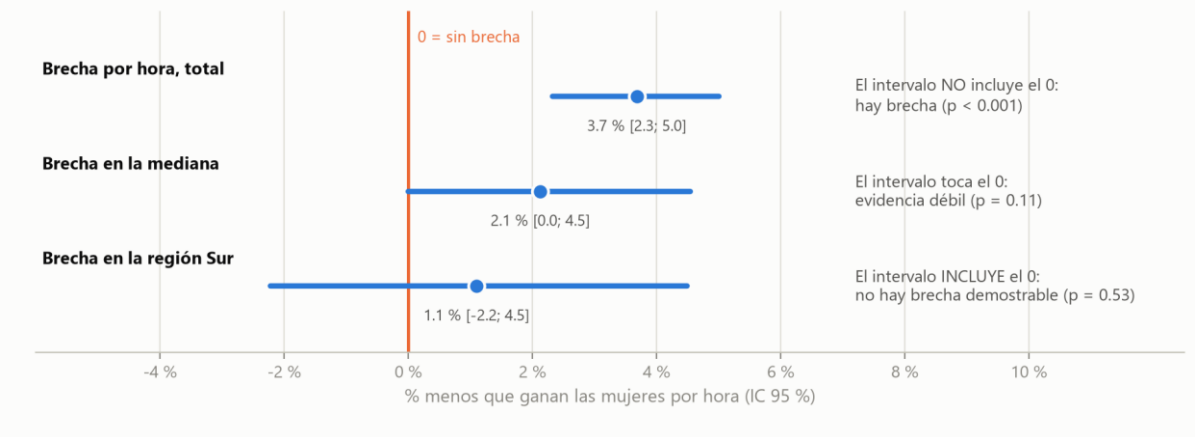


Figura 4. Cómo leer un intervalo de confianza con tres casos reales: uno que excluye el 0 (hay brecha), uno que lo toca (evidencia débil) y uno que lo incluye (no hay brecha demostrable).

Comparaciones múltiples: la corrección de Holm

Si se hacen muchas pruebas, algunas saldrán «significativas» solo por azar. La corrección de **Holm** (1979) controla la probabilidad de equivocarse al menos una vez en todo el conjunto: ordena los valores p de menor a mayor y los compara con umbrales cada vez menos exigentes. Se aplica a las cuatro pruebas por nivel de instrucción y a las categorías de cada dimensión de heterogeneidad.

Tamaño del efecto: la d de Cohen

Con muchas observaciones casi cualquier diferencia resulta «significativa». Para saber si importa en la práctica se mide su tamaño: la **d de Cohen** es la diferencia de medias dividida entre la desviación estándar (0.2 se considera pequeña, 0.5 mediana y 0.8 grande). Significativo no significa grande.

Bootstrap de Rao-Wu y linealización de Taylor

La idea. Para medir la incertidumbre (el error estándar) hay que saber cuánto cambiaría el resultado si se repitiera la encuesta. No se puede repetir, pero se puede *simular*: el **bootstrap** vuelve a muestrear los propios datos. Como la ENOE es por conglomerados, lo que se remuestrea no son personas sino **UPM completas**, respetando los estratos. El método de **Rao y Wu (1988)** lo hace de forma que reproduce correctamente la varianza del diseño.

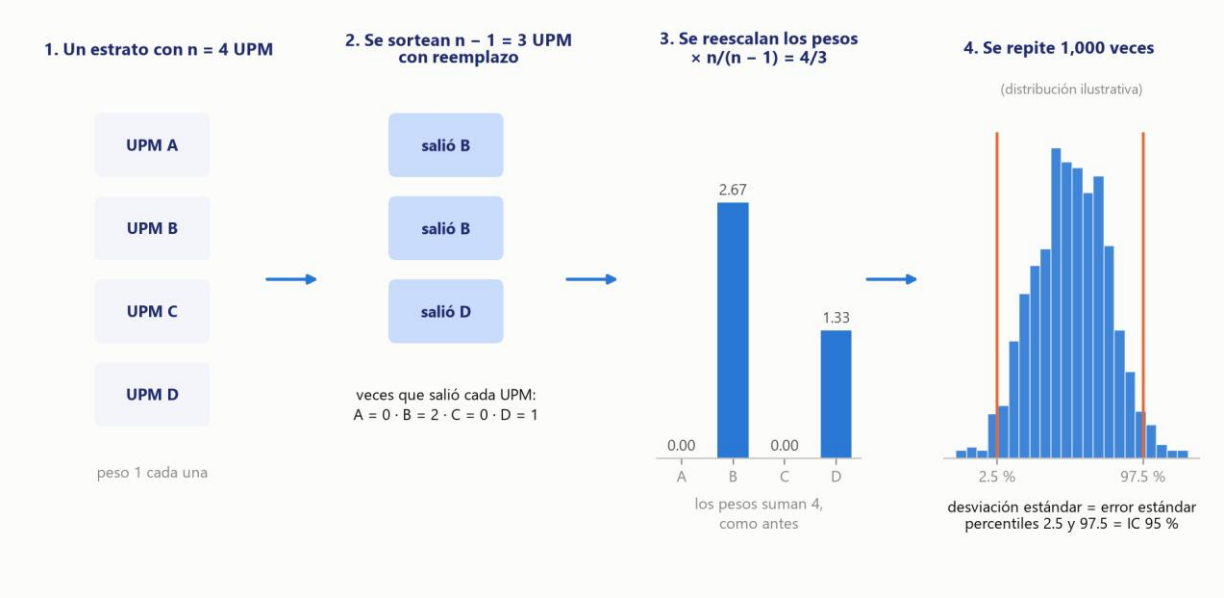


Figura 5. El bootstrap de Rao-Wu en cuatro pasos (ejemplo con un estrato de cuatro UPM).

Cómo se usa. Con 1,000 réplicas, la desviación estándar de las estimaciones replicadas es el error estándar y los percentiles 2.5 y 97.5 son el intervalo de confianza del 95 %. Para los modelos de regresión y logit se usa en cambio la **linealización de Taylor**, una fórmula analítica equivalente que también respeta estratos y UPM. En las pruebas del proyecto, ambos métodos coinciden (dentro de 8 %).

Descomposición de Oaxaca-Blinder

La idea. Separa la brecha entre dos grupos en dos partes: la **explicada** (los grupos difieren en sus características: escolaridad, edad, lugar de residencia, tipo de empleo...) y la **no explicada** (a las *mismas* características se les paga distinto). Se usa la referencia agrupada de Neumark (1988): los coeficientes de comparación salen de una regresión con hombres y mujeres juntos.



Figura 6. Idea de la descomposición de Oaxaca-Blinder con los resultados del proyecto (puntos logarítmicos, hombres − mujeres).

Cómo se lee. La parte no explicada **no prueba discriminación**: incluye todo lo que no se pudo medir (ocupación específica, experiencia real, negociación, selección).

No respuesta: imputación por rangos y ponderación por probabilidad inversa (IPW)

Cuando una parte de la muestra no responde y quienes no responden son distintos de quienes sí, los resultados se sesgan. Se usan dos correcciones: **imputar** el ingreso de quien solo dio un rango (asignándole el ingreso típico de quienes ganan en ese rango) y **IPW**, que da más peso a quienes se parecen a los que no respondieron (peso = 1 ÷ probabilidad de responder, estimada con una regresión logística).

Regresión logística

Cuando la variable que se explica es sí/no (por ejemplo, tener un empleo informal), se usa un **logit**. Sus coeficientes se leen como **razones de momios** (*odds ratio*): un valor de 0.82 por año de escolaridad significa que cada año reduce 18 % los momios de ser informal. Para una lectura más directa se reporta el **efecto marginal promedio**: cuántos puntos porcentuales cambia la probabilidad.

2.5 Ingeniería de datos

- **ETL** (*Extract, Transform, Load*): proceso que extrae los datos de su fuente, los transforma (limpia, une, calcula variables) y los carga en un almacén. Aquí es un programa en Python que se puede ejecutar de principio a fin.
- **Base de datos relacional (SQL):** guarda los datos en tablas con columnas de tipos fijos y relaciones entre tablas. Es ideal para datos tabulares y para agregaciones (`GROUP BY`, `JOIN`). Las restricciones (`PRIMARY KEY`, `FOREIGN KEY`, `CHECK`) impiden guardar datos inconsistentes.
- **Esquema en estrella:** una tabla central de hechos (aquí, una fila por persona ocupada) rodeada de tablas de dimensiones pequeñas (entidad, sexo, nivel de instrucción...).
- **Base de datos documental (NoSQL):** guarda documentos JSON anidados, sin esquema rígido. Es ideal para servir «la ficha completa» de un elemento (una entidad) con una sola lectura.
- **Persistencia políglota:** usar cada tipo de base donde mejor funciona. Aquí, SQLite para analizar y MongoDB para servir la ficha de cada entidad.
- **Idempotencia y determinismo:** ejecutar el proceso dos veces produce exactamente el mismo resultado (se fija una semilla para todo lo aleatorio y se recrea la base desde cero).

3. Datos (KDD fase 1: Selección)

3.1 Fuente y archivos

Se usan los microdatos de la ENOE del 4.º trimestre de 2025, publicados por el INEGI (https://www.inegi.org.mx/programas/enoe/15ymas/) en archivos CSV con codificación latin-1. El paquete incluye cinco tablas; el proyecto usa dos y guarda la huella SHA-256 de cada archivo para poder demostrar con qué datos se corrió todo.

Tabla 3. Tablas de origen utilizadas. SDEMT trae 115 columnas (se leen las 35 necesarias).

Tabla	Archivo	Filas	Columnas leídas	MB	SHA-256 (inicio)
SDEMT	ENOE_SDEMT425.csv	419,038	35	118	c3e8d9ea23d695c1…
COE2T	ENOE_COE2T425.csv	344,166	14	69	fabf6491712394f1…

- **SDEMT** (sociodemográfica y laboral): una fila por residente del hogar, de todas las edades; trae el ponderador, el diseño muestral, la escolaridad, el ingreso y las horas.
- **COE2T** (cuestionario de ocupación, parte 2): el detalle de cómo se captó el ingreso (monto, o rango de salarios mínimos cuando no hubo monto).
- Las tablas COE1T, HOGT y VIVT no aportan variables al problema y no se usan.

3.2 Llave de persona y unión de tablas

Para unir SDEMT con COE2T hace falta una llave que identifique a cada persona. La llave que se cita habitualmente (`cd_a, ent, con, v_sel, n_hog, h_mud, n_ren`) **no es única** en este trimestre: tiene 8,371 duplicados. Se comprobó empíricamente que la combinación `cd_a, cve_ent, con, upm, d_sem, n_pro_viv, v_sel, n_hog, h_mud, n_ent, n_ren` sí lo es (0 duplicados en ambas tablas). La unión se hace con la condición «uno a uno»: si alguna persona ocupada de SDEMT no encontrara pareja en COE2T, el proceso se detiene. Resultado: los 190,187 ocupados encuentran su pareja.

3.3 Variables utilizadas

Tabla 4. Variables de origen utilizadas (diccionario completo en docs/diccionario_de_datos.md).

Variable	Tabla	Significado	Valores / notas
r_def, c_res	SDEMT	Resultado de la entrevista; condición de residencia	r_def = 0 (completa); c_res ∈ {1, 3} (residente habitual)
cve_ent	SDEMT	Entidad federativa	1 a 32
upm, est_d_tri	SDEMT	Unidad primaria de muestreo y estrato de diseño	21,194 UPM en 724 estratos
fac_tri	SDEMT	Factor de expansión trimestral	> 0; suma 131.0 millones
sex, eda	SDEMT	Sexo y edad	sex: 1 hombre, 2 mujer; eda: 0 a 98
niv_ins, anios_esc	SDEMT	Nivel de instrucción y años de escolaridad	anios_esc = 99 significa «no especificado»
clase1, clase2	SDEMT	Condición de actividad	clase2 = 1: ocupado

Variable	Tabla	Significado	Valores / notas
pos_ocu	SDEMT	Posición en la ocupación	1 subordinado, 2 empleador, 3 cuenta propia, 4 sin pago
emp_ppal	SDEMT	Empleo informal en la ocupación principal	1 informal, 2 formal
rama_est2	SDEMT	Gran rama de actividad	11 ramas
t_loc_tri, salario	SDEMT	Tamaño de localidad; salario mínimo mensual	4 tamaños; $8,364 / $12,596
hrsocup	SDEMT	Horas trabajadas la semana pasada	0 a 168
ingocup, ing_x_hrs, ing7c	SDEMT	Ingreso mensual, ingreso por hora y rango en salarios mínimos	ingocup = 0 si no hay monto exacto
p6b2, p6c	COE2T	Monto declarado; rango de salarios mínimos	p6c: 1 a 7 rangos, 8 no sabe, 9 no respondió

3.4 Validación externa: ¿las cifras coinciden con las oficiales?

Antes de analizar nada se comprobó que los filtros y los ponderadores reproducen lo que el INEGI publicó para este trimestre. Si coinciden, se interpretan bien los códigos y los factores de expansión y los resultados son comparables con la estadística oficial. La base oficial es: personas ocupadas de 15 años y más, entrevista completa, residentes habituales, ponderadas con `fac_tri`.

Tabla 5. Validación externa: cifras del proyecto frente a las publicadas por el INEGI para el 4T-2025.

Indicador	Proyecto	INEGI (publicado)	¿Coincide?
PEA (millones)	61.35	61.3	Sí
Tasa de participación (%)	59.28	59.3	Sí
Ocupación informal (millones)	32.88	32.9	Sí
TIL1 nacional (%)	55.00	55.0	Sí
TIL1 Chiapas (%)	74.90	74.9	Sí
TIL1 Chihuahua (%)	36.19	36.2	Sí
TIL1 Ciudad de México (%)	45.71	45.7	Sí

Las siete comparaciones coinciden al redondear a la precisión publicada. Un hallazgo de la validación: si se incluyeran los 1,078 menores de 15 años que aparecen como ocupados en la muestra, el TIL1 subiría de 55.00 % a 55.27 % y dejaría de coincidir con el oficial; por eso toda la población de estudio se restringe a 15 años y más.

> **Nota de transparencia**
>
> Las cifras oficiales de referencia se obtuvieron de los boletines del INEGI para el 4T-2025 mediante una búsqueda web; conviene contrastarlas con el PDF oficial antes de citarlas.

4. Preprocesamiento (KDD fase 2: limpieza)

Los datos crudos nunca están listos para analizarse: traen personas que no corresponden a la población de estudio, códigos que significan «no sabe» y no cantidades, jornadas imposibles y, sobre todo en esta encuesta, un ingreso que vale cero por razones muy distintas. Esta sección explica cada decisión de limpieza, cuántos registros afectó y por qué se tomó. El principio rector es **marcar, no borrar**: el universo completo se conserva en la base de datos y cada análisis elige, mediante banderas, qué registros usa.

4.1 Bitácora de limpieza: del archivo crudo al universo de estudio

Cada regla se registra en una bitácora (`etl_bitacora`, tabla del modelo relacional) con el número de registros antes y después. Así cualquier persona puede auditar cuántos registros se perdieron en cada paso y por qué.

Tabla 6. Embudo de filtros que define el universo de estudio (SDEMT, 4T-2025).

Paso	Regla	Antes	Después	Excluidos
L0	Registros crudos (todas las personas del hogar)	419,038	419,038	0
L1	Entrevista completa (`r_def = 0`)	419,038	418,146	892
L2	Residente habitual (`c_res` ∈ {1, 3})	418,146	408,099	10,047
L3	Edad válida de 15 a 98 años	408,099	323,367	84,732
L4	Población ocupada (`clase2 = 1`)	323,367	190,187	133,180
L5	Ponderador positivo (`fac_tri > 0`)	190,187	190,187	0

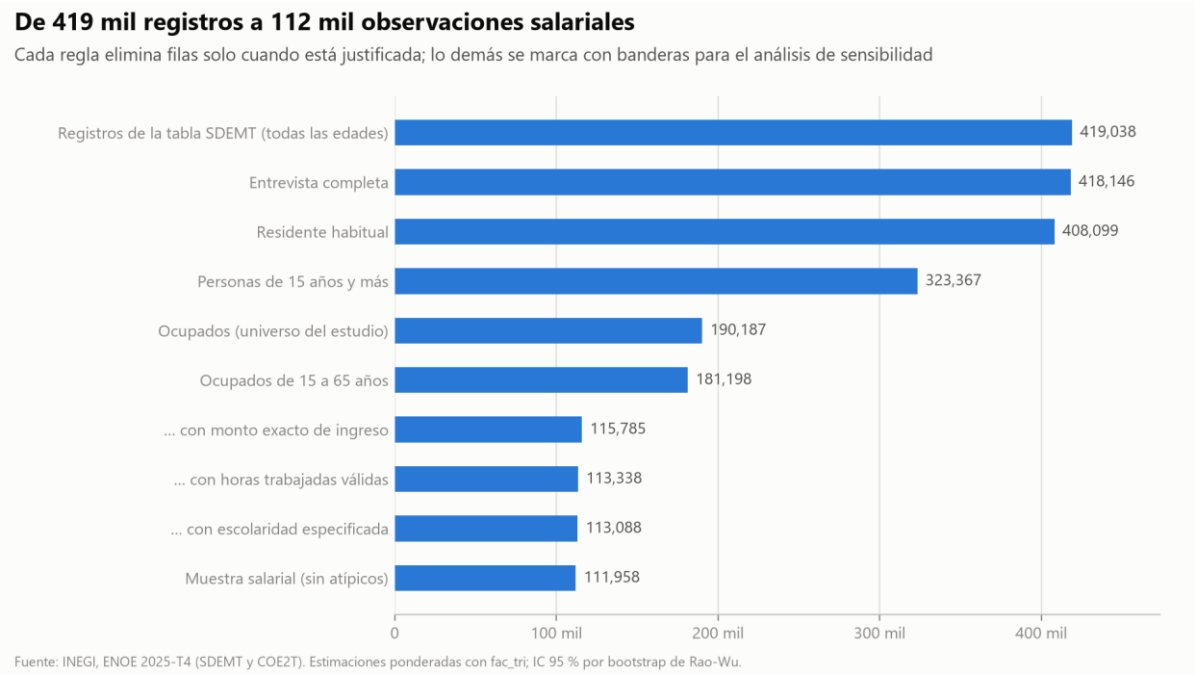


Figura 7. Embudo de datos: de 419,038 registros crudos a 190,187 personas ocupadas (universo), y de ahí a las muestras de análisis.

- **L1 (892 excluidos).** Solo se usan entrevistas completas; las incompletas no tienen datos laborales confiables.
- **L2 (10,047).** Se excluyen los «nuevos residentes» (`c_res = 2`), que el INEGI no considera parte de la población residente habitual y para quienes no se captan sexo ni edad.
- **L3 (84,732).** Se conservan las personas de 15 años o más con edad especificada. Esta restricción es la que hace coincidir el proyecto con la definición oficial de población ocupada.
- **L4 (133,180).** Se conservan las personas ocupadas, que son el objeto de estudio.
- **L5 (0).** Se comprueba que todos los ponderadores sean positivos; es una verificación, no excluye a nadie.

4.2 Datos faltantes y códigos especiales

En los archivos del INEGI, un dato desconocido casi nunca aparece vacío: aparece como un **código especial** (99 años de escolaridad, nivel «no especificado», 0 horas...). Si se tratara ese 99 como un número real, se obtendrían promedios absurdos. Por eso cada código se convierte explícitamente en valor faltante y se registra:

Tabla 7. Códigos especiales convertidos en valores faltantes.

Marca	Variable	Código	Registros	Tratamiento
M1	`anios_esc`	99 = no especificado	610	Se convierte en faltante; esa persona no entra al análisis de escolaridad.
M2	`hrsocup`	0 horas trabajadas la semana pasada	5,278	Faltante: están ocupadas pero ausentes de su trabajo esa semana; no se puede calcular el ingreso por hora.
M3	`hrsocup`	> 112 horas semanales	41	Faltante: 112 h equivale a 16 h diarias los 7 días; se considera un error de captura.
M4	`niv_ins`	5 = no especificado	479	Se excluye del análisis por nivel de instrucción.

Los faltantes son una fracción muy pequeña del universo (menos de 3 % en el peor caso), por lo que una eliminación simple no cambia las conclusiones. El caso importante no es este sino el del ingreso, que se trata en la siguiente sección.

4.3 El problema del «ingreso cero»

La variable de ingreso mensual (`ingocup`) vale **cero en 36 % de los registros (39 % de la población ponderada)**. Tomarla literalmente sería un error grave: no son personas que ganen cero. El INEGI capta el ingreso en dos pasos: primero se pregunta el monto exacto y, si la persona no lo da, se le ofrece una lista de rangos en salarios mínimos. `ingocup` solo guarda el monto exacto, y vale 0 cuando no lo hay. Para entender por qué vale 0 se cruza con el rango (`ing7c`) y se obtienen cuatro grupos mutuamente excluyentes y exhaustivos:

Tabla 8. Los cuatro grupos de calidad del ingreso (ocupados de 15 a 65 años).

Grupo	Qué significa	Registros	% ponderado (IC 95 %)	Tratamiento
A	Monto exacto declarado (`ingocup > 0`)	120,948	60.8 % (60.2–61.4)	Es la única con ingreso conocido. Constituye la muestra salarial.
B	Solo rango de salarios mínimos (`ingocup = 0`, `ing7c` 1 a 5)	36,438	22.2 % (21.7–22.8)	Ingreso acotado entre dos valores; se imputa en el análisis de sensibilidad.
C	No recibe ingresos (`ing7c = 6`)	7,666	4.2 % (4.1–4.5)	Cero verdadero: 77 % son trabajadores sin pago. Se excluye del análisis salarial.
D	No especificó (`ing7c = 7`)	25,135	12.7 % (12.3–13.1)	Ingreso desconocido; se excluye y se estudia como no respuesta.

En palabras sencillas

Cuando una persona dice «gano más o menos entre dos y tres salarios mínimos» pero no quiere decir cuánto exactamente, el archivo guarda un 0 en el ingreso. Si no se corrige, parecería que 39 de cada 100 personas ocupadas no ganan nada. En realidad, solo el grupo C (alrededor de 4 de cada 100) no recibe ingreso.

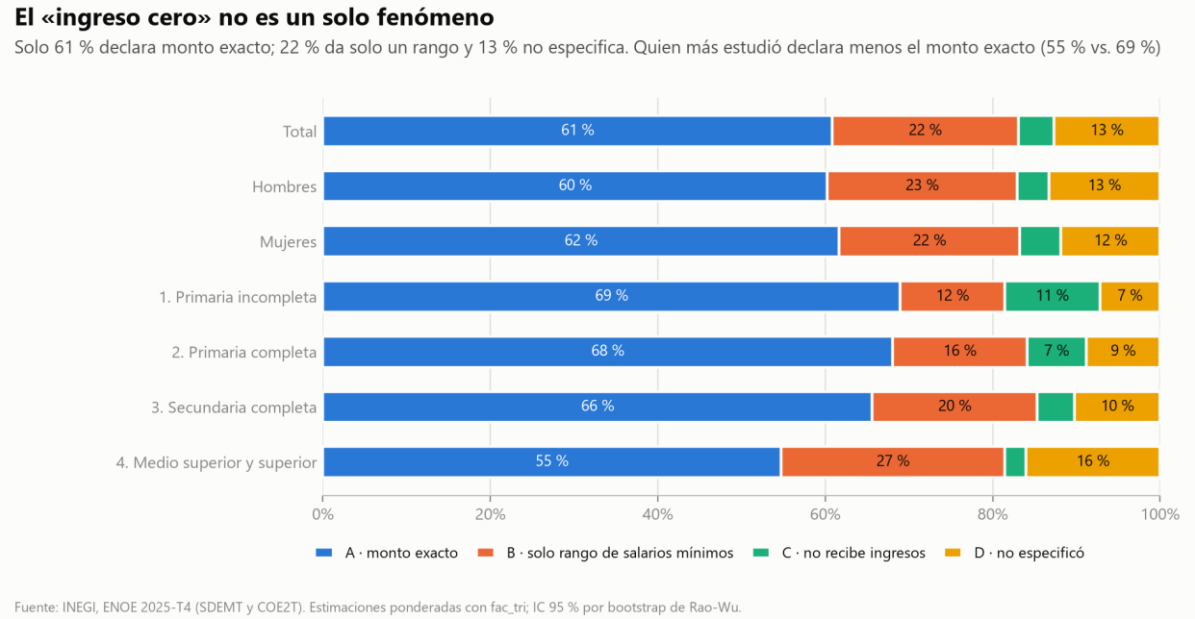


Figura 8. Calidad del ingreso por grupo de declaración: composición total, por sexo y por nivel de instrucción.

¿Quiénes pertenecen a cada grupo?

Tabla 9. Perfil promedio de cada grupo (ponderado).

Grupo	Millones	% mujeres	Años esc.	Edad	% informal	% cuenta propia	% sin pago	Horas/sem.
A	34.5	42	10.5	39	57	19	0	41
B	12.6	40	11.9	40	43	22	0	43
C	2.4	48	8.7	36	99	21	77	33
D	7.2	39	12.2	40	43	21	0	42

El grupo C es distinto de los demás: casi todas sus personas son informales (99 %), 77 % son trabajadores sin pago y tienen menos escolaridad. Los grupos B y D tienen más escolaridad que el A, lo que anticipa que la no respuesta del monto no es aleatoria.

¿La no respuesta es aleatoria? Pruebas χ^2 y regresión logística

Tabla 10. Asociación entre el grupo de ingreso y características de la persona (χ^2 con n = 180,766).

Variable que se cruza con el grupo	χ^2	g.l.	Valor p	V de Cramér
Sexo	333	3	< 0.001	0.043
Nivel de instrucción	5,302	9	< 0.001	0.099
Informalidad	8,512	3	< 0.001	0.217
Posición	147,483	9	< 0.001	0.521

Todas las asociaciones son estadísticamente significativas, pero la **V de Cramér** (0 = sin asociación, 1 = asociación perfecta) revela su tamaño real: mínima con el sexo (0.04), pequeña con el nivel de instrucción (0.10), moderada con la informalidad (0.22) y fuerte con la posición en la ocupación (0.52), lo que es lógico porque el grupo C está formado por trabajadores sin pago.

Tabla 11. Regresión logística de la no respuesta (errores estándar agrupados por UPM). Una razón de momios mayor que 1 aumenta la probabilidad.

Característica	Declarar monto exacto (A) · razón de momios	No especificar el ingreso (D) · razón de momios
Mujer	1.26 (1.22–1.31)	0.83 (0.79–0.87)
Un año más de escolaridad	0.93 (0.93–0.94)	1.08 (1.07–1.08)
Empleo informal	1.43 (1.36–1.50)	0.84 (0.78–0.89)
Empleador (vs. subordinado)	0.58 (0.54–0.63)	1.54 (1.39–1.71)
Cuenta propia (vs. subordinado)	0.63 (0.60–0.67)	1.36 (1.26–1.47)
Un año más de edad	0.99 (0.99–1.00)	1.01 (1.00–1.01)

Lectura. Cada año adicional de escolaridad *reduce* 6.6 % los momios de declarar el monto exacto (razón de momios 0.93) y *aumenta* 7.5 % los de no especificar el ingreso (1.08). Las mujeres tienen mayor probabilidad de declarar el monto exacto (1.26) y los empleadores y trabajadores por cuenta propia, menor. La conclusión es importante: **quienes aparecen en la muestra salarial no son un subconjunto aleatorio**; tienden a tener menos escolaridad que quienes no declaran. Si esa selección distorsionara los resultados, se vería en los

análisis de sensibilidad (imputación de rangos y ponderación por probabilidad inversa), que se presentan en las secciones 6 y 7.

4.4 Imputación del ingreso a partir del rango (grupo B)

A las personas del grupo B se les conoce el rango (por ejemplo «más de 2 a 3 salarios mínimos»), pero no el monto. Para aprovechar esa información en el análisis de sensibilidad se les asigna un valor plausible con una imputación *hot-deck por rango*: se calcula la **mediana ponderada de (ingreso ÷ salario mínimo)** entre quienes sí declararon un monto exacto dentro del mismo rango y se multiplica por el salario mínimo de la persona. Se usa la mediana observada y no el punto medio del rango porque la distribución dentro del rango es asimétrica: hay más personas cerca del límite inferior que del superior.

Tabla 12. Tabla de imputación por rango. SM = salario mínimo mensual de la persona.

Código p6c	Rango declarado	Referencia (grupo A en el rango)	Mediana imputada (× SM)	Personas del grupo B
1	Menos de 1 SM	51,496	0.62	7,994
2	Exactamente 1 SM	88	1.00	11,664
3	Más de 1 a 2 SM	53,258	1.29	12,684
4	Más de 2 a 3 SM	10,386	2.39	3,154
5	Más de 3 a 5 SM	4,304	3.59	762
6	Más de 5 a 10 SM	1,296	5.98	134
7	Más de 10 SM	120	11.96	46

Ejemplo: una persona de la zona general que declaró «más de 2 a 3 salarios mínimos» recibe 2.39 × $8,364 = **$20,000 mensuales** (la mediana de quienes declararon un monto en ese rango). Para el rango «exactamente 1 SM» se asigna 1.00 por definición.

> **Advertencia metodológica**
>
> La imputación asigna **el mismo valor a todos los hombres y mujeres de un mismo rango**, por lo que comprime artificialmente las diferencias entre ellos. En consecuencia, *sesga la brecha de género hacia cero por construcción*. Por eso la imputación se usa solo como análisis de sensibilidad (muestra salarial ampliada: 145,529 personas) y nunca en el resultado principal.

4.5 Valores atípicos

Un ingreso por hora de $5 o de $900 puede ser un error de captura o una persona verdaderamente extrema. Para que unas pocas observaciones no dominen los resultados se excluye el **0.5 % más bajo y el 0.5 % más alto de ln(ingreso por hora) dentro de cada entidad** (percentiles P0.5 y P99.5). El corte se hace por entidad, y no a nivel nacional, para no eliminar sistemáticamente a los habitantes de las entidades más ricas o más pobres. En total se marcan 1,133 observaciones (1.0 % de las 113,338 con ingreso por hora calculable). Los umbrales varían de $2 a $15 por hora en el extremo inferior y de $254 a $594 en el superior, según la entidad.

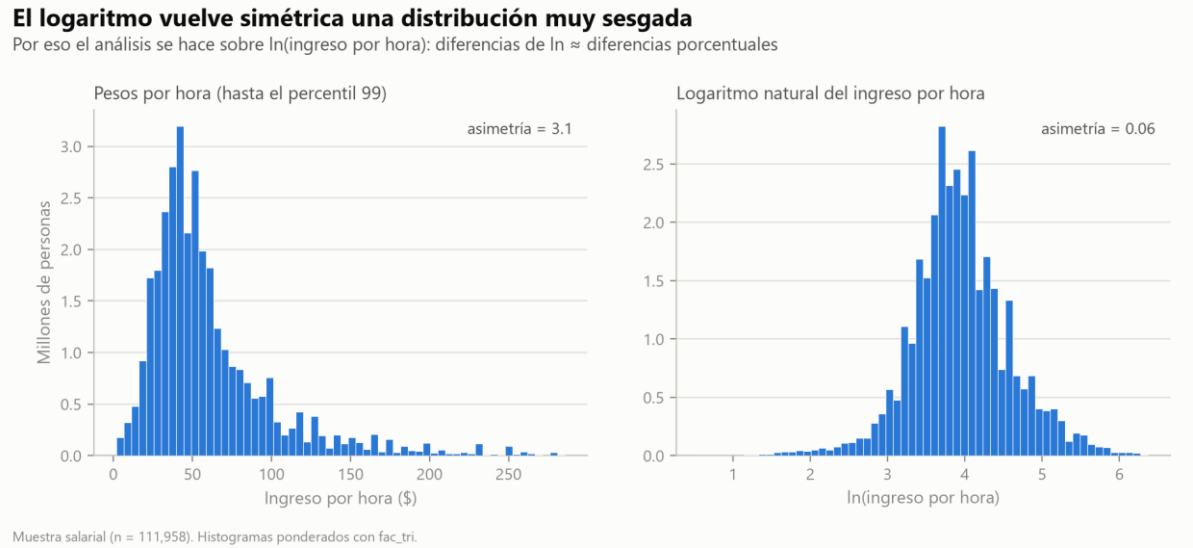


Figura 9. Distribución del ingreso por hora: en pesos (cola larga a la derecha) y en logaritmo natural (casi simétrica).

El logaritmo corrige la asimetría: de 3.07 en pesos a 0.06 en logaritmo, y la curtosis en exceso baja de 14.2 a 1.2. El recorte se evalúa además como análisis de sensibilidad (especificación sin recortar, sección 7.7).

4.6 Muestras de análisis

Del universo de 190,187 ocupados se derivan las muestras de análisis mediante exclusiones sucesivas, todas registradas:

Tabla 13. Embudo de la muestra salarial.

Paso	Descripción	Personas	Excluidas
W0	Ocupados de 15 a 65 años	181,198	0
W1	con monto exacto de ingreso (grupo A)	115,785	65,413
W2	con horas trabajadas válidas (1-112)	113,338	2,447
W3	con escolaridad y nivel especificados	113,088	250
W4	**sin ingreso por hora atípico (P0.5-P99.5 por entidad)**	**111,958**	**1,130**

- **Universo (190,187):** todas las personas ocupadas de 15 años o más. Se usa para informalidad (TIL1), escolaridad y la validación externa.
- **Ventana 15 a 65 años (181,198):** edades en las que la relación ingreso-educación es más estable (excluye a quienes ya se retiran).
- **Muestra salarial (111,958, equivale a 33.4 millones de personas):** ventana 15-65 con monto exacto de ingreso, horas válidas, escolaridad y nivel especificados y sin ingreso atípico. Es la base de todos los resultados salariales.
- **Muestra salarial ampliada (145,529):** agrega a las personas del grupo B con ingreso imputado; solo para sensibilidad.

La mayor pérdida del embudo (65,413 personas) es la del paso W1: quienes no declararon un monto exacto de ingreso. Por eso el análisis de sensibilidad de la selección es una parte central de este trabajo.

4.7 Pruebas automáticas de calidad de los datos (15 «expectativas»)

Después de limpiar y transformar, el ETL verifica **15 expectativas** sobre la base resultante. Son afirmaciones que deben ser verdaderas si los datos están bien; si alguna crítica falla, el proceso se detiene con un error en lugar de continuar con datos dudosos (es el equivalente a las pruebas unitarias, pero aplicadas a los datos).

Tabla 14. Expectativas de calidad de datos evaluadas en cada corrida (15 de 15 cumplidas).

#	Expectativa	¿Cumple?	Tipo	Detalle
1	persona_id único	Sí	Crítica	190,187 ids distintos / 190,187 filas
2	32 entidades presentes	Sí	Crítica	32 entidades
3	sexo en {1,2}	Sí	Crítica	[1, 2]
4	edad entre 15 y 98	Sí	Crítica	min=15, max=98
5	ponderador positivo	Sí	Crítica	min=12
6	todos son ocupados	Sí	Crítica	clase2 == 1
7	grupo de ingreso exhaustivo	Sí	Crítica	A 120,948 · B 36,438 · C 7,666 · D 25,135
8	ing7c consistente con ingocup/salario mínimo	Sí	Crítica	100 % de los registros del grupo A
9	ing_x_hrs = ingocup / (hrsocup x 4.3)	Sí	Crítica	máxima diferencia relativa 7.25e-05
10	niv_ins=1 implica <= 5 años de escolaridad	Sí	Crítica	12,416 registros
11	niv_ins=4 implica >= 12 años de escolaridad	Sí	Crítica	93,188 registros
12	horas entre 0 y 168 (crudas)	Sí	Crítica	max=168
13	ingocup entre 0 y 1,000,000	Sí	Crítica	max=250,000
14	p6c (COE2T) reproduce ing7c (SDEMT) en el grupo B	Sí	Crítica	100 % de 36,438 registros
15	ingocup == p6b2 (COE2T) en el grupo A	Sí	Informativa	100 % de 120,948 registros

Dos de ellas validan el ingreso contra una segunda fuente: la expectativa 9 comprueba que el ingreso por hora recalculado (`ingocup / (hrsocup × 4.3)`) coincide con la variable `ing_x_hrs` del INEGI, y la 14 que el rango `p6c` de la tabla COE2T reproduce al 100 % el rango `ing7c` de SDEMT; esto confirma que la unión de tablas y la interpretación de los códigos son correctas.

5. Transformación e ingeniería de datos (KDD fase 3)

Con los datos limpios, esta fase crea las variables que usarán los modelos y los guarda en una arquitectura pensada para analizar y para servir los resultados. Es la parte de «ingeniería de datos» del proyecto: no solo importa el resultado, sino que el proceso sea **repetible, auditable y verificable**.

5.1 Variables derivadas

Tabla 15. Principales variables derivadas en la fase de transformación.

Variable	Definición	Para qué sirve
`mujer`	1 si `sex = 2`, 0 si hombre	Variable binaria para regresiones y la brecha de género.
`edad2`	`eda² / 100`	Término cuadrático de la edad (el ingreso sube con la experiencia y luego se aplana). Se divide entre 100 para que el coeficiente sea legible.
`grupo_edad`	15-24, 25-34, 35-44, 45-54, 55-64, 65+	Heterogeneidad por edad (sección 7.8).
`informal`	1 si `emp_ppal = 1`, 0 si formal	Variable de informalidad (TIL1).
`niv_det`	Nivel 4 dividido: medio superior (4) vs. superior (5, con 16+ años)	Detalle del nivel de instrucción para el premio por nivel.
`entidad`, `region`	Nombre y región (Norte, Centro-Norte, Centro, Sur)	Etiquetas y análisis regional.
`log_horas`	ln(`hrsocup`)	Control de horas trabajadas.
`grupo_ingreso`	A, B, C o D según `ingocup` e `ing7c`	Calidad del ingreso (sección 4.3).
`ing_mensual`	`ingocup` solo en el grupo A	Ingreso mensual conocido.
`ing_hora`	`ingocup / (hrsocup × 4.3)` (grupo A, horas válidas)	Ingreso por hora; se verifica contra el del INEGI.
`ln_ing_hora`	ln(`ing_hora`)	Variable dependiente de los modelos.
`ing_mensual_imp`, `ing_hora_imp`	Imputación por rango para el grupo B	Solo en análisis de sensibilidad.
`persona_id`	Concatenación de la llave de 11 campos	Llave primaria legible.

Siete banderas (`en_ventana_15_65`, `anios_esc_valido`, `horas_validas`, `nivel_especificado`, `outlier_ing_hora`, `en_muestra_salarial` y `en_muestra_salarial_ext`) definen, combinadas, las muestras de análisis. La tabla de hechos guarda 36 columnas para las 190,187 personas ocupadas; las transformaciones puramente algebraicas (`mujer`, `edad2`, `log_horas`) se calculan en el momento del análisis.

5.2 Arquitectura del proyecto

El proyecto es una tubería de datos de cinco etapas con dos almacenes. Cada etapa es una función de Python independiente, probada por separado y encadenada por un orquestador (`pipeline.py`):

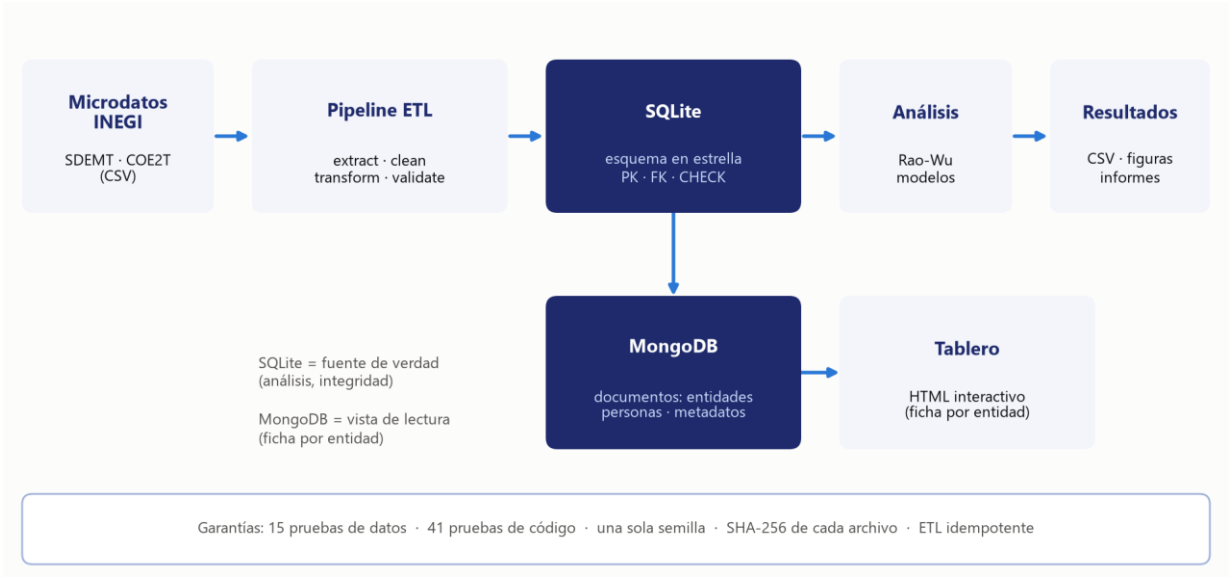


Figura 10. Arquitectura del proyecto: de los microdatos del INEGI a los resultados, el tablero y la base documental.

- **Microdatos** (CSV del INEGI) → **ETL** (extraer, limpiar, transformar, validar) → **SQLite** (almacén relacional, fuente de verdad).
- **Análisis** estadístico lee de SQLite/ETL y escribe 30 tablas de **resultados** (CSV y tablas `res_*` en la propia base).
- **MongoDB** recibe una copia derivada (documentos por entidad y por persona) para servir el tablero.
- Garantías transversales: semilla única (20251231), idempotencia, 41 pruebas automáticas, bitácora de ejecución y huellas SHA-256 de los datos de origen.

5.3 Almacén relacional: SQLite con esquema en estrella

¿Por qué una base de datos relacional? Los datos de la ENOE son una tabla rectangular de esquema fijo y el análisis consiste en agregaciones (`GROUP BY`) y uniones (`JOIN`): justo para lo que fue diseñado SQL. **¿Por qué SQLite?** Es una base completa (transacciones ACID, SQL estándar, restricciones de integridad) contenida en **un solo archivo**, sin servidor que instalar, lo que hace el proyecto reproducible en cualquier computadora.



Figura 11. Esquema en estrella: la tabla de hechos fact_ocupado (190,187 filas) rodeada de diez tablas de dimensiones.

En un **esquema en estrella** la tabla de hechos contiene las mediciones (una fila por persona ocupada) y cada dimensión describe un atributo (entidad, sexo, nivel de instrucción...) con una clave. Ventajas: se evita repetir textos largos en 190 mil filas, los cambios de una descripción se hacen en un solo lugar y las consultas son rápidas y legibles.

Tabla 16. Objetos de la base de datos relacional (44 MB; además contiene 24 tablas de resultados `res_*`).

Objeto	Tipo	Filas	Descripción
v_calidad_ingreso_entidad	Vista	128	Vista: composición A/B/C/D por entidad.
v_escolaridad_entidad	Vista	32	Vista: años de escolaridad promedio por entidad.
v_muestra_salarial	Vista	111,958	Vista: la muestra salarial lista para el análisis.
v_til_entidad	Vista	32	Vista: TIL1 ponderado por entidad.
dim_entidad	Tabla	32	32 entidades federativas con nombre, abreviatura, región y posición en el mosaico.
dim_grupo_ingreso	Tabla	4	Los grupos A, B, C y D.
dim_ing7c	Tabla	7	Rangos de ingreso en salarios mínimos.
dim_nivel_detalle	Tabla	5	Niveles con el medio superior y el superior separados.
dim_nivel_instruccion	Tabla	5	Cuatro niveles de instrucción más «no especificado».
dim_posicion_ocupacion	Tabla	4	Subordinado, empleador, cuenta propia, sin pago.
dim_rama	Tabla	12	Gran rama de actividad económica.
dim_sexo	Tabla	2	Hombre/Mujer.
dim_tamano_localidad	Tabla	4	Tamaño de la localidad.
dim_upm	Tabla	21,194	Unidades primarias de muestreo con su estrato (original y colapsado).
etl_bitacora	Tabla	16	Auditoría: reglas de limpieza y registros afectados.
etl_embudo_salarial	Tabla	5	Auditoría: embudo de la muestra salarial.
etl_expectativas	Tabla	15	Auditoría: resultado de las 15 expectativas.

Objeto	Tipo	Filas	Descripción
etl_imputacion_rangos	Tabla	7	Auditoría: tabla de imputación.
etl_run	Tabla	16	Linaje: versiones, semilla, huellas SHA-256, parámetros.
etl_umbrales_atipicos	Tabla	32	Auditoría: umbrales de ingreso atípico por entidad.
etl_validacion_externa	Tabla	7	Auditoría: comparación con cifras del INEGI.
fact_ocupado	Tabla	190,187	Hechos: una fila por persona ocupada, con 36 columnas.

Integridad: el motor rechaza los datos inconsistentes

- **Llaves primarias** (`persona_id`, `upm`, `cve_ent`...): sin duplicados.
- **Llaves foráneas** (`PRAGMA foreign_keys = ON`): cada código de la tabla de hechos debe existir en su dimensión.
- **Restricciones CHECK**: `fac_tri > 0`, eda entre 15 y 98, `emp_ppal` en {1, 2}, `hrsocup_raw` entre 0 y 168, grupo en {A, B, C, D}.
- **Verificación al cargar:** `integrity_check = ok`, 0 violaciones de llave foránea, 190,187 filas, suma de ponderadores 59.79 millones y TIL1 nacional calculado con SQL de 55.00 %.

Un ejemplo de consulta

La vista `v_til_entidad` calcula la tasa de informalidad ponderada de cada entidad. Obsérvese que la ponderación se expresa directamente en SQL:

```
SELECT e.entidad,
       ROUND(100.0 * SUM(f.fac_tri * f.informal) / SUM(f.fac_tri), 2) AS til1_pct
FROM fact_ocupado f
JOIN dim_entidad e USING (cve_ent)
GROUP BY e.entidad
ORDER BY til1_pct DESC;
```

Se crearon además cinco índices (por entidad, UPM, entidad-sexo, muestra salarial y grupo de ingreso) para acelerar estas agregaciones.

5.4 Almacén documental: MongoDB

Una base **documental** guarda cada elemento como un documento JSON anidado, sin un esquema rígido. Es la herramienta adecuada cuando se necesita leer «toda la información de un elemento» en una sola operación. En este proyecto sirve para el tablero: al elegir un estado se muestra su ficha completa (informalidad, escolaridad, ingreso, rendimiento, correlación, brecha, calidad del ingreso).

Persistencia políglota: cada base donde funciona mejor

Tabla 17. Justificación de la elección de modelo de datos.

Uso	Patrón de acceso	Modelo elegido	Por qué
Análisis estadístico	Agregaciones ponderadas y uniones sobre 190 mil filas; regresiones	Relacional · SQLite	Datos tabulares de esquema fijo; SQL expresa `GROUP BY` y `JOIN`; restricciones de integridad; archivo único y ACID.
Servicio de lectura (tablero, API)	«Dame la ficha de la entidad 20»	Documental · MongoDB	Un documento por clave con todo anidado (*embedding*), sin `JOIN`; el esquema puede crecer sin migraciones; escala por entidad.

La elección responde al **patrón de acceso**, no al volumen: 190 mil filas caben en memoria y no son un caso de «big data». SQLite es la fuente de verdad; los documentos de MongoDB son una vista materializada que se regenera con `scripts/run_mongo.py`.

Modelo de documentos

Base `enoe_2025t4` con tres colecciones:

- **`entidades`** (32 documentos): una ficha por entidad con indicadores, intervalos de confianza y lugares en el ranking, todos **embebidos** porque siempre se leen juntos.
- **`personas`** (190,187 documentos): una persona por documento con subdocumentos temáticos (`persona`, `trabajo`, `ingreso`, `diseno`, `muestras`). No se embeben dentro de la entidad porque 190 mil subdocumentos superarían el límite de 16 MB de BSON; se relacionan por `cve_ent`.
- **`metadatos`** (1 documento): linaje del pipeline (versiones, semilla, parámetros, huellas SHA-256).

```
{
  "_id": 20, "cve_ent": 20, "entidad": "Oaxaca", "region": "Sur", "periodo": "2025-T4",
  "informalidad": {"til1_pct": 80.06, "ic95": [78.11, 81.88], "lugar": 1},
  "escolaridad":  {"anios_medios_ocupados": 9.07, "ic95": [8.82, 9.33]},
  "rendimiento_escolaridad": {"pct_por_anio": 6.18, "ic95": [5.21, 7.17]},
  "correlacion_spearman": {"rho": 0.28, "ic95": [0.23, 0.33], "lugar": 20},
  "brecha_genero": {"hora_pct": 16.5, "hora_ic95": [7.3, 25.0], "mensual_pct": 40.7},
  "calidad_ingreso_pct": {"A": 58.0, "B": 14.0, "C": 18.0, "D": 10.0}
}
```

Los índices creados (`entidades.cve_ent` único; `region`; `informalidad.til1_pct`; en `personas`: `cve_ent`, `cve_ent + ingreso.grupo`, `cve_ent + persona.sexo` y un índice **parcial** solo para la muestra salarial) corresponden a las consultas que hace el tablero.

La misma pregunta en SQL y en MongoDB

Tabla 18. Consultas equivalentes.

Pregunta	SQL	MongoDB
Ficha de Oaxaca	`SELECT * FROM … WHERE cve_ent = 20`	`db.entidades.findOne({cve_ent: 20})`
Entidades con TIL1 > 70 %	`… HAVING til1_pct > 70`	`db.entidades.find({"informalidad.til1_pct": {$gt: 70}})`
TIL1 ponderado por entidad	`SUM(fac_tri*informal)/SUM(fac_tri) … GROUP BY cve_ent`	`db.personas.aggregate([{$group: {_id: "$cve_ent", ocupados: {$sum: "$fac_tri"}, informales: {$sum: {$cond: ["$trabajo.informal", "$fac_tri", 0]}}}}, …])`

Qué se verificó y qué no (alcance honesto)

- **Verificado:** los documentos se construyen y se exportan (`entidades.json`, `entidades.ndjson`, `personas.ndjson.gz`, `metadatos.ndjson`) y la **carga completa se probó contra mongomock**, un simulador de MongoDB en memoria: los 190,187 documentos de persona, los 32 de entidad y el de metadatos, siete índices, documentos BSON válidos y una recarga que no duplica nada. El pipeline de agregación «TIL1 por entidad», ejecutado en el motor, reproduce la vista SQL `v_til_entidad` con una diferencia máxima de 0.005 puntos porcentuales (el redondeo del SQL); el tablero se alimenta de la colección `entidades`. Siete pruebas automáticas cubren esta capa.
- **No ejecutado:** la carga a un servidor MongoDB real, porque en el equipo de desarrollo no hay un servidor. mongomock imita la API y la agregación, pero **no es MongoDB**: no reproduce todo el comportamiento del servidor (por ejemplo, algunas reglas sobre los índices). El código de carga usa solo `insert_many`, `create_index` y `drop_collection`, y los archivos están listos para `mongoimport`.

> **Cómo cargar en un servidor real**
>
> Con Python: `pip install -r requirements.txt` (incluye pymongo) y luego `python scripts/run_mongo.py --uri mongodb://localhost:27017` (o una URI de MongoDB Atlas).
>
> Sin Python: `mongoimport --db enoe_2025t4 --collection entidades --file data/processed/mongo/entidades.ndjson`.
>
> Sin servidor: `python scripts/run_mongo.py --simulado --limite 20000` carga y verifica contra mongomock (sin `--limite`, la carga completa tarda unos 6 minutos).

5.5 Reproducibilidad y pruebas

Un resultado científico solo vale si otra persona puede obtenerlo. El proyecto incorpora varios mecanismos:

- **Una sola orden:** `python scripts/run_all.py` ejecuta el ETL, el análisis, las figuras, la base documental, el tablero, el cuaderno, las dos presentaciones, el informe en Word y las 41 pruebas (de 6 a 10 minutos según el equipo; la opción `--rapido` usa 100 réplicas bootstrap y omite el cuaderno, las presentaciones y el informe).
- **Semilla fija:** toda operación aleatoria usa la semilla 20251231. Dos ejecuciones producen exactamente los mismos números: se comprobó que los 30 archivos de resultados son idénticos.
- **Idempotencia:** la base se recrea desde cero y las colecciones documentales se eliminan y recargan, de modo que correr el proceso dos veces no duplica datos.
- **Linaje:** la tabla `etl_run` guarda las versiones de Python y las bibliotecas, la semilla, los parámetros y la huella SHA-256 de cada archivo de origen.
- **Pruebas automáticas (41):** limpieza, estadística de encuestas (comparadas con `statsmodels` y con soluciones analíticas), modelos, la capa documental contra mongomock y una prueba de integración con los datos reales (se omite si los datos no están).
- **Parámetros centralizados:** todos los umbrales y catálogos viven en `config.py`; ninguna cifra queda «escondida» dentro del código.

Tabla 19. Conjunto de pruebas automáticas (41 en total).

Archivo	Pruebas	Qué verifica
`test_clean.py`	8	Cada regla de cobertura excluye lo que debe; ventana 15-65; recodificación de faltantes; grupos de ingreso excluyentes (y error si un ingreso queda sin clasificar); ingreso por hora; atípicos por entidad; imputación por mediana del rango
`test_survey.py`	13	Cuantiles y medias ponderadas; Spearman ponderado (igual a SciPy y a los datos «expandidos»); WLS; Holm; colapso de estratos; factores Rao-Wu con esperanza 1 y reproducibles; bootstrap = Taylor; el diseño complejo agranda la varianza; dominios; IC percentil
`test_modelos.py`	6	WLS y logit con diseño iguales a `statsmodels`; el efecto de conglomerado agranda el error; dominios con ponderadores cero; identidad exacta de Oaxaca-Blinder; brecha en %
`test_etl_datos_reales.py`	7	Integridad de SQLite; cifras oficiales del INEGI; TIL1 estatal; conteos de la cascada; la muestra salarial cumple su definición; 32 entidades y ponderador positivo; la vista de calidad suma 100 %
`test_mongo_simulado.py`	7	Capa documental contra mongomock: carga por lotes e idempotente, siete índices, documentos BSON válidos, el pipeline de agregación reproduce la vista SQL y la comparación detecta una diferencia

5.6 Mapa del código

El código está organizado como un paquete de Python (`src/enoe/`) con una responsabilidad por módulo, y un conjunto de scripts que lo ejecutan:

Tabla 20. Mapa del código fuente.

Módulo	Qué contiene
config.py	Rutas, parámetros (edad, horas, semilla, réplicas), catálogos de entidades y cifras de referencia del INEGI.
extract.py	Lectura de los CSV (latin-1), selección de columnas, huella SHA-256.
clean.py	Filtros de cobertura, faltantes, grupos de ingreso, atípicos, muestras y las 15 expectativas.
transform.py	Llave de persona, unión SDEMT-COE2T, variables derivadas e imputación por rangos.
validacion.py	Comparación con las cifras publicadas por el INEGI.
load_sqlite.py, **load_mongo.py**	Carga al modelo relacional y al modelo documental.
pipeline.py	Orquesta el ETL completo y escribe los metadatos.
survey.py	Estadística de encuestas: diseño, Rao-Wu, Taylor, Spearman ponderado, WLS/logit, Holm.
datos.py, **estimadores.py**, **modelos.py**	Bloques de réplicas, fábricas de estimadores, modelos de regresión, Oaxaca-Blinder y IPW.
analisis.py	Ejecuta todo el análisis y escribe las 30 tablas de resultados.
viz.py, **viz_diagramas.py**, **figuras.py**	Las 17 figuras de datos y los 8 diagramas explicativos.
scripts/	`run_etl`, `run_analysis`, `make_figures`, `run_mongo`, `build_dashboard`, `build_notebook`, `build_deck` (corta), `build_deck_completa`, `build_informe` y `run_all`; las bibliotecas de diseño `deck_lib`, `deck_slides_base`, `deck_slides_extra`, `informe_lib`, `informe_datos` e `informe_s1` a `informe_s4`.

6. Metodología estadística (KDD fase 4: análisis)

Esta sección detalla **qué se calculó, cómo y con qué supuestos**. Es el puente entre los conceptos de la sección 2 y los resultados de la sección 7: aquí se fija, para cada objetivo, el estimador, la medida de incertidumbre y las decisiones que tomó el equipo.

6.1 Poblaciones y muestras

Tabla 21. Poblaciones y muestras de análisis.

Nombre	Definición	n	Se usa para
Universo	Ocupados de 15+ años, entrevista completa (`r_def = 0`), residentes habituales (`c_res` ∈ {1, 3})	190,187	Informalidad (objetivo 3), escolaridad, validación externa
Ventana 15-65	Universo con `eda ≤ 65`	181,198	Ventana definida en el protocolo
Muestra salarial	Ventana + monto exacto (grupo A) + 1 ≤ horas ≤ 112 + escolaridad y nivel especificados + sin atípicos	111,958	Resultado principal de ingreso (objetivos 1 y 2)
Muestra salarial ampliada	Igual, pero grupos A o B (B con ingreso imputado por rango)	145,529	Solo análisis de sensibilidad

¿Por qué 15 años o más para la informalidad? Porque es la base con la que el INEGI publica sus indicadores: con ella se reproducen siete cifras oficiales (sección 3.4). *¿Por qué 15 a 65 años para el ingreso?* Es la ventana del protocolo y evita mezclar a personas en retiro, cuyo ingreso responde a otras dinámicas.

6.2 Definiciones operativas

Tabla 22. Definiciones operativas de los indicadores.

Concepto	Fórmula	Cómo se lee
Ingreso por hora	`ingocup / (hrsocup × 4.3)`	Pesos por hora trabajada. Se trabaja con su logaritmo natural.
Rendimiento de la escolaridad	`100 × (exp(β) − 1)`	β es el coeficiente de `anios_esc` en la regresión de Mincer. Es el % de aumento del ingreso por hora por cada año de estudio.
Brecha de género (%)	`100 × (1 − exp(−Δ))`, con `Δ = media(ln w | hombres) − media(ln w | mujeres)`	«Las mujeres ganan X % menos que los hombres», comparando ingresos medios geométricos. Un valor negativo significa que ganan más.
Brecha mensual y de horas	Igual, con `ln(ingocup)` y `ln(hrsocup)`	Por identidad en logaritmos: *brecha mensual = brecha por hora + brecha de horas*.
TIL1	`ocupados informales / ocupados de 15+` (ponderado)	Tasa de informalidad laboral, definición oficial del INEGI.

Verificación de la identidad con los datos: en log-puntos, la brecha mensual (0.3132) es igual a la brecha por hora (0.0375) más la brecha de horas (0.2756), porque 0.0375 + 0.2756 = 0.3132.

6.3 Inferencia con el diseño muestral complejo

Tratar la ENOE como una muestra aleatoria simple subestima los errores estándar (sección 2.2). Los pasos para evitarlo son:

1. **Estratos con una sola UPM.** Para estimar la varianza hacen falta al menos dos UPM por estrato. Hay 11 estratos con una sola UPM (de 724); se fusionan con el estrato vecino de la misma entidad (*collapsed strata*), lo que deja 713 estratos con dos UPM o más.
2. **Bootstrap de Rao y Wu (1988).** En cada estrato con n UPM se remuestrean $n - 1$ UPM con reemplazo y el ponderador de cada persona se multiplica por $n/(n-1) \times$ *(veces que salió su UPM)*. Se generan B = 1,000 réplicas con una **única semilla** (20251231) para todo el proyecto, de modo que la réplica b es el mismo remuestreo en todos los análisis (esto permite, por ejemplo, calcular el ranking de las entidades en cada réplica).
3. **Dominios.** Las réplicas se construyen sobre **todas las UPM** de la muestra completa y cada fila de un subconjunto (la muestra salarial, una entidad, un nivel...) toma el factor de su UPM. Así no se pierde variabilidad cuando una UPM no aporta casos al dominio, un error común al filtrar antes de estimar.
4. **Intervalos y pruebas.** El intervalo de confianza es el percentil 2.5 y 97.5 de las réplicas. Las pruebas de hipótesis son de Wald bilaterales con el error estándar bootstrap (los grados de libertad del diseño, cerca de 20 mil, justifican la aproximación normal).
5. **Modelos de regresión y logit.** Se usa el estimador de sándwich con **linealización de Taylor** que respeta estratos y UPM (`survey.regresion_diseno` y `survey.logit_diseno`), equivalente a `svy:` de Stata o al paquete `survey` de R. Se verificó contra `statsmodels`: mismos coeficientes y errores equivalentes en el caso de muestreo aleatorio simple.

Tabla 23. Efecto de diseño: cuánto cambia el error estándar al respetar estratos y UPM (el EE como muestreo aleatorio simple, m.a.s., es siempre menor).

Estimador	n	EE con diseño	EE como m.a.s.	Efecto de diseño	n efectivo
TIL1 nacional	190,187	0.0025	0.0011	4.79	39,704
Brecha por hora total (log-puntos)	111,958	0.0067	0.0038	3.08	36,310

El efecto de diseño de 4.8 en la tasa de informalidad significa que la varianza real es casi cinco veces mayor que la de una muestra aleatoria simple, o que los 190 mil ocupados equivalen a unos 40 mil independientes; para la brecha por hora es de 3.1. Ignorar el diseño haría que los errores estándar fueran entre 1.8 y 2.2 veces demasiado pequeños (la raíz cuadrada del efecto de diseño).

6.4 Estimadores y pruebas por objetivo

Tabla 24. Estimadores y medidas de incertidumbre para cada objetivo.

Objetivo	Estimador	Incertidumbre
Correlación escolaridad-ingreso por entidad (M2)	Spearman ponderado: Pearson entre rangos medios ponderados	Bootstrap de Rao-Wu; lugar de cada entidad en el ranking con su intervalo (el ranking se recalcula en cada réplica)
Rendimiento por entidad	WLS por entidad con edad, edad² y sexo	Bootstrap de Rao-Wu
Estados de mayor vs. menor ingreso	Cuartiles de ingreso mediano por hora (recalculados en cada réplica); diferencia del rendimiento medio Q4 − Q1	Bootstrap + Wald
Brecha por hora, mensual y de horas por nivel (M1)	Diferencia de medias ponderadas de logaritmos	Bootstrap + Wald; **Holm** sobre las cuatro pruebas por nivel
Pruebas «clásicas» del protocolo	Welch (t) y Mann-Whitney por nivel, sin ponderar; *d* de Cohen; correlación biserial por rangos	Valores p ajustados con Holm
Brecha ajustada	WLS de ln(w) sobre `mujer` con escalera de controles G0 a G6	Sándwich de diseño
Descomposición de la brecha	Oaxaca-Blinder con referencia agrupada de Neumark (1988); también con coeficientes de hombres o de mujeres	Bootstrap
Brecha por percentil	Cuantiles ponderados por sexo; diferencia en P10, P25, P50, P75 y P90	Bootstrap
Informalidad (objetivo 3)	TIL1 ponderado (nacional, sexo, región, nivel, entidad); asociación entre estados (Pearson, Spearman, pendiente); logit individual y efecto marginal promedio	Bootstrap / sándwich
No respuesta del ingreso	Logit ponderado «A vs. resto» y «D vs. resto»; IPW	Sándwich de diseño

Tamaño del efecto. Con 112 mil observaciones casi cualquier diferencia es «significativa»; por eso se reportan siempre la brecha en % y la *d* de Cohen. **Multiplicidad.** Holm controla el error por familia de pruebas: los cuatro niveles de instrucción y las categorías de cada dimensión de heterogeneidad. Los 32 intervalos por entidad no se prueban uno a uno: se reporta el ranking con su incertidumbre.

6.5 El sesgo de división: por qué no se interpreta el modelo con horas

El ingreso por hora es el ingreso mensual dividido entre las horas semanales. Si las horas tienen algún error de medición (la encuesta pregunta las horas de *una sola semana*), ese error aparece en el denominador de la variable dependiente y crea una relación negativa **mecánica** entre ln(ingreso por hora) y ln(horas), aunque no exista una relación económica. Controlar por horas infla entonces la brecha ajustada (de 8.2 % a 16.3 %) y la «parte explicada» por horas (-11 puntos logarítmicos).

Decisión

El modelo con horas (G6) y la descomposición «con horas» se muestran **solo por transparencia y no se interpretan**. La estimación de referencia para «personas comparables» es G5 (8.2 %), que no controla por horas. La brecha **mensual** sí se interpreta, porque la identidad en logaritmos es exacta: la diferencia mensual se descompone sin sesgo en diferencia por hora más diferencia de horas.

6.6 Decisiones del analista y su sensibilidad

Tabla 25. Decisiones metodológicas y cómo se evaluó su efecto.

Decisión	Valor elegido	Sensibilidad
Ventana de edad	15-65 (protocolo); 15+ para informalidad	La base oficial es 15+
Horas válidas	1 ≤ horas ≤ 112	Solo 41 casos con más de 112 horas
Atípicos	Fuera de P0.5-P99.5 del ingreso por hora de su entidad	S1 «sin recorte»: brecha 3.6 % vs. 3.7 %; rendimiento 5.4 % vs. 5.1 %
Ingreso faltante	Muestra del grupo A (monto exacto)	S2 (asalariados), S3 (imputación) y S4 (IPW)
Estratos con una UPM	Se fusionan con el estrato vecino	—
Réplicas bootstrap	1,000 con una semilla única	—
Nivel detallado	El nivel 4 se divide con `anios_esc` (12 a 15 años / 16+)	Resultados por subnivel (sección 7.8)

6.7 Verificación del método

Las piezas estadísticas se programaron desde cero (no hay una biblioteca estándar de Python para el bootstrap de Rao-Wu), por lo que se verificaron con pruebas automáticas: el factor de remuestreo tiene esperanza 1; la varianza bootstrap coincide con la de Taylor (dentro de ±8 %); el Spearman ponderado coincide con `scipy.stats.spearmanr` cuando los pesos son iguales y con los datos «expandidos» cuando son enteros; la regresión ponderada coincide con `statsmodels`; la descomposición de Oaxaca-Blinder cumple su identidad exacta; y con efecto de conglomerado el error con diseño supera al de muestreo aleatorio simple.

7. Resultados

Todos los resultados se calculan con los ponderadores de la encuesta, con intervalos de confianza del 95 % del bootstrap de Rao-Wu (salvo que se indique lo contrario) y con 1,000 réplicas. Cada subsección explica **qué se calculó**, muestra el resultado y termina con una **lectura** en palabras sencillas.

7.1 Panorama: la muestra salarial

Tabla 26. Descriptivos ponderados de la muestra salarial (n = 111,958, 33.4 millones de personas).

Variable	Media (total)	Mediana (total)	Media hombres	Media mujeres
Ingreso por hora ($)	64.0	50.0	64.4	63.5
Ingreso mensual ($)	10,632	8,600	11,703	9,145
Horas por semana	42.3	45.0	45.7	37.5
Años de escolaridad	10.5	10.0	10.2	11.0
Edad	38.8	38.0	38.6	39.2

La persona ocupada típica de la muestra salarial tiene 39 años, 10.5 años de estudio (secundaria terminada y un poco más), trabaja 42 horas a la semana y gana $50 por hora ($8,600 al mes). Las mujeres trabajan menos horas (37.5 frente a 45.7) y tienen algo más de escolaridad (11.0 frente a 10.2 años).

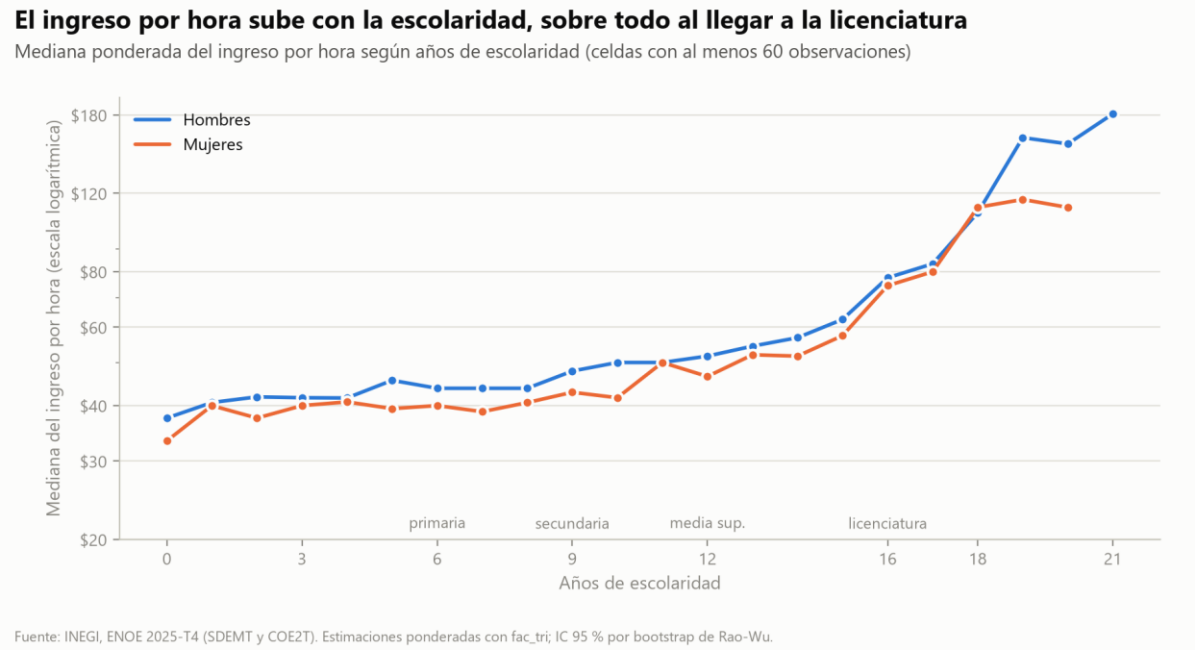


Figura 12. Mediana ponderada del ingreso por hora según los años de escolaridad, por sexo (escala logarítmica).

Lectura. El ingreso por hora casi no cambia durante los primeros años de escolaridad (la curva es casi plana de 0 a 10 años), empieza a subir con la preparatoria y da su salto más grande al llegar a la licenciatura. La curva de las mujeres queda por debajo de la de los hombres en casi todos los niveles; las diferencias más visibles aparecen con 0 a 10 años de estudio y con posgrado (19 y 20 años), mientras que con 11 años y entre 16 y 18 las medianas casi coinciden.

7.2 Rendimiento de la escolaridad (objetivo 1)

Qué se calculó. El coeficiente de Mincer: en una regresión del logaritmo del ingreso por hora sobre los años de escolaridad, controlando por edad, edad², sexo, entidad y tamaño de localidad (modelo M3), se obtiene el aumento porcentual del ingreso por cada año adicional de estudio. Se compararon cinco especificaciones para ver cómo cambia al agregar controles:

Tabla 27. Rendimiento por año de escolaridad según el modelo (n = 111,958). El modelo M3 es el de referencia.

Modelo	β (log-puntos)	Rendimiento por año, % (IC 95 %)	R^2
M1 Mincer simple	0.0561	5.77 (5.57 a 5.97)	0.126
M2 + edad, edad² y sexo	0.0597	6.15 (5.94 a 6.36)	0.152
M3 + entidad y localidad	**0.0501**	**5.14 (4.96 a 5.32)**	**0.241**
M4 + posición, informalidad y rama	0.0375	3.82 (3.64 a 4.00)	0.300
M5 interacción: efecto en hombres	0.0455	4.66 (4.44 a 4.88)	0.243
M5 interacción: diferencia de las mujeres	0.0107	1.08 (0.78 a 1.37)	0.243

- **Resultado principal (M3): 5.1 % por año** (IC 95 %: 5.0 a 5.3). Es la comparación entre personas de la misma edad, sexo, entidad y tamaño de localidad.
- Al agregar solo edad y sexo (M2) sube a 6.1 %; al incluir la entidad y el tamaño de localidad (M3) baja a 5.1 % porque parte de la ventaja de estudiar se debe a vivir en lugares de mayor ingreso.
- Al agregar la posición en la ocupación, la informalidad y la rama (M4) baja a 3.8 %: una parte del beneficio de estudiar **actúa a través** de conseguir mejores empleos (formales, asalariados). Por eso M4 no es el resultado principal: controlar por un canal subestimaría el beneficio total.
- **Por sexo (M5):** 4.6 % para los hombres y 5.9 % para las mujeres; la diferencia es de 0.012 log-puntos ($p < 0.001$). Cada año de estudio rinde algo más a las mujeres.

El rendimiento no es lineal: el premio por nivel

Tabla 28. Premio salarial por nivel respecto a primaria incompleta (controlando edad, sexo y entidad).

Nivel de instrucción	Premio frente a primaria incompleta	IC 95 %	n
Primaria completa	+6.9 %	4.1 a 9.7	14,656
Secundaria completa	+15.8 %	12.9 a 18.7	38,874
Media superior / superior trunca (12-15 años)	+28.4 %	25.0 a 31.9	29,507
Licenciatura o posgrado (16+ años)	+92.4 %	87.1 a 97.9	22,582

Lectura. Terminar la primaria agrega 7 % al ingreso por hora; la secundaria, 16 %; la preparatoria, 28 %; y una licenciatura o posgrado, **92 %** (casi lo duplica). El beneficio de estudiar se concentra en los niveles altos, no se reparte parejo entre los años.

Diferencias entre entidades

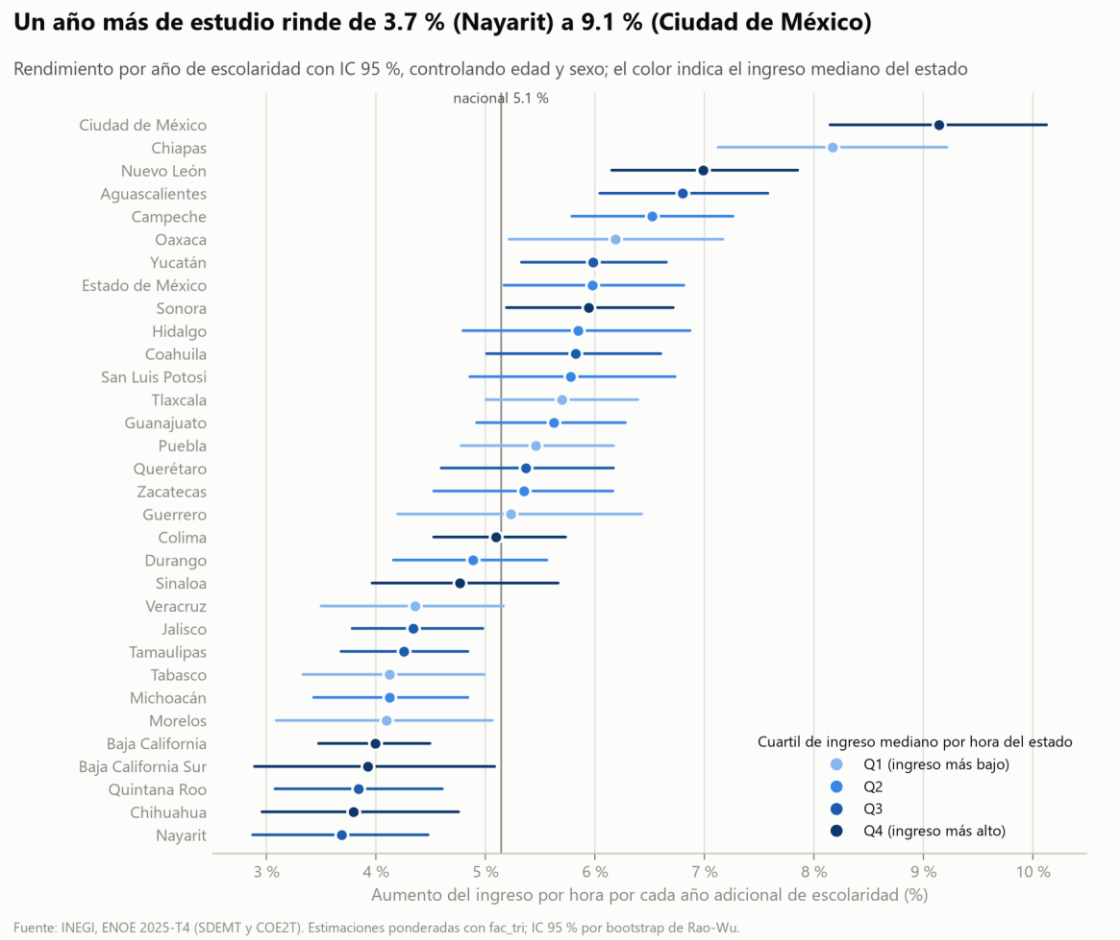


Figura 13. Rendimiento por año de escolaridad en cada entidad (con IC 95 %). El color indica el cuartil de ingreso mediano por hora del estado.

Lectura. El rendimiento va de 3.7 % (Nayarit) a 9.1 % (Ciudad de México). Sin embargo, la mayoría de los intervalos se traslapan (la precisión por entidad es limitada: entre 1,900 y 5,900 observaciones salariales por estado), de modo que solo las diferencias grandes son confiables.

¿Es distinto el rendimiento en los estados de mayor y menor ingreso?

Tabla 29. Rendimiento y correlación promedio por cuartil de ingreso estatal.

Estados agrupados por ingreso mediano por hora	Rendimiento medio por año, % (IC 95 %)	Spearman medio (IC 95 %)
Cuartil 1 (ingreso más bajo)	5.41 (5.16 a 5.90)	0.30 (0.28 a 0.32)
Cuartil 2	5.51 (5.06 a 5.81)	0.30 (0.27 a 0.32)
Cuartil 3	5.01 (4.72 a 5.68)	0.30 (0.27 a 0.33)
Cuartil 4 (ingreso más alto)	5.44 (4.73 a 5.70)	0.32 (0.29 a 0.34)

La diferencia de rendimiento entre los cuartiles de mayor y menor ingreso es de 0.0003 log-puntos (IC -0.008 a 0.003; p = 0.91); la de las correlaciones es de 0.03 (p = 0.10). **Lectura:** no hay evidencia de que estudiar

rinda más en los estados ricos que en los pobres. Los estados ricos pagan más *en todos los niveles*, pero el aumento porcentual por año de estudio es similar.

> **Cuidado con la lectura**
>
> Entre los estados, la escolaridad promedio y el ingreso mediano sí están fuertemente asociados (Spearman = 0.74, sección 7.3), pero esta es una relación **entre estados** (cada punto es una entidad) y no dice nada sobre lo que le pasaría a una persona que estudiara más (falacia ecológica). El rendimiento por año no se asocia positivamente con el ingreso del estado (Spearman = -0.25, IC -0.33 a -0.08).

7.3 Correlación escolaridad-ingreso por entidad (métrica M2)

Qué se calculó. El coeficiente de Spearman ponderado entre los años de escolaridad y el ingreso por hora en cada una de las 32 entidades, con su intervalo de confianza por bootstrap y el lugar que ocupa cada entidad en el ranking (con el intervalo de ese lugar, recalculado en cada réplica). A nivel nacional, ρ = 0.34 (IC 0.33 a 0.35): una relación moderada.

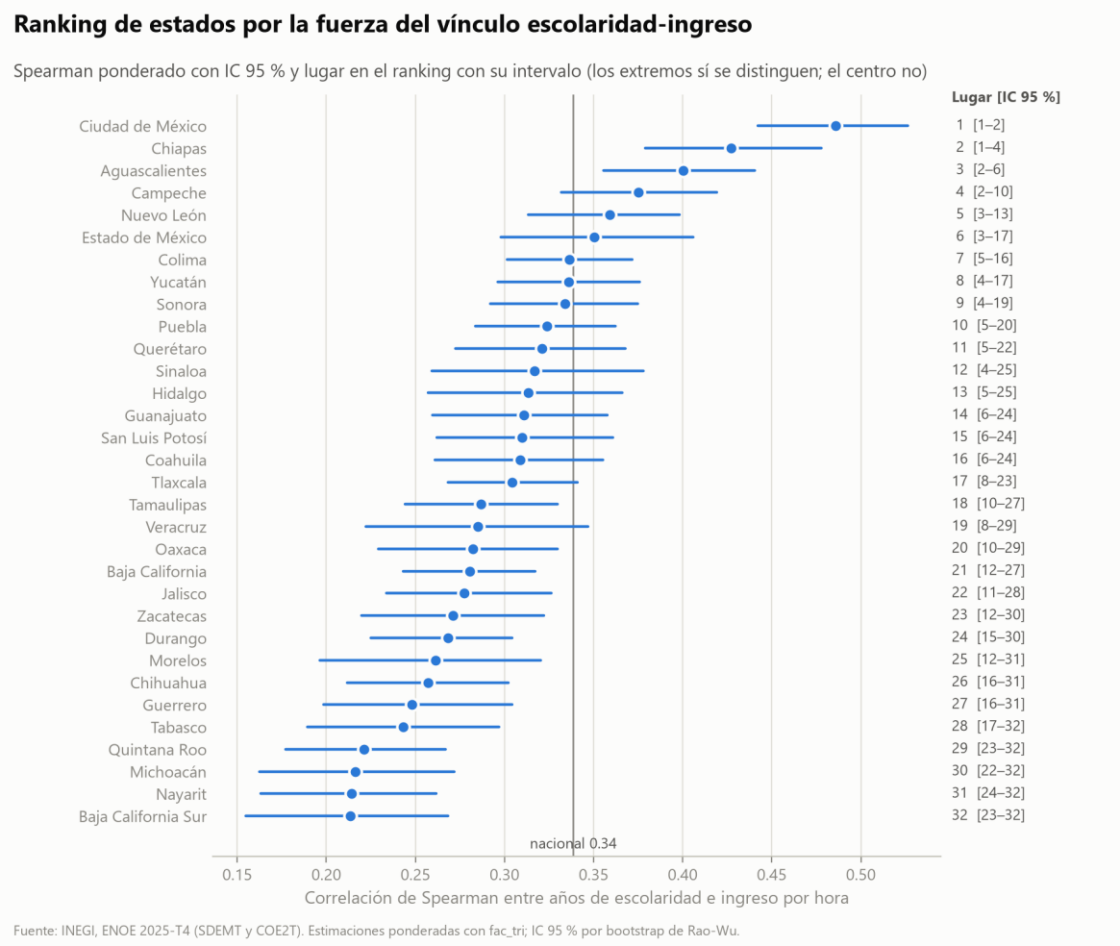


Figura 14. Correlación de Spearman entre escolaridad e ingreso por hora en cada entidad, con IC 95 % y lugar en el ranking.

Tabla 30. Las cinco entidades con mayor y menor correlación (el ranking completo está en el Anexo C).

Lugar	Entidad	ρ de Spearman (IC 95 %)	Intervalo del lugar	Rendimiento % por año
1	Ciudad de México	0.49 (0.44 a 0.53)	1 a 2	9.1
2	Chiapas	0.43 (0.38 a 0.48)	1 a 4	8.2
3	Aguascalientes	0.40 (0.36 a 0.44)	2 a 6	6.8
4	Campeche	0.38 (0.33 a 0.42)	2 a 10	6.5
5	Nuevo León	0.36 (0.31 a 0.40)	3 a 13	7.0
28	Tabasco	0.24 (0.19 a 0.30)	17 a 32	4.1
29	Quintana Roo	0.22 (0.18 a 0.27)	23 a 32	3.8
30	Michoacán	0.22 (0.16 a 0.27)	22 a 32	4.1
31	Nayarit	0.21 (0.16 a 0.26)	24 a 32	3.7
32	Baja California Sur	0.21 (0.15 a 0.27)	23 a 32	3.9

Lectura. La correlación va de 0.21 (Baja California Sur) a 0.49 (Ciudad de México). En todas las entidades es positiva y significativa: dentro de cada entidad, quienes tienen más escolaridad tienden a ganar más por hora. El **ranking es defendible solo en los extremos**: los lugares de las entidades intermedias tienen intervalos muy amplios (varios lugares hacia arriba y hacia abajo), por lo que no conviene interpretar diferencias de uno o dos lugares.

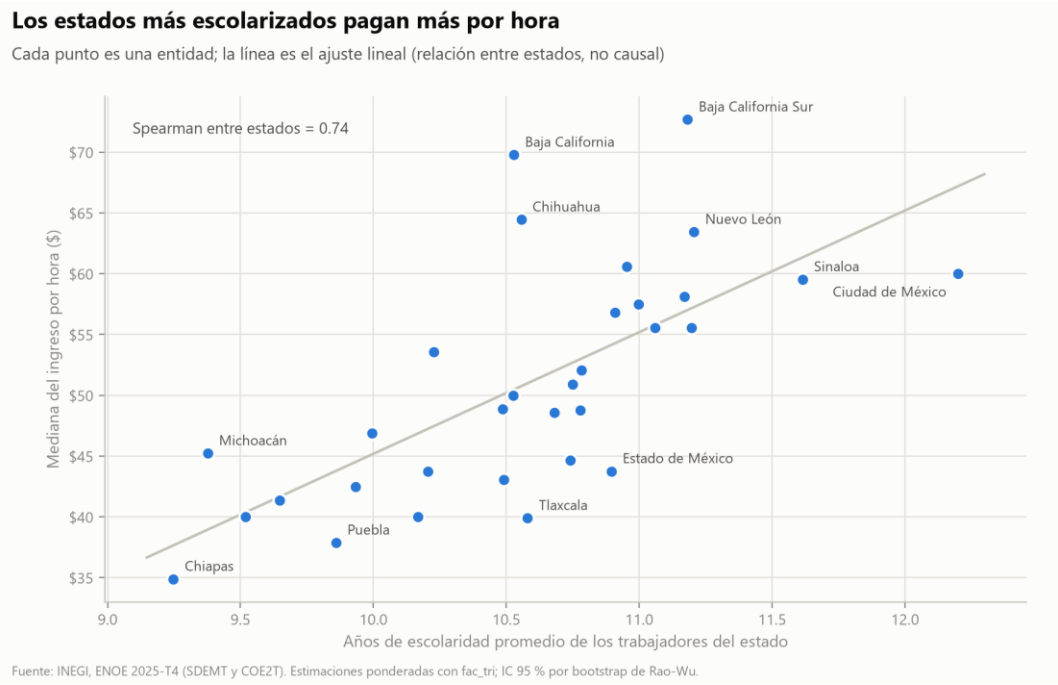


Figura 15. Relación entre la escolaridad promedio y el ingreso mediano por hora entre estados (Spearman entre estados = 0.74; relación entre estados, no causal).

7.4 Brecha salarial de género por nivel de instrucción (métrica M1)

Qué se calculó. Para cada nivel de instrucción, la brecha de género en el ingreso por hora (y, para completar el panorama, en el ingreso mensual y en las horas trabajadas), con su intervalo de confianza y su valor p ajustado por Holm.

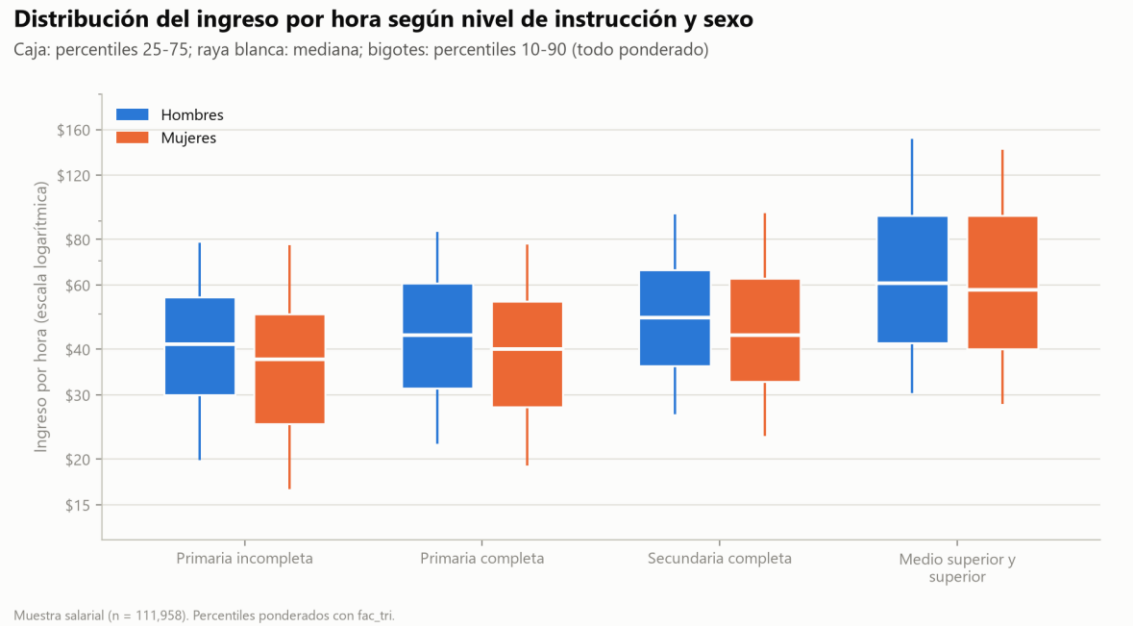


Figura 16. Distribución de ln(ingreso por hora) por nivel de instrucción y sexo.

Tabla 31. Brecha salarial de género por hora, por nivel de instrucción ($/h = media geométrica del ingreso por hora).

Nivel	Hombres	Mujeres	$/h hombres	$/h mujeres	Brecha %	IC 95 %	p (Holm)
Primaria incompleta	4,066	2,273	39.06	35.77	8.4	4.1 a 12.9	< 0.001
Primaria completa	9,177	5,479	43.20	38.82	10.1	7.3 a 12.9	< 0.001
Secundaria completa	22,704	16,170	48.96	45.26	7.6	5.9 a 9.3	< 0.001
Medio superior y superior	28,130	23,959	63.88	61.39	3.9	2.0 a 5.5	< 0.001
Total	**64,077**	**47,881**	**52.53**	**50.60**	**3.7**	**2.3 a 5.0**	**< 0.001**

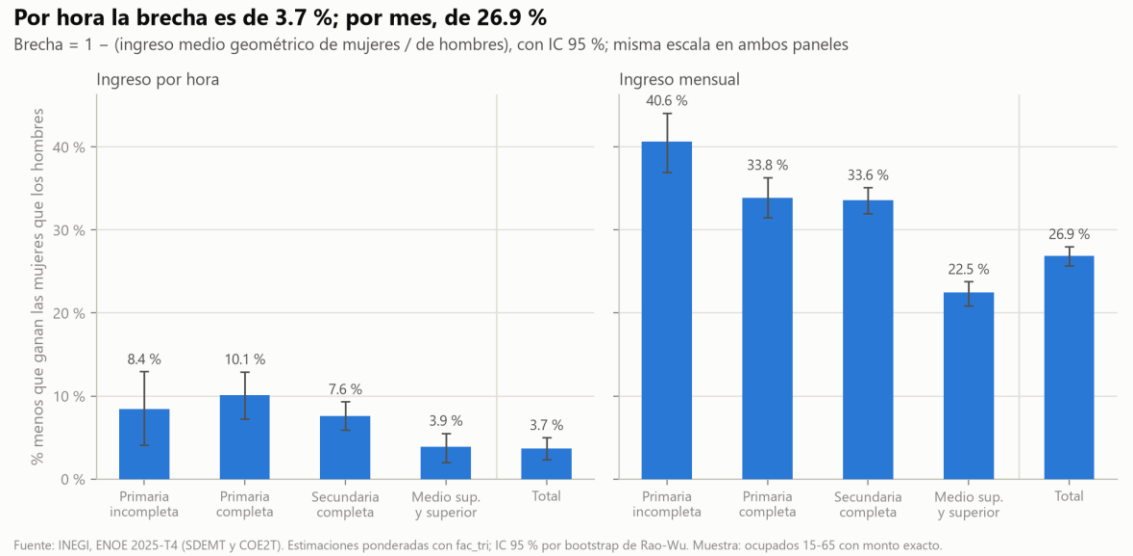


Figura 17. Brecha salarial de género por hora, por nivel de instrucción (IC 95 %).

Lectura. Las mujeres ganan menos por hora que los hombres en **los cuatro niveles**, y las cuatro diferencias son estadísticamente significativas aun después de la corrección de Holm ($p < 0.001$ en todos). La brecha va de 3.9 % (preparatoria y superior) a 10.1 % (primaria completa); es **mayor en los niveles bajos** y menor entre quienes tienen más estudios. En el total es de 3.7 % (IC 2.3 a 5.0).

Las pruebas «clásicas» del protocolo

Tabla 32. Pruebas sin ponderar de diferencia de ln(ingreso por hora) entre hombres y mujeres, como pide el protocolo.

Nivel	t de Welch	p Welch (Holm)	p Mann-Whitney (Holm)	d de Cohen	r biserial
Primaria incompleta	8.9	< 0.001	< 0.001	0.24	0.16
Primaria completa	11.4	< 0.001	< 0.001	0.20	0.13
Secundaria completa	14.6	< 0.001	< 0.001	0.15	0.10
Medio superior y superior	6.5	< 0.001	< 0.001	0.06	0.03
Total	12.3	< 0.001	< 0.001	0.08	0.05

Las pruebas t de Welch (diferencia de medias) y U de Mann-Whitney (diferencia de distribuciones, sin supuesto de normalidad) confirman la significancia en todos los niveles. Pero la **d de Cohen** muestra que el tamaño del efecto es **pequeño** (entre 0.06 y 0.24, por debajo del 0.5 que se considera mediano): hay diferencia, pero hombres y mujeres se traslapan mucho. Estas pruebas no ponderan por el diseño y se incluyen porque el protocolo las pide; los intervalos de la tabla anterior son los válidos para inferir sobre la población.

La brecha mensual es mucho mayor que la brecha por hora

Tabla 33. Brecha por hora, brecha mensual y diferencia de horas trabajadas.

Nivel	Brecha por hora %	Brecha mensual %	Mujeres trabajan menos horas, %	Horas/sem. hombres	Horas/sem. mujeres
Primaria incompleta	8.4	40.6	35.2	43.3	31.8
Primaria completa	10.1	33.8	26.4	45.0	36.5
Secundaria completa	7.6	33.6	28.1	46.5	37.1
Medio superior y superior	3.9	22.5	19.3	45.8	38.7
Total	**3.7**	**26.9**	**24.1**	**45.7**	**37.5**

Lectura. En el ingreso **mensual** la brecha es de 26.9 %, siete veces mayor que la brecha por hora. La razón es que las mujeres trabajan en promedio 37.5 horas a la semana y los hombres 45.7: **24.1 % menos horas pagadas**. Por la identidad en logaritmos, casi toda la diferencia mensual se debe a la diferencia de horas y solo una pequeña parte a la diferencia de pago por hora. Que las mujeres trabajen menos horas remuneradas no es necesariamente una elección libre: refleja, en parte, la distribución del trabajo doméstico y de cuidados, que esta encuesta no mide en el ingreso.

7.5 Brecha entre personas comparables: la escalera de controles

Qué se calculó. La brecha por hora entre mujeres y hombres «de iguales características». Se agregan controles uno por uno (regresión ponderada de ln(ingreso por hora) sobre `mujer`) para ver cómo cambia la brecha:

Tabla 34. Brecha por hora ajustada: G0 es la brecha sin ajustar; G5 es la estimación de referencia; G6 sufre del sesgo de división y no se interpreta.

Modelo (controles acumulados)	Brecha %	IC 95 %	R^2	Parámetros
G0 Sin controles	3.7	2.4 a 4.9	0.001	2
G1 + escolaridad	7.7	6.6 a 8.8	0.130	3
G2 + edad y edad²	8.8	7.6 a 9.9	0.152	5
G3 + entidad y tamaño de localidad	9.9	8.9 a 10.9	0.241	39
G4 + posición e informalidad	8.4	7.3 a 9.4	0.257	42
G5 + rama de actividad	**8.2**	**7.1 a 9.2**	**0.300**	**52**
G6 + horas trabajadas	16.3	15.4 a 17.2	0.413	53

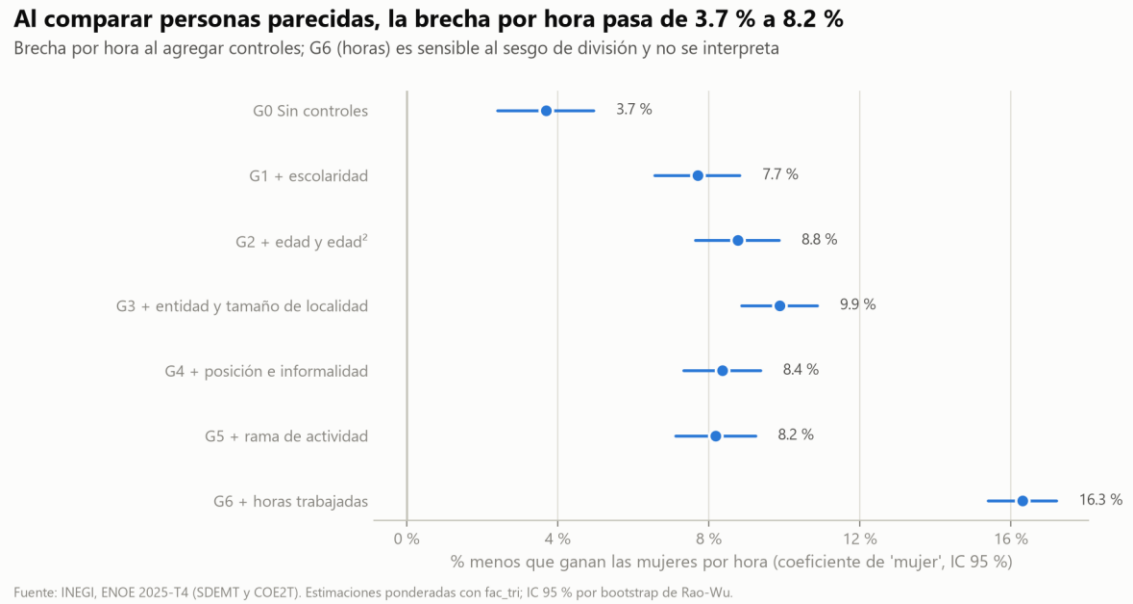


Figura 18. Escalera de controles: cómo cambia la brecha por hora al agregar controles (G6 no se interpreta).

- **G0 → G1:** al comparar personas con la misma escolaridad, la brecha **sube** de 3.7 % a 7.7 %. Eso ocurre porque las mujeres de la muestra tienen *más* escolaridad que los hombres: la escolaridad «compensa» parcialmente la desventaja y, al igualarla, la brecha aparece completa.
- **G2 → G3:** al comparar dentro de la misma entidad y tamaño de localidad llega a su máximo (9.9 %).
- **G3 → G5:** al agregar la posición en la ocupación y la informalidad (G4: 8.4 %) y luego la rama de actividad (G5: 8.2 %) la brecha baja un poco: una parte menor se asocia con que mujeres y hombres se concentran en puestos y ramas distintos.
- **G5 es la estimación de referencia: 8.2 % (IC 7.1 a 9.2).** Entre personas comparables en escolaridad, edad, lugar, tipo de empleo y rama, las mujeres ganan alrededor de 8 % menos por hora.
- **G6** agrega las horas y salta a 16.3 %, pero ese valor es un artefacto del sesgo de división (sección 6.5) y no se interpreta.

Descomposición de Oaxaca-Blinder: ¿qué la explica?

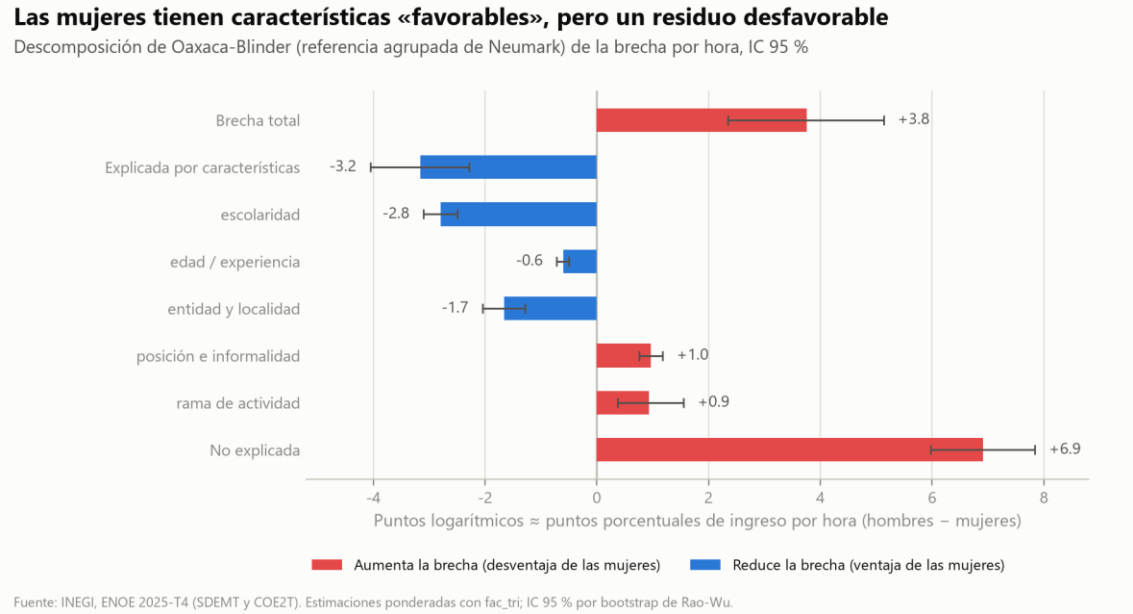


Figura 19. Descomposición de la brecha total (en puntos logarítmicos) en parte explicada y no explicada, y contribución de cada grupo de características.

Tabla 35. Descomposición de Oaxaca-Blinder (referencia agrupada de Neumark); 1 centésima de log-punto ≈ 1 %.

Componente	Centésimas de log-punto	IC 95 %
Brecha total	**3.75**	**2.35 a 5.13**
Explicada por diferencias en características	**-3.15**	**-4.05 a -2.29**
· escolaridad	-2.79	-3.10 a -2.50
· edad / experiencia	-0.60	-0.72 a -0.50
· entidad y tamaño de localidad	-1.66	-2.05 a -1.28
· posición e informalidad	0.96	0.75 a 1.18
· rama de actividad	0.94	0.37 a 1.55
No explicada (mismas características, distinto pago)	**6.91**	**5.97 a 7.84**

Lectura. Con los mismos niveles de escolaridad, edad y ubicación que los hombres, las mujeres *deberían* ganar más (la parte explicada es negativa: −3.2): su **ventaja en escolaridad** (−2.8) y en ubicación (−1.7) pesa más que la ventaja de los hombres en tipo de empleo y rama de actividad (+1.0 y +0.9). Lo que ocurre, en cambio, es que **a iguales características las mujeres reciben 6.9 puntos logarítmicos (6.7 %) menos**: esa es la parte *no explicada*, que es mayor que la brecha total precisamente porque las características de las mujeres las favorecen. Importante: la parte no explicada **no prueba discriminación**; incluye todo lo que el estudio no mide (la ocupación específica, la experiencia real, la negociación, las interrupciones de carrera, la selección hacia el empleo).

7.6 La brecha a lo largo de la distribución

Qué se calculó. La brecha en distintos puntos de la distribución del ingreso por hora (percentiles 10, 25, 50, 75 y 90). El promedio puede ocultar que la desigualdad sea distinta entre quienes ganan poco y quienes ganan mucho.

Tabla 36. Brecha por hora en cinco puntos de la distribución.

Percentil	$/h hombres	$/h mujeres	Brecha %	IC 95 %	Valor p
P10	26.67	24.49	8.2	3.3 a 10.7	< 0.001
P25	37.21	33.33	10.4	6.6 a 11.1	< 0.001
P50	50.00	48.94	2.1	0.0 a 4.5	0.106
P75	73.33	75.00	-2.3	-2.9 a 0.3	0.039
P90	116.28	116.67	-0.3	-5.3 a 0.0	0.836

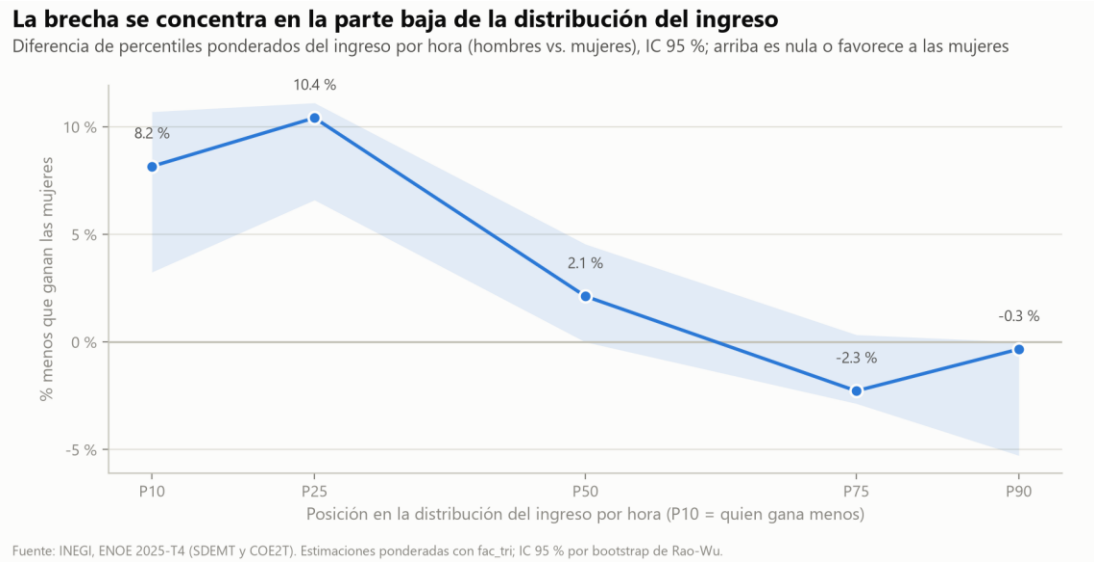


Figura 20. Brecha por hora en distintos percentiles del ingreso por hora (IC 95 %).

Lectura. La brecha se concentra en la parte baja de la distribución: **8.2 % en el decil inferior (P10) y 10.4 % en el cuartil inferior (P25)**, ambas significativas. En la mediana (2.1 %) ya no es significativa, en el cuartil superior se invierte levemente (−2.3 %, p = 0.04) y en el decil superior es nula. Es decir, el pago por hora es más desigual entre quienes ganan poco: el «piso» de las mujeres está por debajo del de los hombres. Como los ingresos por hora son muy «redondos» (muchas personas declaran $50 o $100 por hora), los percentiles saltan de un valor a otro y sus intervalos son irregulares; conviene leerlos como una tendencia y no como cifras exactas.

7.7 Robustez: ¿cambian las conclusiones si cambian las decisiones?

Qué se calculó. La brecha total y el rendimiento de la escolaridad bajo diez especificaciones alternativas (S0 a S9) y siete (R0 a R6): sin recortar atípicos, solo asalariados, imputando los rangos de ingreso, corrigiendo por no respuesta (IPW), usando medianas, usando el ingreso mensual, sin ponderar y con controles.

Tabla 37. Robustez de la brecha total ante las decisiones metodológicas.

Especificación	Qué cambia	Brecha %	IC 95 %	p	n
S0 Base	**Grupo A, 15-65 años, sin atípicos, ponderado**	**3.7**	**2.3 a 5.0**	**< 0.001**	**111,958**
S1 Sin recorte	No se eliminan los atípicos de ingreso por hora	3.6	2.2 a 5.0	< 0.001	113,088
S2 Solo asalariados	Trabajadores subordinados y remunerados	1.6	0.3 a 2.8	0.009	86,552
S3 Con rangos imputados	Grupo A + grupo B (ingreso imputado por rango de SM)	0.7	-0.4 a 1.8	0.220	145,529
S4 Ajuste por no respuesta	Ponderadores multiplicados por 1/P(declara monto exacto)	4.5	3.0 a 5.9	< 0.001	111,958
S5 Medianas	Diferencia de medianas ponderadas (robusta a asimetría)	2.1	0.0 a 4.5	0.106	111,958
S6 Ingreso mensual	Ingreso mensual en lugar de por hora (incluye diferencia de jornada)	26.9	25.7 a 28.0	< 0.001	111,958
S7 Sin ponderar	Medias de la muestra sin ponderadores ni diseño (IC clásico de Welch)	4.6	3.9 a 5.3	< 0.001	111,958
S8 Ajustada (sin horas)	Regresión WLS con controles (G5), IC robusto por UPM	8.2	7.1 a 9.2	< 0.001	111,958
S9 Ajustada (con horas; sesgo de división)	Regresión WLS con controles (G6), IC robusto por UPM	16.3	15.4 a 17.2	< 0.001	111,958

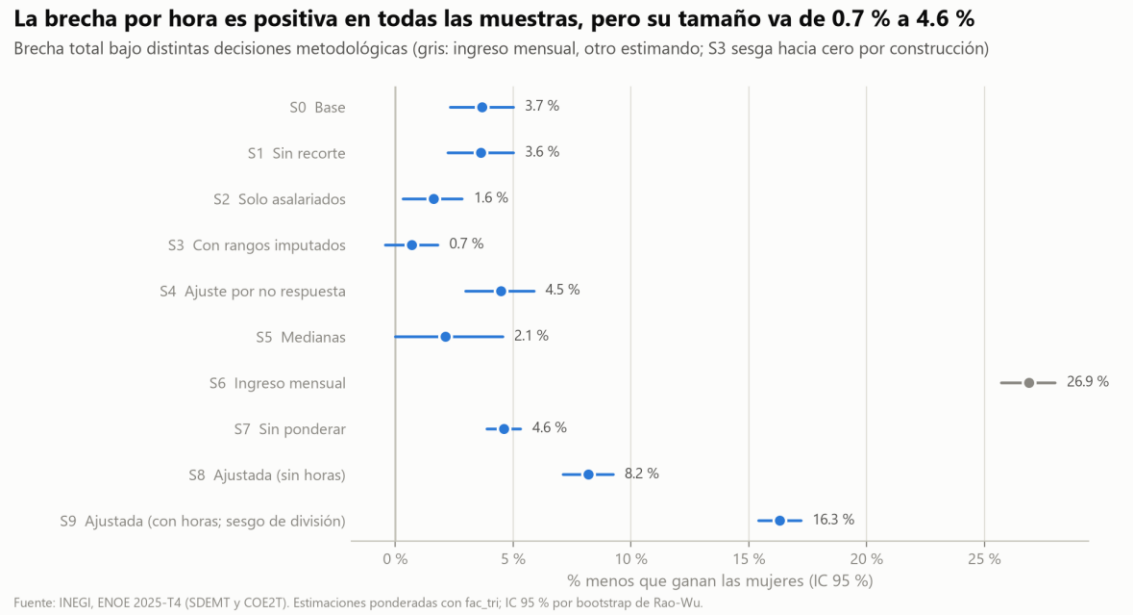


Figura 21. Robustez de la brecha por hora ante distintas decisiones metodológicas (S3 sesga hacia cero por construcción; S6 es otro estimando).

- **La brecha por hora es positiva en las diez especificaciones**, pero su tamaño depende de ellas: de 0.7 % a 4.6 % sin controles, y 8.2 % con controles de personas comparables.
- **En 5 de las 7 especificaciones sin controles la brecha es significativa;** las excepciones son S3 y S5 (la imputación S3, que se sabe sesgada hacia cero, y la diferencia de medianas S5, cuyo intervalo llega al cero). Con controles (S8 y S9) es significativa en todos los casos. La existencia de una brecha por hora no depende de una decisión particular.

- **S2 (solo asalariados) muestra una brecha menor** (1.6 %): en el empleo subordinado y remunerado la diferencia es menor; se amplía en el empleo informal (sección 7.8).
- **S4 (corrección por no respuesta) sube la brecha a 4.5 %:** al dar más peso a quienes se parecen a los que no declararon su ingreso, la brecha crece, lo que sugiere que la muestra de quienes declaran subestima ligeramente la desigualdad.
- **S6 (mensual) es otro estimando**: incluye la diferencia de horas (sección 7.4).

Tabla 38. Robustez del rendimiento de la escolaridad.

Especificación	Qué cambia	Rendimiento %	IC 95 %	n
R0 Base	**Grupo A, 15-65 años, sin atípicos, ponderado**	**5.14**	**4.96 a 5.32**	**111,958**
R1 Sin recorte	No se eliminan los atípicos	5.43	5.24 a 5.63	113,088
R2 Solo asalariados	Trabajadores subordinados y remunerados	5.36	5.18 a 5.54	86,552
R3 Con rangos imputados	Grupo A + grupo B (ingreso imputado por rango)	4.91	4.76 a 5.06	145,529
R4 Ajuste por no respuesta	Ponderadores x 1/P(declara monto exacto)	5.68	5.48 a 5.88	111,958
R5 Sin ponderar	Sin ponderadores (errores por UPM)	5.06	4.95 a 5.18	111,958
R6 Ingreso mensual	Ingreso mensual en vez de por hora	5.38	5.18 a 5.58	111,958

Lectura. El rendimiento por año de escolaridad es muy estable: entre 4.9 % y 5.7 % en las siete especificaciones. Esta conclusión **no depende** de cómo se traten los atípicos, los rangos de ingreso o la no respuesta.

7.8 Heterogeneidad: ¿en qué grupos es mayor la brecha?

Qué se calculó. La brecha por hora dentro de subgrupos definidos por cinco dimensiones: informalidad, posición en la ocupación, región, tamaño de localidad y edad (más el nivel de instrucción detallado). La figura marca con un punto relleno las categorías significativas tras la corrección de Holm dentro de cada dimensión.

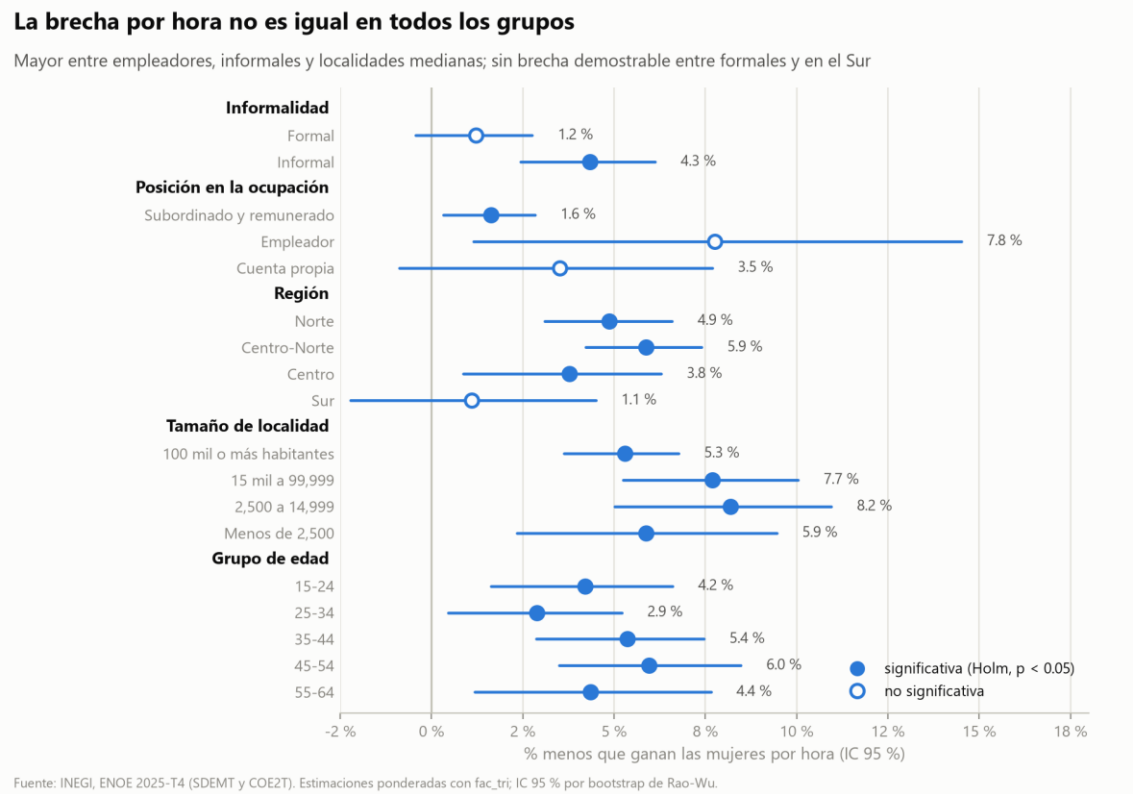


Figura 22. Brecha por hora por subgrupo (IC 95 %). Punto relleno: significativa con Holm ($p < 0.05$); hueco: no significativa.

- **Informalidad:** la brecha es de 4.3 % entre trabajadores informales (significativa) y de 1.2 % entre formales (no significativa). La desigualdad se concentra en el empleo informal.
- **Región:** de 1.1 % en el Sur (no significativa) a 5.9 % en el Centro-Norte; en el Norte es de 4.9 %.
- **Edad:** es significativa entre los 15 y los 64 años (2.9 % a 6.0 %), con un máximo de 6.0 % a los 45-54 años; a partir de los 65 las muestras son pequeñas y el intervalo, muy amplio.
- **Posición:** 1.6 % entre subordinados (significativa), 7.8 % entre empleadores y 3.5 % entre trabajadores por cuenta propia; estas dos últimas tienen intervalos amplios y no son significativas con Holm.
- **Tamaño de localidad:** significativa en todos los tamaños, de 5.3 % a 8.2 %.
- **Nivel de instrucción detallado:** entre 5.9 % y 10.1 %; incluso entre quienes tienen licenciatura o posgrado la brecha es de 5.9 %.

Lectura. La brecha no es uniforme: es más visible en el empleo informal, en el centro-norte del país y en la mitad de la vida laboral. Sin embargo, con intervalos tan amplios en algunos subgrupos, conviene evitar conclusiones fuertes sobre diferencias pequeñas entre ellos.

7.9 La brecha de género por entidad federativa

Con 1,900 a 5,900 observaciones por entidad la brecha por hora se estima con poca precisión: es positiva en 28 de las 32 entidades y significativa ($p < 0.05$, sin ajuste por multiplicidad) en 21. Va de -13.3 % (Chiapas) a 16.5 % (Oaxaca). Estas cifras se incluyen en el Anexo C y en las fichas del tablero como **descriptivas**, con sus intervalos; no se comparan entidades entre sí. En cambio, la brecha *mensual* es significativa en 31 de las 32 entidades (de 3.4 % a 40.7 %).

7.10 Informalidad laboral y escolaridad (objetivo 3)

Qué se calculó. La tasa de informalidad laboral (TIL1) ponderada para todo el país, por sexo, región, nivel de instrucción y entidad, con intervalos por bootstrap, y su asociación con la escolaridad promedio de cada entidad.

Tabla 39. Tasa de informalidad laboral (TIL1) por grupo.

Grupo	TIL1 %	IC 95 %
Nacional	**55.0**	**54.5 a 55.5**
Hombres	54.4	53.9 a 55.0
Mujeres	55.8	55.2 a 56.5
Región Norte	38.4	37.7 a 39.2
Región Centro-Norte	52.7	52.0 a 53.6
Región Centro	57.5	56.4 a 58.6
Región Sur	69.2	68.5 a 70.1
Nivel 1. Primaria incompleta	86.9	86.0 a 87.8
Nivel 2. Primaria completa	78.7	77.8 a 79.5
Nivel 3. Secundaria completa	62.5	61.9 a 63.3
Nivel 4. Medio superior y superior	37.6	37.0 a 38.2

Lectura. El **55.0 %** de las personas ocupadas está en un empleo informal. Es algo mayor entre las mujeres (55.8 %) que entre los hombres (54.4 %), pero la diferencia por regiones es enorme: de 38 % en el Norte a 69 % en el Sur. Y la escolaridad es decisiva: la informalidad baja de 87 % entre quienes no terminaron la primaria a 38 % entre quienes tienen preparatoria o más.

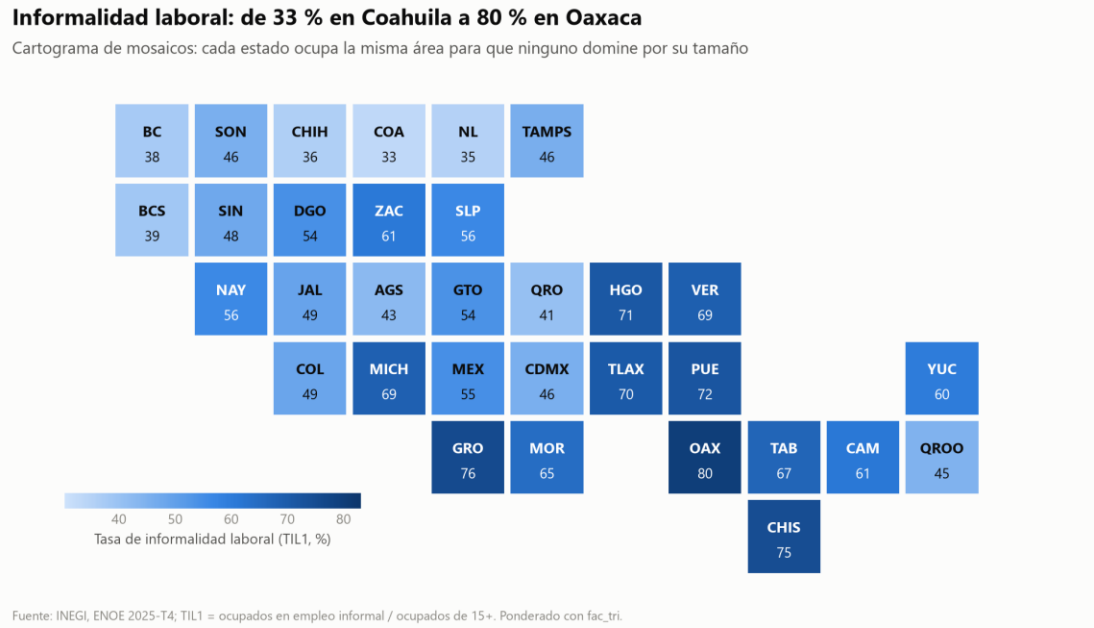


Figura 23. Informalidad laboral por entidad (TIL1, %) en un cartograma de mosaicos: cada estado ocupa la misma área.

Tabla 40. Las cinco entidades con mayor y menor informalidad (ranking completo en el Anexo C).

Lugar	Entidad	Región	TIL1 %	IC 95 %	Intervalo del lugar	Esc. media
1	Oaxaca	Sur	80.1	78.1 a 81.9	1 a 1	9.1
2	Guerrero	Sur	75.7	73.8 a 77.6	2 a 3	9.4
3	Chiapas	Sur	74.9	73.2 a 76.8	2 a 4	9.0
4	Puebla	Centro	72.1	70.0 a 74.1	4 a 6	10.0
5	Hidalgo	Centro	71.3	67.8 a 74.9	3 a 8	9.9
28	Baja California Sur	Centro-Norte	38.6	36.5 a 40.6	27 a 30	11.3
29	Baja California	Norte	37.6	35.9 a 39.3	28 a 30	11.1
30	Chihuahua	Norte	36.2	34.3 a 37.8	29 a 31	11.0
31	Nuevo León	Norte	35.4	33.7 a 37.1	29 a 32	11.6
32	Coahuila	Norte	33.3	31.5 a 35.3	31 a 32	11.4

Las entidades con más informalidad son Oaxaca, Guerrero y Chiapas (más de 74 %), y las de menos, Coahuila, Nuevo León y Chihuahua (alrededor de 33 a 36 %). El ranking es confiable en los extremos: Oaxaca ocupa siempre el primer lugar en las réplicas (intervalo de 1 a 1).

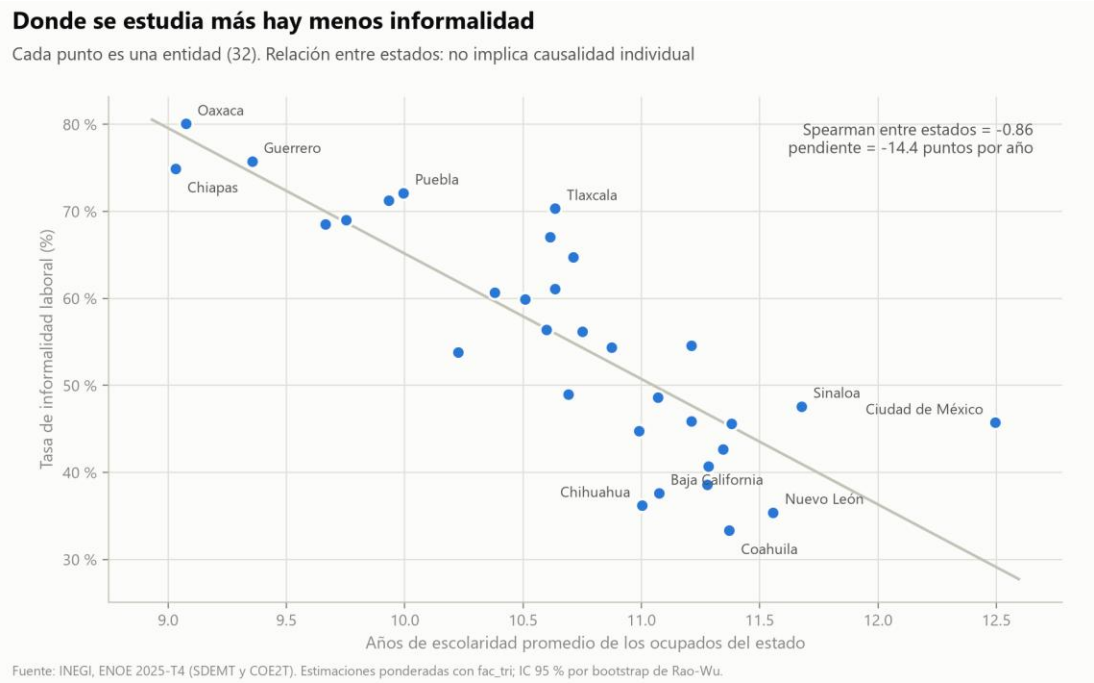


Figura 24. Informalidad laboral y escolaridad promedio de los ocupados de cada entidad.

Asociación entre estados. La correlación de Pearson entre la informalidad y la escolaridad promedio de las entidades es -0.83 (IC -0.85 a -0.80) y la de Spearman -0.86: una relación negativa muy fuerte. La pendiente es de -14.4 puntos porcentuales por cada año adicional de escolaridad promedio (IC -15.0 a -13.5). Es una relación entre estados y no causal.

Asociación individual (regresión logística con diseño). Controlando por edad y sexo, cada año de escolaridad reduce los momios de tener un empleo informal en 18 % (razón de momios 0.82; IC 0.81 a 0.82), lo que

equivale a un **efecto marginal promedio de -3.9 puntos porcentuales por año** (con un modelo lineal de probabilidad se obtiene -3.9). Las mujeres tienen 37 % más momios de ser informales (6.1 puntos porcentuales) a igualdad de edad y escolaridad. El pseudo-R^2 de McFadden es 0.18.

7.11 Diagnósticos del modelo

Los modelos de regresión se revisaron con los diagnósticos habituales. El análisis se hace sobre el modelo con todos los controles (G6) para no ocultar problemas:

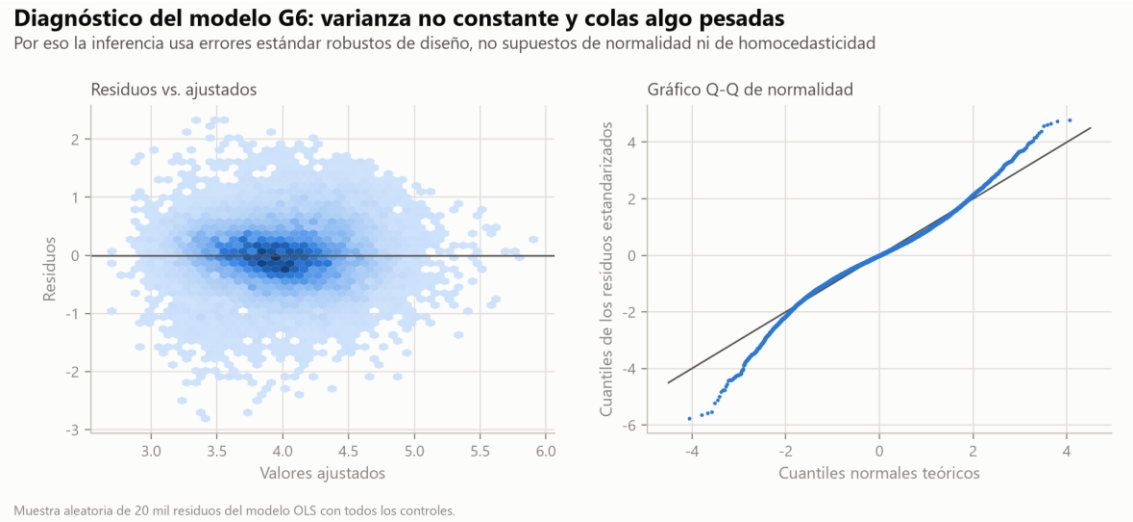


Figura 25. Diagnósticos del modelo con todos los controles: residuos contra valores ajustados (izquierda) y gráfico Q-Q de normalidad (derecha).

Tabla 41. Diagnósticos del modelo con todos los controles.

Diagnóstico	Resultado	Interpretación
R^2 del modelo OLS	0.397	Con los 53 parámetros explica 40 % de la variación de ln(ingreso por hora).
Prueba de Breusch-Pagan	LM = 9,286, p < 0.001	Hay **varianza no constante** (heterocedasticidad): por eso los errores estándar son robustos de diseño y no los clásicos.
VIF máximo (variables clave)	1.66	Muy por debajo de 5: no hay multicolinealidad problemática.
Distancia de Cook máxima	0.0005	Ninguna observación individual tiene influencia relevante.
Observaciones con Cook > 4/n	6.0 %	Al eliminarlas, el coeficiente de «mujer» cambia de -0.1780 a -0.1774: el resultado no depende de ellas.
Forma de los residuos	asimetría -0.12; curtosis en exceso 1.89	Los residuos son casi simétricos con colas algo pesadas, sobre todo en el extremo inferior (panel derecho de la figura).
Normalidad de ln(ingreso por hora)	Se rechaza (p < 0.001)	Con 112 mil observaciones cualquier desviación pequeña se rechaza. La inferencia no la necesita: se basa en el bootstrap y en errores robustos.

8. Discusión

8.1 Hallazgos principales

1. **Estudiar paga, y paga más en lo alto de la escalera.** Cada año de escolaridad se asocia con 5.1 % más ingreso por hora (IC 95 %: 5.0 a 5.3) entre personas de igual edad, sexo, entidad y tamaño de localidad. El beneficio no es lineal: terminar una licenciatura o un posgrado se asocia con 92 % más ingreso por hora que no terminar la primaria, mientras que terminar la primaria agrega solo 7 %.
2. **El rendimiento de estudiar es parecido en estados ricos y pobres.** La diferencia entre los estados del cuartil de mayor ingreso y los del menor es prácticamente cero ($p = 0.91$). Los estados más escolarizados pagan más (Spearman entre estados = 0.74), pero el aumento porcentual por año de estudio es similar.
3. **El ranking de entidades solo es defendible en los extremos.** La correlación escolaridad-ingreso va de 0.21 (Baja California Sur) a 0.49 (Ciudad de México), pero el lugar de las entidades intermedias tiene intervalos de decenas de lugares.
4. **La brecha salarial de género depende de qué se mida.** Por hora es de 3.7 % (2.3 a 5.0) y significativa en los cuatro niveles de instrucción tras la corrección de Holm; por mes, de 26.9 %. La diferencia mensual se debe sobre todo a que las mujeres trabajan 24.1 % menos horas pagadas. Entre personas comparables la brecha por hora es de 8.2 %.
5. **La brecha por hora se concentra abajo y en el empleo informal.** Es de 8.2 % en el decil inferior y de 10.4 % en el cuartil inferior, desaparece en la mediana y se invierte levemente en el cuartil superior; y es significativa entre los trabajadores informales (4.3 %) pero no entre los formales (1.2 %).
6. **Las mujeres tienen mejores características, pero reciben menos pago a igualdad de ellas.** En la descomposición de Oaxaca-Blinder, las diferencias en escolaridad y ubicación favorecen a las mujeres; la parte no explicada (6.9 puntos logarítmicos) es mayor que la brecha total (3.8) y no debe leerse como discriminación probada.
7. **La informalidad es alta, desigual y baja con la escolaridad.** El 55.0 % de los ocupados es informal; de 33 % (Coahuila) a 80 % (Oaxaca); de 87 % entre quienes no terminaron la primaria a 38 % con preparatoria o más. Entre estados, la asociación es de -0.86 (Spearman).
8. **El ingreso «cero» es un problema de medición y no de pobreza extrema:** 39 % de los ocupados tiene `ingocup = 0`, pero solo 4 % no recibe ingresos. Quien más estudió declara con menos frecuencia el monto exacto, por lo que la muestra salarial subrepresenta a los más escolarizados.

8.2 Evaluación de las métricas de éxito

Tabla 42. Cumplimiento de las métricas de éxito del protocolo.

Métrica	Exigencia del protocolo	Evidencia	Estado
M1	Brecha salarial de género (%) por nivel de instrucción, con IC 95 % y prueba de hipótesis	Tabla de la sección 7.4: brecha por hora y mensual en los cuatro niveles, con IC por bootstrap de Rao-Wu y valores p ajustados con Holm; también pruebas de Welch y Mann-Whitney y *d* de Cohen.	Cumplida
M2	Correlación escolaridad-ingreso (Spearman) en las 32 entidades, con IC por bootstrap y un ranking defendible	Spearman ponderado para las 32 entidades con IC y con el intervalo del lugar de cada entidad (sección 7.3 y Anexo C). Se declara explícitamente que el ranking solo distingue los extremos.	Cumplida
M3	Tablero con al menos cuatro visualizaciones interpretables, alimentado por un pipeline que carga a MongoDB consultable por entidad	Tablero interactivo de un solo archivo con seis visualizaciones y la ficha de cada entidad (`tablero/tablero_enoe.html`); pipeline que construye y exporta los documentos y verifica que la agregación documental reproduce la vista SQL.	Cumplida, con una salvedad: la carga a un servidor MongoDB real no se ejecutó (se probó con un simulador, mongomock)

8.3 Interpretación integrada

Los resultados forman una historia coherente. **La educación paga**, y paga sobre todo cuando se llega a niveles altos, pero la ganancia porcentual por año de estudio es parecida en todo el país: lo que cambia entre estados es el *nivel* de ingreso, no el *rendimiento* de estudiar. **El mayor beneficio de estudiar parece pasar por el tipo de empleo**: al controlar por posición, informalidad y rama el rendimiento baja de 5.1 % a 3.8 %, y la informalidad cae de 87 % a 38 % conforme aumenta la escolaridad. Estudiar abre la puerta al empleo formal.

La desigualdad de género en el ingreso tiene dos componentes de naturaleza distinta. Uno es de *tiempo*: las mujeres trabajan una cuarta parte menos horas remuneradas, lo que explica casi toda la brecha mensual. El otro es de *pago por hora*: entre personas comparables, las mujeres ganan alrededor de 8 % menos, con una desventaja concentrada en la parte baja de la distribución y en el empleo informal, es decir, donde hay menos protección salarial. Que la brecha por hora aumente al comparar personas con la misma escolaridad (de 3.7 % a 7.7 %) muestra que las mujeres obtienen menos ingreso a pesar de tener más estudios.

8.4 Implicaciones y recomendaciones

Los resultados son asociaciones, no efectos causales; las siguientes implicaciones se formulan con esa cautela y como líneas de reflexión, no como evaluación de políticas.

- **Educación.** Como el mayor beneficio se concentra en completar la educación media superior y superior, las políticas que reduzcan el abandono entre la secundaria y la licenciatura (becas, cobertura, transporte) apuntan al tramo con mayor rendimiento asociado. La similitud del rendimiento entre estados sugiere que el beneficio de estudiar no es exclusivo de los estados ricos.
- **Informalidad.** La asociación entre escolaridad e informalidad (de 87 % a 38 %) y su variación regional (de 33 % a 80 %) indican que cualquier estrategia para formalizar el empleo debe considerar tanto la oferta de personas con estudios como la generación de empleos formales en el Sur y Centro del país.
- **Igualdad de género.** La brecha mensual depende sobre todo de las horas; reducirla pasa por medidas que amplíen las oportunidades de trabajo remunerado de jornada completa (servicios de cuidado,

flexibilidad laboral). La concentración de la brecha por hora en la parte baja de la distribución y en el empleo informal sugiere prestar atención a los pisos salariales y a la formalización.

- **Medición.** El 39 % de los ocupados no da un monto exacto de ingreso y la no respuesta no es aleatoria. Mejorar su captación, o publicar ajustes por no respuesta, aumentaría la precisión de los estudios sobre ingreso.

8.5 Limitaciones

Tabla 43. Limitaciones del estudio.

Limitación	Qué implica
Correlación, no causalidad	No se puede afirmar que estudiar un año más *cause* un aumento de 5 %: personas con más estudios pueden diferir en habilidad, redes o contexto familiar (sesgo de habilidad).
Selección en el empleo	Solo se observa el ingreso de quienes trabajan. Si las mujeres que trabajan son un grupo seleccionado (por ejemplo, con más escolaridad), la brecha estimada se distorsiona. No se modeló la participación laboral (corrección de Heckman, 1979).
Selección en la declaración del ingreso	Solo se usa a quienes dan monto exacto (61 %). La no respuesta no es aleatoria; se evaluó con imputación, IPW y asalariados, pero no se puede descartar un sesgo residual.
Medición del ingreso	El ingreso es autorreportado, redondeado y se refiere al mes anterior; el ingreso por hora usa las horas de una sola semana, lo que introduce error de medición (sesgo de división).
Un solo trimestre	Los resultados describen el 4.º trimestre de 2025; no se puede hablar de tendencias ni de estacionalidad.
Falacia ecológica	Las relaciones entre estados (por ejemplo, escolaridad promedio e ingreso mediano) no se pueden leer a nivel individual.
Precisión por entidad	Con 1,900 a 5,900 observaciones salariales por estado, los intervalos son amplios; las diferencias entre entidades cercanas no son distinguibles. Las 32 brechas estatales no se corrigen por multiplicidad y son solo descriptivas.
Ocupación específica no observada	No se controla por la ocupación detallada, la experiencia real, la antigüedad ni las interrupciones de carrera, por lo que la parte «no explicada» de Oaxaca-Blinder no equivale a discriminación.
Elementos por verificar	Los códigos de `p6c` se infirieron de su correspondencia exacta con `ing7c`; las cifras del INEGI usadas para validar se consultaron mediante búsqueda web de los boletines; no se cargó a un servidor MongoDB real.

8.6 Trabajo futuro

- Usar **varios trimestres** (el panel rotativo de la ENOE permite seguir hasta cinco veces a una misma persona) para estudiar tendencias y controlar características fijas no observadas.
- Modelar la **participación laboral** (corrección de Heckman) para tratar la selección hacia el empleo, y las **horas de trabajo no remunerado** (Encuesta Nacional sobre Uso del Tiempo) para dimensionar la parte de la brecha asociada con los cuidados.
- Agregar la **ocupación detallada** (SINCO) y regresiones cuantílicas para describir mejor la brecha a lo largo de la distribución.
- Un mapa geográfico real con el Marco Geoestadístico del INEGI, **estimación en áreas pequeñas** para mejorar la precisión por entidad y la carga de los documentos en un servidor **MongoDB real** con una API de consulta.

9. Conclusiones

El proyecto cumple el ciclo KDD completo sobre datos reales y responde la pregunta planteada:

1. **Rendimiento de la escolaridad:** +5.1 % de ingreso por hora por año de estudio (IC 95 %: 5.0 a 5.3), con un premio de 92 % para quienes tienen licenciatura o posgrado; resultado estable ante siete especificaciones alternativas (de 4.9 % a 5.7 %).
2. **Entre entidades:** el rendimiento no es distinto entre los estados de mayor y menor ingreso; la correlación escolaridad-ingreso varía entre 0.21 y 0.49 y el ranking solo es defendible en los extremos.
3. **Brecha salarial de género:** 3.7 % por hora y 26.9 % por mes. Es estadísticamente significativa en los cuatro niveles de instrucción, aunque pequeña en tamaño del efecto; la diferencia mensual es sobre todo de horas trabajadas (24.1 % menos); entre personas comparables es de 8.2 %.
4. **Informalidad:** 55.0 % de los ocupados, de 33 % a 80 % según la entidad, y estrechamente asociada con la escolaridad (87 % → 38 %).
5. **Calidad de los datos:** el «ingreso cero» de la ENOE esconde información incompleta (22 % solo da un rango de salarios mínimos y 13 % no especifica); la no respuesta es selectiva, y por eso las conclusiones se contrastaron con imputación, ponderación inversa y solo asalariados.
6. **Ingeniería de datos:** el proceso es reproducible de principio a fin (una semilla, una orden, 41 pruebas, 30 archivos de resultados idénticos en dos corridas), y la arquitectura relacional (SQLite) y documental (MongoDB) responde a patrones de acceso distintos.
7. **Alcance:** los resultados son asociaciones de un trimestre; su lectura causal requeriría otros diseños de investigación.

> **Mensaje final**
>
> Estudiar se asocia con un mayor ingreso y con menos informalidad en todo el país; la desigualdad de género en el ingreso mensual es, sobre todo, una desigualdad de horas, y la de pago por hora se concentra en quienes menos ganan.

Anexo A. Glosario

Tabla 44. Glosario de términos.

Término	Significado
ACID	Propiedades de una base de datos transaccional: atomicidad, consistencia, aislamiento y durabilidad. SQLite las cumple.
Asimetría	Medida de qué tan desbalanceada está una distribución. Vale 0 si es simétrica; el ingreso por hora tiene 3.1 y su logaritmo, 0.06.
Bootstrap	Técnica que estima la incertidumbre volviendo a muestrear los propios datos muchas veces.
Brecha salarial de género	Porcentaje menos que ganan las mujeres que los hombres; aquí se calcula comparando medias geométricas de ingresos.
COE2T	Tabla de la ENOE con el cuestionario de ocupación y empleo (parte 2); contiene el detalle de la captación del ingreso.
Cohen, d de	Tamaño del efecto: diferencia de medias dividida entre la desviación estándar (0.2 pequeño, 0.5 mediano, 0.8 grande).
Conglomerado	Grupo de unidades parecidas entre sí (aquí, las viviendas de una UPM) que se muestrea como bloque.
Curtosis	Peso de las colas de una distribución respecto a la normal; valor en exceso 0 = como la normal.
Dominio	Subpoblación para la que se estima (un estado, un nivel de instrucción...). Se estima conservando todo el diseño muestral.
Efecto de diseño (deff)	Razón entre la varianza real de un estimador con el diseño de la encuesta y la que tendría una muestra aleatoria simple del mismo tamaño.
ENOE	Encuesta Nacional de Ocupación y Empleo del INEGI: principal fuente de información del mercado laboral mexicano.
Estrato	Grupo de áreas parecidas a partir del cual se sortean las UPM.
ETL	Extract-Transform-Load: proceso de extraer, transformar y cargar datos.
Factor de expansión (fac_tri)	Número de personas de la población que representa cada persona de la muestra.
Falacia ecológica	Error de atribuir a las personas una relación observada entre promedios de grupos (por ejemplo, entre estados).
Heterocedasticidad	Varianza de los errores de un modelo que no es constante.
Holm	Corrección de valores p que controla la probabilidad de equivocarse al menos una vez en un conjunto de pruebas; es más potente que Bonferroni.
Hot-deck	Imputación que toma el valor de «donantes» parecidos; aquí, la mediana de quienes declararon monto en el mismo rango.
Idempotencia	Propiedad de un proceso que, si se repite, produce el mismo resultado sin duplicar efectos.
Imputación	Sustituir un dato faltante por un valor plausible.
Informalidad laboral (TIL1)	Porcentaje de ocupados en un empleo informal (sin protección laboral formal) respecto al total de ocupados de 15 años y más.
Ingreso por hora	Ingreso mensual dividido entre las horas trabajadas al mes (horas semanales × 4.3).
Intervalo de confianza	Rango de valores plausibles para una cantidad poblacional; al 95 %, el procedimiento contiene al valor verdadero el 95 % de las veces.

Término	Significado
IPW	Ponderación por la probabilidad inversa de responder: da más peso a quienes se parecen a los que no respondieron.
KDD	Knowledge Discovery in Databases: proceso completo de descubrimiento de conocimiento (selección, preprocesamiento, transformación, minería, interpretación).
Linealización de Taylor	Método analítico para calcular varianzas de estimadores complejos respetando estratos y UPM.
Logaritmo natural	Transformación que acorta las colas largas; la diferencia de logaritmos equivale a una diferencia porcentual.
Logit	Regresión para una variable sí/no; sus coeficientes se leen como razones de momios.
Media geométrica	Exponencial del promedio de los logaritmos; resume mejor datos con cola larga.
Mincer, ecuación de	Regresión del logaritmo del ingreso sobre los años de escolaridad y la experiencia; mide el rendimiento de la educación.
MongoDB	Base de datos documental (NoSQL) que guarda documentos JSON.
NDJSON	Formato con un documento JSON por línea; es el que usa `mongoimport`.
Oaxaca-Blinder	Descomposición de la diferencia entre dos grupos en una parte explicada por características y otra no explicada.
Panel rotativo	Diseño en el que cada vivienda se entrevista varias veces consecutivas (en la ENOE, cinco).
Persistencia políglota	Usar distintos tipos de bases de datos según el patrón de acceso.
Percentil	Valor bajo el cual queda cierto porcentaje de las observaciones (P10: 10 %).
Razón de momios (odds ratio)	Cociente de los momios de un evento entre dos situaciones; 0.82 = 18 % menos momios.
Rao-Wu, bootstrap de	Bootstrap para encuestas complejas que remuestrea UPM dentro de cada estrato y reescala los ponderadores.
Rango (Spearman)	Lugar que ocupa un valor al ordenar todos los datos; los empates reciben el rango medio.
SDEMT	Tabla de la ENOE con las variables sociodemográficas y laborales de cada persona, además del ponderador.
Sesgo de división	Relación negativa mecánica entre el ingreso por hora y las horas trabajadas causada por el error de medición en las horas.
SQLite	Base de datos relacional contenida en un solo archivo, sin servidor.
Salario mínimo (SM)	Unidad en que la ENOE capta los rangos de ingreso; en 2025: $8,364 al mes (zona general) y $12,596 (frontera norte).
UPM	Unidad Primaria de Muestreo: conjunto de viviendas que se sortea en la primera etapa del diseño.
Valor p	Probabilidad de observar una diferencia tan grande como la hallada si la hipótesis nula fuera cierta.
VIF	Factor de inflación de la varianza: mide la multicolinealidad; valores menores que 5 se consideran aceptables.
WLS	Mínimos cuadrados ponderados: regresión en la que cada observación pesa según su factor de expansión.

Anexo B. Guía para reproducir el proyecto

B.1 Requisitos

- **Python 3.12**, la versión con la que se desarrolló y verificó el proyecto (los paquetes fijados en `requirements.txt` requieren una versión reciente de Python).
- Los paquetes de `requirements.txt`: `pandas`, `numpy`, `scipy`, `statsmodels`, `matplotlib`, `plotly` (solo para incrustar `plotly.js` en el tablero), `nbformat`, `nbconvert`, `ipykernel`, `jinja2`, `python-pptx` (presentaciones), `python-docx` y `pillow` (informe en Word), además de `pymongo` y `mongomock` (capa documental).
- Los **microdatos del INEGI** (≈ 300 MB), que no se incluyen en el proyecto: https://www.inegi.org.mx/programas/enoe/15ymas/ → Microdatos → CSV → 4.º trimestre de 2025. Se necesitan `ENOE_SDEMT425.csv` y `ENOE_COE2T425.csv`.
- Opcional: un servidor MongoDB para la carga real de los documentos (sin servidor, `--simulado` usa mongomock).

B.2 Instalación y datos

```
pip install -r requirements.txt
# Opción 1: copiar los CSV a la carpeta data\raw
# Opción 2: indicar su ubicación con una variable de entorno (PowerShell):
$env:ENOE_RAW_DIR = "C:\ruta\a\enoe_2025_trim4_csv"
```

B.3 Ejecución

```
python scripts/run_all.py            # todo el proyecto, ~10 minutos
python scripts/run_all.py --rapido   # 100 réplicas, sin cuaderno, presentaciones ni informe

# o paso a paso:
python scripts/run_etl.py            # 10 s    limpia, valida y crea la base SQLite
python scripts/run_analysis.py       # ~5 min  1,000 réplicas Rao-Wu; escribe results/
python scripts/make_figures.py       # 17 figuras de datos + 8 diagramas en figures/
python scripts/run_mongo.py --exportar   # documentos NoSQL + verificación contra SQL
python scripts/run_mongo.py --simulado --limite 20000   # carga y pipeline contra mongomock (sin
servidor)
python scripts/build_dashboard.py    # tablero/tablero_enoe.html
python scripts/build_notebook.py     # cuaderno ejecutado (.ipynb y .html)
python scripts/build_deck.py         # presentación corta (24 diapositivas)
python scripts/build_deck_completa.py  # presentación completa explicada
python scripts/build_informe.py      # informe técnico (Word)
powershell -File scripts\exportar_informe.ps1   # (Windows con Word) índice y PDF del informe en
Word
python -m unittest discover -s tests # 41 pruebas automáticas
```

B.4 Qué produce cada paso

Tabla 45. Salidas de cada paso de la ejecución.

Comando	Archivos que genera
`run_etl.py`	`data/processed/enoe_2025t4.sqlite`; `results/etl_*.csv`; `results/etl_meta.json`
`run_analysis.py`	30 tablas en `results/*.csv`, `results/resumen.json` y tablas `res_*` en la base
`make_figures.py`	`figures/01…17_*.png` y `figures/D01…D08_*.png`
`run_mongo.py`	`data/processed/mongo/` (entidades, personas, metadatos)
`build_dashboard.py`	`tablero/tablero_enoe.html` (funciona sin internet)
`build_notebook.py`	`notebooks/Proyecto_Integrador_ENOE.ipynb` y `.html`
`build_deck*.py`	`presentacion/Proyecto_Integrador_ENOE.pptx` y `presentacion/Presentacion_Completa_Proyecto_ENOE.pptx`
`build_informe.py`	`documento/Informe_Final_Proyecto_ENOE.docx`

B.5 Solución de problemas

- **`FileNotFoundError` con `ENOE_SDEMT425.csv`:** no se encontró la carpeta de datos; revise `ENOE_RAW_DIR` o copie los CSV a `data/raw`.
- **Caracteres extraños al leer los CSV:** los archivos del INEGI están en codificación `latin-1`; el proyecto ya los lee así.
- **Poca memoria:** el ETL carga solo 35 de las 115 columnas de SDEMT. Si el análisis agota la memoria, cierre otros programas o ejecute `python scripts/run_analysis.py --B 100`.
- **Para una verificación rápida del análisis:** `python scripts/run_analysis.py --B 100`.
- **Los resultados cambian de una corrida a otra:** no debería ocurrir (semilla fija). Revise que `etl_meta.json` registre la semilla 20251231 y las mismas versiones de las bibliotecas.

Anexo C. Resultados por entidad federativa

Las tablas siguientes reúnen, para las 32 entidades, los indicadores que alimentan las métricas M2 y M3 y el tablero. Los intervalos son del bootstrap de Rao-Wu al 95 %; el lugar es el que ocupa la entidad en el ranking (1 = mayor valor) y su intervalo, en las 1,000 réplicas.

Tabla 46. Informalidad (TIL1), escolaridad media de los ocupados e ingreso mediano por hora.

Entidad	Región	TIL1 %	IC 95 %	Lugar (IC)	Esc. media	Mediana $/h	IC 95 %
Aguascalientes	Centro-Norte	42.6	40.7 a 44.6	26 (25-27)	11.3	50.9	50.0 a 52.1
Baja California	Norte	37.6	35.9 a 39.3	29 (28-30)	11.1	69.8	67.7 a 70.4
Baja California Sur	Centro-Norte	38.6	36.5 a 40.6	28 (27-30)	11.3	72.7	68.9 a 77.5
Campeche	Sur	61.1	58.9 a 63.2	11 (11-13)	10.6	44.6	43.5 a 46.5
Coahuila	Norte	33.3	31.5 a 35.3	32 (31-32)	11.4	55.6	53.6 a 57.1
Colima	Centro-Norte	48.6	46.7 a 50.4	20 (19-22)	11.1	60.6	58.3 a 62.5
Chiapas	Sur	74.9	73.2 a 76.8	3 (2-4)	9.0	34.9	33.3 a 37.5
Chihuahua	Norte	36.2	34.3 a 37.8	30 (29-31)	11.0	64.4	62.5 a 66.7
Ciudad de México	Centro	45.7	43.9 a 47.6	23 (21-25)	12.5	60.0	58.1 a 62.5
Durango	Centro-Norte	54.4	51.6 a 57.1	17 (14-18)	10.9	48.8	46.9 a 50.0
Guanajuato	Centro-Norte	53.8	50.8 a 56.7	18 (14-18)	10.2	46.9	45.8 a 48.8
Guerrero	Sur	75.7	73.8 a 77.6	2 (2-3)	9.4	42.5	40.7 a 44.4
Hidalgo	Centro	71.3	67.8 a 74.9	5 (3-8)	9.9	43.7	41.7 a 46.5
Jalisco	Centro-Norte	49.0	47.0 a 50.8	19 (19-21)	10.7	53.6	52.1 a 55.6
Estado de México	Centro	54.5	52.4 a 56.5	16 (15-18)	11.2	43.8	42.6 a 46.3
Michoacán	Centro-Norte	68.5	65.9 a 70.9	8 (5-9)	9.7	45.2	43.7 a 48.4
Morelos	Centro	64.7	62.7 a 66.8	10 (9-10)	10.7	40.0	37.5 a 41.2
Nayarit	Centro-Norte	56.2	53.4 a 59.0	15 (14-18)	10.8	55.6	52.1 a 58.1
Nuevo León	Norte	35.4	33.7 a 37.1	31 (29-32)	11.6	63.4	62.5 a 66.7
Oaxaca	Sur	80.1	78.1 a 81.9	1 (1-1)	9.1	41.3	40.0 a 42.0
Puebla	Centro	72.1	70.0 a 74.1	4 (4-6)	10.0	37.9	37.5 a 39.5
Querétaro	Centro-Norte	40.7	38.2 a 43.3	27 (26-28)	11.3	52.1	50.0 a 54.5
Quintana Roo	Sur	44.7	42.4 a 47.0	25 (22-26)	11.0	56.8	53.6 a 58.3
San Luis Potosí	Centro-Norte	56.4	53.8 a 58.9	14 (14-17)	10.6	48.6	46.5 a 50.0
Sinaloa	Centro-Norte	47.6	45.2 a 50.1	21 (19-24)	11.7	59.5	58.1 a 62.0
Sonora	Norte	45.6	43.3 a 48.2	24 (20-25)	11.4	58.1	55.6 a 60.4
Tabasco	Sur	67.0	64.9 a 69.3	9 (7-10)	10.6	43.1	41.7 a 45.5
Tamaulipas	Norte	45.9	43.6 a 47.8	22 (21-25)	11.2	57.5	55.6 a 58.3
Tlaxcala	Centro	70.3	68.2 a 72.5	6 (4-8)	10.6	39.9	38.5 a 40.0
Veracruz	Sur	69.0	66.9 a 71.2	7 (5-9)	9.8	40.0	38.1 a 41.7
Yucatán	Sur	59.9	58.2 a 61.7	13 (11-13)	10.5	50.0	50.0 a 51.1
Zacatecas	Centro-Norte	60.6	58.3 a 63.1	12 (11-13)	10.4	48.9	46.5 a 50.0

Tabla 47. Correlación de Spearman, rendimiento por año de escolaridad y brecha por hora en cada entidad.

Entidad	ρ	IC 95 %	Lugar (IC)	Rend. %	IC 95 %	Brecha %	IC 95 %
Aguascalientes	0.40	0.36 a 0.44	3 (2-6)	6.8	6.0 a 7.6	4.1	-0.4 a 8.6
Baja California	0.28	0.24 a 0.32	21 (12-27)	4.0	3.5 a 4.5	3.2	0.1 a 6.1
Baja California Sur	0.21	0.15 a 0.27	32 (23-32)	3.9	2.9 a 5.1	6.2	1.5 a 11.1
Campeche	0.38	0.33 a 0.42	4 (2-10)	6.5	5.8 a 7.3	6.3	2.0 a 10.4
Coahuila	0.31	0.26 a 0.36	16 (6-24)	5.8	5.0 a 6.6	2.8	-0.7 a 6.3
Colima	0.34	0.30 a 0.37	7 (5-16)	5.1	4.5 a 5.7	6.3	2.3 a 10.0
Chiapas	0.43	0.38 a 0.48	2 (1-4)	8.2	7.1 a 9.2	-13.3	-26.5 a -1.6
Chihuahua	0.26	0.21 a 0.30	26 (16-31)	3.8	3.0 a 4.8	4.0	0.2 a 7.4
Ciudad de México	0.49	0.44 a 0.53	1 (1-2)	9.1	8.1 a 10.1	5.7	-1.7 a 12.0
Durango	0.27	0.23 a 0.30	24 (15-30)	4.9	4.2 a 5.6	-3.7	-8.4 a 0.8
Guanajuato	0.31	0.26 a 0.36	14 (6-24)	5.6	4.9 a 6.3	4.7	0.4 a 8.8
Guerrero	0.25	0.20 a 0.30	27 (16-31)	5.2	4.2 a 6.4	11.6	4.0 a 19.4
Hidalgo	0.31	0.26 a 0.37	13 (5-25)	5.8	4.8 a 6.9	15.2	9.0 a 21.4
Jalisco	0.28	0.23 a 0.33	22 (11-28)	4.3	3.8 a 5.0	10.0	5.8 a 14.0
Estado de México	0.35	0.30 a 0.41	6 (3-17)	6.0	5.2 a 6.8	2.5	-2.2 a 6.8
Michoacán	0.22	0.16 a 0.27	30 (22-32)	4.1	3.4 a 4.8	7.6	3.0 a 11.8
Morelos	0.26	0.20 a 0.32	25 (12-31)	4.1	3.1 a 5.1	6.6	0.0 a 11.7
Nayarit	0.21	0.16 a 0.26	31 (24-32)	3.7	2.9 a 4.5	7.6	4.1 a 11.1
Nuevo León	0.36	0.31 a 0.40	5 (3-13)	7.0	6.2 a 7.9	8.1	3.9 a 12.0
Oaxaca	0.28	0.23 a 0.33	20 (10-29)	6.2	5.2 a 7.2	16.5	7.3 a 25.0
Puebla	0.32	0.28 a 0.36	10 (5-20)	5.5	4.8 a 6.2	5.7	1.8 a 9.7
Querétaro	0.32	0.27 a 0.37	11 (5-22)	5.4	4.6 a 6.2	9.1	5.1 a 12.9
Quintana Roo	0.22	0.18 a 0.27	29 (23-32)	3.8	3.1 a 4.6	7.0	2.5 a 11.2
San Luis Potosí	0.31	0.26 a 0.36	15 (6-24)	5.8	4.9 a 6.7	4.2	-2.1 a 9.8
Sinaloa	0.32	0.26 a 0.38	12 (4-25)	4.8	4.0 a 5.7	1.0	-5.1 a 7.1
Sonora	0.33	0.29 a 0.37	9 (4-19)	5.9	5.2 a 6.7	-0.1	-6.1 a 4.7
Tabasco	0.24	0.19 a 0.30	28 (17-32)	4.1	3.3 a 5.0	0.1	-6.0 a 6.3
Tamaulipas	0.29	0.24 a 0.33	18 (10-27)	4.3	3.7 a 4.8	8.2	4.6 a 11.6
Tlaxcala	0.30	0.27 a 0.34	17 (8-23)	5.7	5.0 a 6.4	10.8	6.9 a 14.6
Veracruz	0.29	0.22 a 0.35	19 (8-29)	4.4	3.5 a 5.2	-0.1	-6.8 a 5.8
Yucatán	0.34	0.30 a 0.38	8 (4-17)	6.0	5.3 a 6.7	6.9	2.6 a 11.3
Zacatecas	0.27	0.22 a 0.32	23 (12-30)	5.4	4.5 a 6.2	3.6	-1.9 a 8.8

Anexo D. Preguntas frecuentes de la defensa

Respuestas cortas a las preguntas más probables. **Entiendan la lógica de cada respuesta; no las memoricen.** Las cifras proceden de `results/resumen.json`.

A. Conceptos

¿Qué es el factor de expansión y por qué hay que usarlo?

Es el número de personas de la población que representa cada persona de la muestra (`fac_tri`; su suma es 131 millones). Sin ponderar se describe a la muestra, no al país.

¿Qué es el efecto de diseño?

Cuánto más grande es la varianza real, por ser una muestra por conglomerados, que la de una muestra aleatoria simple. Aquí vale 4.8 en la informalidad: 190 mil ocupados equivalen a unos 40 mil independientes.

¿Cómo se interpreta un intervalo de confianza del 95 %?

Es un rango de valores plausibles: si se repitiera el estudio muchas veces, el 95 % de los intervalos construidos así contendría el valor real. Si no incluye el cero, la diferencia es significativa.

¿Qué diferencia hay entre «significativo» y «grande»?

El valor p dice si una diferencia puede deberse al azar; el tamaño del efecto dice si importa. Con 112 mil observaciones casi todo es significativo; por eso se reporta la d de Cohen (0.06 a 0.24, pequeña) y la brecha en %.

¿Por qué 4.3 semanas por mes?

Es la convención del INEGI para construir `ing_x_hrs = ingocup / (hrsocup × 4.3)` (52 semanas ÷ 12 meses ≈ 4.33); nuestra variable coincide con la del INEGI con error relativo menor de 0.01 %.

B. Datos y limpieza

¿Por qué ese conjunto de datos y cómo saben que está bien leído?

ENOE 4T-2025 del INEGI: 419,038 registros, fuente oficial, con «suciedad» real y diccionario. Con la base oficial se reproducen **7 de 7 cifras publicadas** (PEA 61.3 M, participación 59.3 %, informales 32.9 M, TIL1 55.0 % y los TIL1 de Chiapas, Chihuahua y CDMX). Si se incluyeran los menores de 15 años, el TIL1 sería 55.27 % y no coincidiría.

¿Qué limpieza hicieron y por qué esas reglas?

La cobertura (entrevista completa, residente habitual, 15+, ocupado) elimina filas; lo demás (faltantes codificados, calidad del ingreso, atípicos) **crea banderas** para poder hacer análisis de sensibilidad sin volver a limpiar. Cada regla es una función probada y queda en una bitácora (de 419 mil a 112 mil).

«No hay nulos» en la ENOE, ¿entonces qué limpiaron?

Los faltantes vienen **codificados como valores reales**: escolaridad 99 (610 casos), horas 0 (5,278 ocupados ausentes) u horas mayores de 112 (41 casos imposibles). Un `isna()` diría que todo está completo.

¿Qué es el «ingreso cero» y por qué importa?

El 36 % de los registros tiene `ingocup = 0`, pero no es «sin ingreso»: 22 % (ponderado) solo da un **rango de salarios mínimos**, 13 % no especifica y solo 4 % realmente no recibe ingresos. Además, quien más estudió declara menos el monto exacto (55 % frente a 69 %): los datos faltan de forma no aleatoria. Por eso se contrastó con imputación por rango, IPW y solo asalariados.

¿Por qué recortan atípicos en P0.5-P99.5 por entidad?

El ingreso por hora va de $0.03 a $11,628. Recortar dentro de cada entidad respeta que los salarios difieren por estado. Es 1 % de la muestra y el resultado casi no cambia sin recorte (brecha 3.6 % frente a 3.7 %; rendimiento 5.4 % frente a 5.1 %).

C. Estadística

¿Por qué ponderan con `fac_tri` y por qué el bootstrap de Rao-Wu?

Cada persona representa a `fac_tri` personas. Y como la ENOE es por conglomerados, los errores estándar «normales» serían demasiado pequeños: Rao-Wu remuestrea UPM dentro de estratos y reescala los ponderadores; se verificó que reproduce la varianza de Taylor.

¿Por qué el logaritmo del ingreso?

Porque el ingreso por hora tiene asimetría 3.1 y el logaritmo la vuelve simétrica (0.06); además, una diferencia de logaritmos es una diferencia porcentual aproximada.

¿Spearman o Pearson?

Spearman: mide asociación monótona, robusta a atípicos y a la forma de la relación; la escolaridad tiene muchos empates (se usan rangos medios ponderados). Con pesos iguales coincide con SciPy.

¿Qué significa «ranking defendible»?

Que se reporta con incertidumbre: cada estado tiene un intervalo del lugar que ocupa. La Ciudad de México es la primera con seguridad (lugar 1 a 2), Baja California Sur está entre las últimas (23 a 32), pero los estados del centro del ranking tienen intervalos de 15 o más lugares y **no se pueden distinguir**.

¿Por qué Holm y no Bonferroni?

Holm controla la misma tasa de error por familia pero es uniformemente más potente. Se aplica a las cuatro pruebas por nivel de instrucción.

¿Por qué hay Welch y Mann-Whitney *y* el método de diseño?

El protocolo pedía las pruebas clásicas (sin ponderar) y coinciden en las conclusiones; pero la inferencia **correcta** para la población es la que usa el diseño. Se muestran las dos.

D. Resultados

¿Cuánto rinde un año de escolaridad?

≈ **5.1 %** más ingreso por hora (IC 95 %: 5.0 a 5.3) controlando edad, sexo, entidad y localidad; ≈ 3.8 % si además se controla el tipo de empleo (parte del beneficio pasa por conseguir un mejor empleo). Es **robusto**: 4.9 a 5.7 % en siete especificaciones. No es lineal: licenciatura o posgrado paga **+92 %** frente a no terminar primaria.

¿Estudiar rinde más en estados ricos?

No: la diferencia entre el cuarto cuartil y el primero es ≈ 0 ($p = 0.91$). El *nivel* de ingreso sí difiere (los estados más escolarizados pagan más: $\rho = 0.74$ entre estados), pero el *rendimiento por año* es parecido.

¿Hay brecha de género?

Sí, **pero depende de qué se mide**: por hora 3.7 % (IC 2.3 a 5.0, $p < 0.001$); por nivel 8.4 / 10.1 / 7.6 / 3.9 %, las cuatro significativas tras Holm; por **mes 26.9 %**. La diferencia mensual es de **horas** (las mujeres trabajan 24.1 % menos), no de pago por hora. Entre personas comparables, 8.2 %.

¿Qué es la parte «no explicada» de Oaxaca-Blinder?

La parte de la brecha que **no** se explica por las características medidas (escolaridad, edad, lugar, empleo, rama). Aquí las mujeres tienen *mejores* características (más escolaridad) pero reciben menos, así que el residuo (6.9 puntos logarítmicos) es mayor que la brecha total (3.8). **No prueba discriminación**: incluye todo lo no observado.

¿Por qué no interpretan el modelo con horas (G6)?

Por el **sesgo de división**: el ingreso por hora es ingreso ÷ horas, así que un error en las horas crea una relación negativa mecánica y la brecha «sube» a 16 % artificialmente. Se muestra por transparencia.

¿Por qué la imputación (S3) da 0.7 % si las demás dan más?

Imputar el grupo B con la mediana del rango le asigna **el mismo ingreso a un hombre y a una mujer** del mismo rango y borra diferencias: sesga hacia cero por construcción y es una cota inferior. La conclusión honesta: la brecha por hora es positiva pero su tamaño depende de la muestra (de 0.7 % a 4.6 %); la ajustada (≈ 8 %) y la mensual (≈ 27 %) son sólidas.

¿Dónde está la brecha?

Abajo: 8.2 % en el P10 y 10.4 % en el P25; en la mediana es 2.1 % (no significativa) y arriba es nula o favorece a las mujeres (un «piso pegajoso»). También se concentra en el empleo informal.

¿Qué hallazgo hay sobre informalidad?

TIL1 nacional 55.0 %; de 33 % (Coahuila) a 80 % (Oaxaca); 87 % entre quienes no terminaron la primaria frente a 38 % con preparatoria o más. Entre estados ρ = -0.86; a nivel individual cada año de escolaridad baja ≈ 3.9 puntos la probabilidad; ser mujer suma ≈ 6 puntos.

¿Es causal?

No. Es una asociación: hay sesgo de habilidad no observada y selección. Y las relaciones entre estados no deben leerse a nivel individual (falacia ecológica).

E. Ingeniería de datos y NoSQL

¿Por qué SQLite y MongoDB?

Persistencia políglota por **patrón de acceso**: análisis (agregaciones ponderadas, `JOIN`, integridad) en una base relacional; servir la ficha de una entidad (un documento por clave, esquema flexible) en una documental. SQLite es la fuente de verdad; MongoDB es una vista de lectura que se regenera.

¿Por qué embeben los indicadores en `entidades` pero no las personas?

Los indicadores se leen siempre junto con la entidad (una lectura, sin `JOIN`). Las 190 mil personas no caben en un documento (límite de 16 MB de BSON) ni se leen con la entidad: son una colección aparte relacionada por `cve_ent`.

¿Cargaron a un servidor MongoDB real?

No: en la máquina de desarrollo no hay un servidor MongoDB. Los documentos se exportaron (NDJSON listos para `mongoimport`) y la carga completa se probó contra **mongomock**, un simulador de MongoDB en memoria: 190,187 documentos de persona, 32 de entidad y uno de metadatos, siete índices, documentos BSON válidos y una recarga que no duplica nada. Además se **verificó que la agregación ejecutada en el motor reproduce la vista SQL** (diferencia máxima 0.005 puntos porcentuales). mongomock imita la API pero no es MongoDB; con un servidor, `python scripts/run_mongo.py --uri …` hace la carga y las mismas verificaciones.

¿Cómo garantizan la reproducibilidad?

Una sola semilla (20251231), versiones y huellas SHA-256 en `etl_meta.json`, ETL idempotente, 41 pruebas automáticas y un cuaderno que se reconstruye desde `results/` con aserciones que avisan si una conclusión deja de ser cierta.

F. Preguntas incómodas

¿Qué limitaciones tiene su trabajo?

Un trimestre; ingreso autorreportado con redondeo; ingreso por hora a partir de las horas de *una* semana; selección en el empleo; no causalidad; entre 1,900 y 5,900 observaciones por estado; y la redacción literal de los códigos de `p6c` se infirió de su correspondencia con `ing7c` (conviene confirmarla con el cuestionario).

¿Qué harían con más tiempo?

Usar varios trimestres (panel rotativo), modelar la participación laboral (corrección de Heckman), hacer un mapa geográfico real con el Marco Geoestadístico y estimaciones para áreas pequeñas.

¿Qué parte hiciste tú?

(La responden los integrantes.) Roles propuestos: ingeniería de datos y pipeline; análisis estadístico; visualización y comunicación. Cada integrante debe poder explicar de principio a fin al menos una sección del cuaderno.

Anexo E. Guion de exposición

Propuesta de reparto de la exposición entre los tres integrantes del equipo. Hay dos versiones: la **presentación completa** (`Presentacion_Completa_Proyecto_ENOE.pptx`, 48 diapositivas que explican cada concepto y cada decisión; unos 50 minutos) y la **ruta corta** (las 18 diapositivas principales señaladas con ★ en la presentación completa, que también existen como presentación independiente de 24 diapositivas; unos 18 minutos). Las notas del orador de cada diapositiva incluyen el texto sugerido y el nombre de quien presenta, y el archivo está dividido en secciones por bloque.

Tabla 48. Reparto sugerido de la exposición (49 minutos la versión completa; 18 minutos la ruta corta).

Bloque	Presenta	Contenido	Min. (completa)	Min. (ruta corta)
A. Apertura	Juan Evelio	La pregunta, los objetivos, qué es el KDD y la hoja de ruta	5	2
B. Datos y diseño muestral	Juan Evelio	ENOE, tablas, llave, diseño muestral, factor de expansión, validación con cifras oficiales	5	2
C. Limpieza de datos	Angel Yireh	Embudo de filtros, códigos especiales, el ingreso cero, no respuesta, imputación, atípicos, 15 expectativas	7	2
D. Ingeniería de datos	Angel Yireh	Arquitectura, esquema en estrella, SQL frente a MongoDB, reproducibilidad, pruebas, mapa del código	6	1
E. Estadística explicada	Luis Andre	Diseño muestral y error, bootstrap de Rao-Wu, intervalos y valor p, Spearman, Mincer, brecha y Holm	7	2
F1. Escolaridad e ingreso	Luis Andre	Rendimiento, estados ricos y pobres, ranking de entidades	4	3
F2. Brecha de género	Angel Yireh	Brecha por hora y por mes, personas comparables, Oaxaca-Blinder, distribución, heterogeneidad y robustez	6	3
F3. Informalidad, tablero y diagnóstico	Luis Andre	Informalidad y escolaridad, tablero interactivo, diagnóstico del modelo	5	1
G. Cierre	Juan Evelio	Síntesis, métricas de éxito, limitaciones y cierre; al final (bloque H, respaldo) quedan el glosario y las preguntas difíciles	4	2

Tres mensajes que todo el equipo debe poder repetir

1. Cada año de escolaridad se asocia con 5.1 % más ingreso por hora, con un beneficio mucho mayor en la licenciatura, y el rendimiento es parecido en estados ricos y pobres.
2. La brecha de género es de 3.7 % por hora y de 26.9 % por mes: la diferencia mensual es sobre todo de horas trabajadas.
3. Los resultados son asociaciones, descritas con intervalos de confianza que respetan el diseño de la encuesta; el trabajo documenta qué se hizo, qué se verificó y qué no.

Consejos para la defensa

- Cuando se pregunte por una cifra, **responda primero con la idea** («cada año de estudio sube el ingreso 5 %») y después con el número y el intervalo.
- Si no se sabe una respuesta, es válido decir qué se haría para averiguarla; **no inventar cifras**. Todas están en `results/resumen.json` y en el cuaderno.
- Ante «¿es causal?», responder siempre que no, y explicar por qué (habilidad no observada, selección).
- Tener abiertos el tablero y el cuaderno HTML para mostrar cualquier detalle a la audiencia.
- Reconocer las limitaciones (anexo y sección 8.5) antes de que las pregunten: transmite rigor.

Anexo F. Referencias

Blau, F. D., y Kahn, L. M. (2017). The gender wage gap: Extent, trends, and explanations. *Journal of Economic Literature*, 55(3), 789-865.

Blinder, A. S. (1973). Wage discrimination: Reduced form and structural estimates. *Journal of Human Resources*, 8(4), 436-455.

Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2.ª ed.). Lawrence Erlbaum.

Fayyad, U., Piatetsky-Shapiro, G., y Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37-54.

Fortin, N., Lemieux, T., y Firpo, S. (2011). Decomposition methods in economics. En *Handbook of Labor Economics* (vol. 4A, pp. 1-102). Elsevier.

Heckman, J. J. (1979). Sample selection bias as a specification error. *Econometrica*, 47(1), 153-161.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65-70.

INEGI. Encuesta Nacional de Ocupación y Empleo (ENOE), población de 15 años y más: metodología, descriptor de archivos y tabulados. https://www.inegi.org.mx/programas/enoe/15ymas/

Jann, B. (2008). The Blinder-Oaxaca decomposition for linear regression models. *The Stata Journal*, 8(4), 453-479.

Kish, L. (1965). *Survey Sampling*. Wiley.

Little, R. J. A., y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.ª ed.). Wiley.

Lumley, T. (2010). *Complex Surveys: A Guide to Analysis Using R*. Wiley.

Mincer, J. (1974). *Schooling, Experience, and Earnings*. National Bureau of Economic Research.

Neumark, D. (1988). Employers' discriminatory behavior and the estimation of wage discrimination. *Journal of Human Resources*, 23(3), 279-295.

Oaxaca, R. (1973). Male-female wage differentials in urban labor markets. *International Economic Review*, 14(3), 693-709.

Rao, J. N. K., y Wu, C. F. J. (1988). Resampling inference with complex survey data. *Journal of the American Statistical Association*, 83(401), 231-241.

Rao, J. N. K., Wu, C. F. J., y Yue, K. (1992). Some recent work on resampling methods for complex surveys. *Survey Methodology*, 18(2), 209-217.

Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72-101.