★ ruta corta

Radiografía socioeconómica de México

Escolaridad, ingreso y brecha de género

Encuesta Nacional de Ocupación y Empleo (ENOE), 4.º trimestre de 2025 · INEGI

Equipo 1: Juan Evelio Culin Grajeda · Angel Yireh Garcia Jara · Luis Andre Gutierrez Zuñiga

Proyecto Integrador de Ciencia de Datos · Ingeniería en Computación, 9.º semestre · UNE Plantel Centro · 18 de octubre de 2026

419,038	190,187	32	1,000
registros	ocupados de 15+	entidades	réplicas bootstrap

★ ruta corta

La pregunta: ¿cuánto rinde estudiar, y para quién?

¿Cuánto aumenta el ingreso laboral por cada año adicional de escolaridad, cómo cambia esa relación entre entidades federativas y existe una brecha salarial significativa entre hombres y mujeres con la misma escolaridad?

1. Estimar la correlación y el rendimiento de la escolaridad en cada una de las 32 entidades
2. Probar si hay brecha de ingreso por hora entre hombres y mujeres con el mismo nivel de instrucción
3. Identificar las entidades con más informalidad y su relación con la escolaridad

M1 Brecha por nivel con IC 95 % y prueba de hipótesis

M2 Spearman de las 32 entidades con IC y ranking

M3 Tablero con ≥ 4 gráficas sobre una base NoSQL

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Qué vamos a ver: nueve bloques y dos rutas

A	**Apertura** La pregunta, los objetivos y el ciclo KDD	**Juan Evelio**	5 min
B	**Datos y diseño muestral** La ENOE, el diseño muestral y la validación con cifras oficiales	**Juan Evelio**	5 min
C	**Limpieza de datos** Cobertura, faltantes, ingreso cero, imputación y atípicos	**Angel Yireh**	7 min
D	**Ingeniería de datos** Arquitectura, esquema en estrella, SQL y MongoDB, reproducibilidad	**Angel Yireh**	6 min
E	**Estadística explicada** Rao-Wu, intervalos, Spearman, Mincer, brecha y Holm	**Luis Andre**	7 min
F1	**Escolaridad e ingreso** Rendimiento de la escolaridad y ranking de entidades	**Luis Andre**	4 min
F2	**Brecha de género** Brecha por hora y por mes, Oaxaca-Blinder, distribución y robustez	**Angel Yireh**	6 min
F3	**Informalidad, tablero y diagnóstico** Informalidad, tablero y diagnóstico del modelo	**Luis Andre**	5 min
G	**Cierre** Síntesis, métricas de éxito, límites y cierre	**Juan Evelio**	4 min

★ 18

diapositivas de la ruta corta (≈ 18 min)

48

diapositivas de la ruta completa (≈ 50 min)

El guion de cada diapositiva está en las **notas del orador**. Al final: glosario y preguntas de respaldo.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Por qué importa: educación, informalidad e igualdad de género

59.8 M

personas ocupadas de 15 años y más

55 %

de las personas ocupadas está en un empleo informal

42 %

de la muestra salarial son mujeres

Educación: ¿cuánto rinde estudiar un año más?

La escolaridad es la principal vía de movilidad social: ¿cuánto se paga cada año de estudio y cambia por entidad?

Informalidad: ¿dónde y para quién?

La mitad del empleo carece de protección laboral formal; varía de 33 % a 80 % según la entidad.

Igualdad: ¿ganan lo mismo mujeres y hombres?

Comparar a personas con la misma escolaridad separa la diferencia de preparación de la diferencia de pago.

Fuente: Encuesta Nacional de Ocupación y Empleo (ENOE) del INEGI, 4.º trimestre de 2025: microdatos públicos y anonimizados.

★ ruta corta

Un ciclo KDD completo sobre datos reales y masivos

Selección
Fase 1 · Sem. 1

ENOE 4T-2025; validación contra cifras del INEGI

Preprocesamiento
Fase 2 · Sem. 4

Faltantes codificados, calidad del ingreso, atípicos, 15 pruebas de datos

Transformación
Fase 3 · Sem. 4 · 6 · 7

Variables derivadas, ETL, SQLite y MongoDB

Minería
Fase 4 · Sem. 2 · 3 · 5

Diseño muestral complejo, regresión, Oaxaca-Blinder

Interpretación
Fase 5 · Sem. 5

Hallazgos, recomendaciones y límites

419,038
registros de la tabla SDEMT

111,958
observaciones salariales

21,194
UPM en 713 estratos

7 de 7
cifras oficiales reproducidas

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La ENOE: la encuesta que mide el mercado laboral de México

Qué es

- Encuesta continua del INEGI en viviendas de todo el país
- Panel rotativo: cada vivienda se entrevista hasta 5 veces seguidas
- Microdatos públicos y anonimizados, en 5 tablas CSV (latin-1)
- Cada fila de SDEMT es una persona; fac_tri dice a cuántas personas representa

Tabla	Contenido	¿Se usa?
SDEMT	**Sociodemográfica y laboral: una fila por persona**	**Sí · 35 de 115 columnas**
COE2T	**Ocupación y empleo (parte 2): captación del ingreso**	**Sí · 14 columnas**
COE1T	Ocupación y empleo (parte 1)	No
HOGT	Hogares	No
VIVT	Viviendas	No

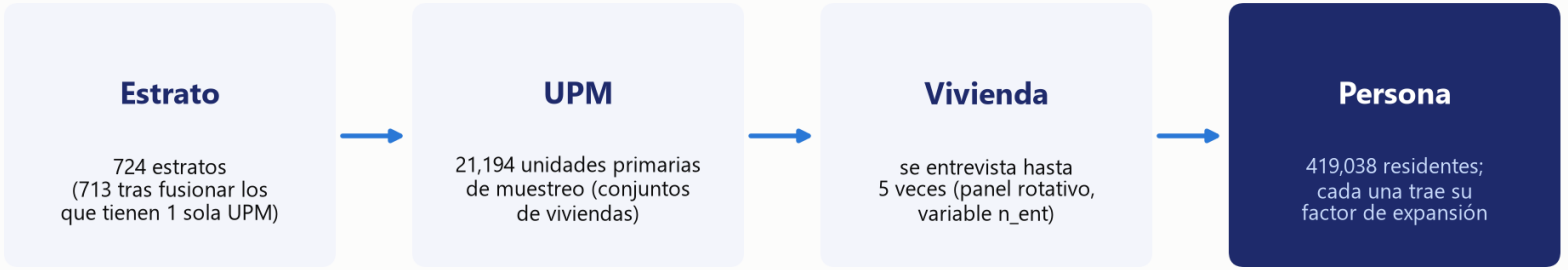
419,038
personas en SDEMT

344,166
filas en COE2T

190,187
ocupados unidos 1 a 1

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

El diseño muestral: por qué cada persona pesa distinto



fac_tri = a cuántas personas de la población representa cada persona de la muestra

La suma de fac_tri es 131.0 millones de personas (la población del país); los ocupados de 15+ años representan 59.8 millones.

Ejemplo: una persona con fac_tri = 300 cuenta como 300 personas en cualquier promedio o porcentaje.

724 → 713
estratos (11 fusionados)

21,194
unidades primarias de muestreo

131.0 M
suma de fac_tri = población del país

Ponderar: un promedio sin ponderar describiría a la muestra, no al país.

Efecto de diseño 4.8: 190 mil ocupados equivalen a unos 40 mil independientes.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Los filtros y ponderadores reproducen las cifras oficiales del INEGI

Indicador	Proyecto	INEGI	¿Coincide?
PEA (millones)	61.35	61.3	**Sí**
Tasa de participación (%)	59.28	59.3	**Sí**
Ocupación informal (millones)	32.88	32.9	**Sí**
TIL1 nacional (%)	55.00	55.0	**Sí**
TIL1 Chiapas (%)	74.90	74.9	**Sí**
TIL1 Chihuahua (%)	36.19	36.2	**Sí**
TIL1 Ciudad de México (%)	45.71	45.7	**Sí**

7 de 7

cifras del INEGI reproducidas al redondear a su precisión

Por qué solo 15+: con los 1,078 menores de 15 años ocupados, el TIL1 sería 55.27 % y dejaría de coincidir con el oficial.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La cobertura define el universo: cinco reglas, 190,187 personas

Paso	Regla	Quién se excluye	Antes	Después	Excluidos
L0	Registros crudos de SDEMT	—	419,038	419,038	0
L1	Entrevista completa	Entrevistas incompletas (r_def ≠ 0)	419,038	418,146	892
L2	Residente habitual	Nuevos residentes (c_res = 2), sin sexo ni edad	418,146	408,099	10,047
L3	Edad de 15 a 98 años	Menores de 15 años y edad no especificada	408,099	323,367	84,732
L4	Población ocupada	Personas no ocupadas (clase2 ≠ 1)	323,367	190,187	133,180
L5	**Ponderador positivo**	**Nadie: es una verificación**	**190,187**	**190,187**	**0**

Marcar, no borrar. Solo la cobertura elimina filas; los faltantes, la calidad del ingreso y los atípicos crean banderas, para cambiar una decisión y rehacer el análisis sin volver a limpiar.

190,187

personas ocupadas de 15+: el universo de estudio

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Los faltantes vienen codificados como números reales

Lo que ve el código

```
df.isna().sum().sum()
→ 0      # «todo está completo»
df['anios_esc'].max()
→ 99     # no especificado
```

Un 99 tratado como número real distorsionaría los promedios. Cada código se convierte en faltante y se registra; nadie se borra del universo.

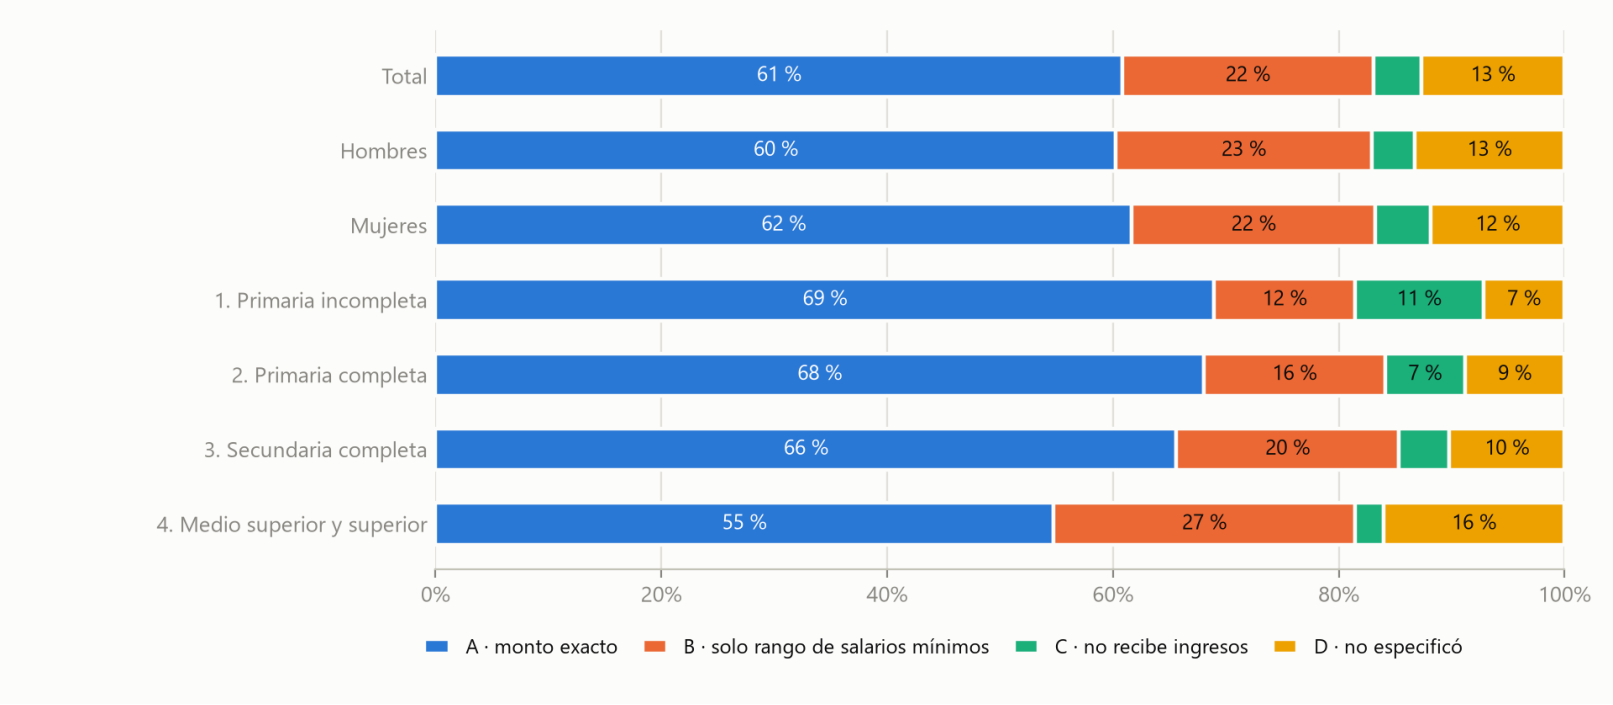
Marca	Variable	Código	Registros	Tratamiento
M1	anios_esc	99 = no especificado	610	Faltante: no entra al análisis de escolaridad
M2	hrsocup	0 horas la semana pasada	5,278	Faltante: ocupado pero ausente; no hay ingreso por hora
M3	hrsocup	> 112 horas semanales	41	Faltante: 16 h × 7 días es una jornada imposible
M4	niv_ins	5 = no especificado	479	Se excluye del análisis por nivel de instrucción

Menos de 3 % del universo en el peor caso (M2): el faltante importante es el del ingreso.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

El «ingreso cero» esconde tres fenómenos distintos



61 %
declara el monto exacto

22 %
da solo un rango de salarios mínimos

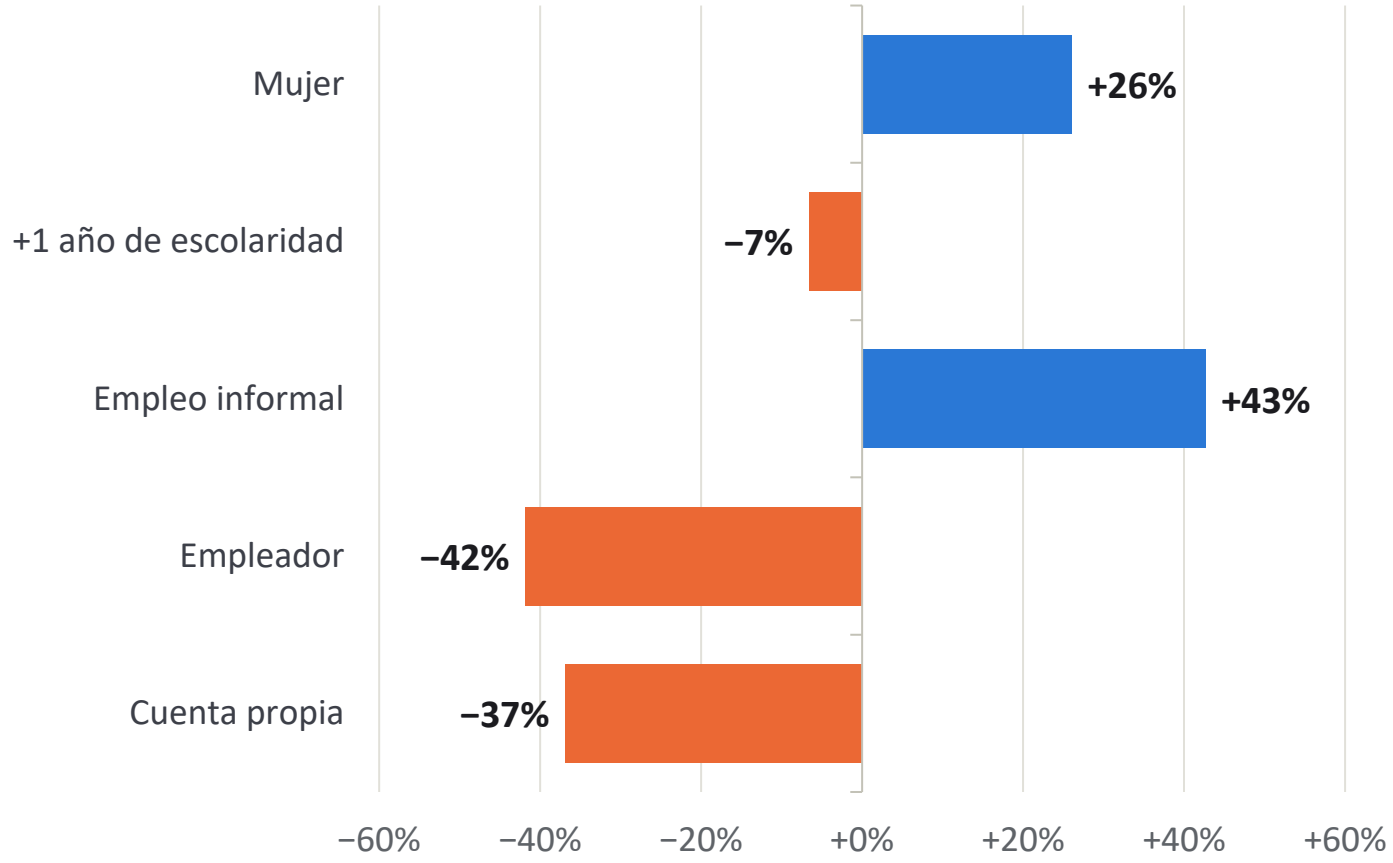
13 %
no especifica su ingreso

Más escolaridad, menos monto exacto (55 % vs. 69 %)

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La no respuesta del ingreso no es aleatoria: quien más estudia declara menos

Cambio en los momios de declarar el monto exacto (%)



69 % → 55 %

declaran el monto exacto: de primaria incompleta a media superior o más

V = 0.52

asociación χ^2 con la posición en la ocupación (informalidad 0.22; nivel 0.10; sexo 0.04)

Consecuencia: la muestra salarial subrepresenta a los más escolarizados; se contrasta con imputación, IPW y solo asalariados.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Imputación por rango: la mediana de quienes sí declararon

Rango declarado	Referencia (grupo A)	Mediana (× SM)	Personas B
Menos de 1 SM	51,496	0.62	7,994
Exactamente 1 SM	88	1.00	11,664
Más de 1 a 2 SM	53,258	1.29	12,684
Más de 2 a 3 SM	**10,386**	**2.39**	**3,154**
Más de 3 a 5 SM	4,304	3.59	762
Más de 5 a 10 SM	1,296	5.98	134
Más de 10 SM	120	11.96	46

SM = salario mínimo mensual de la zona de la persona. La mediana se usa en lugar del punto medio porque dentro de cada rango hay más personas cerca del límite inferior.

Ejemplo

«Más de 2 a 3 SM»

2.39 × $8,364

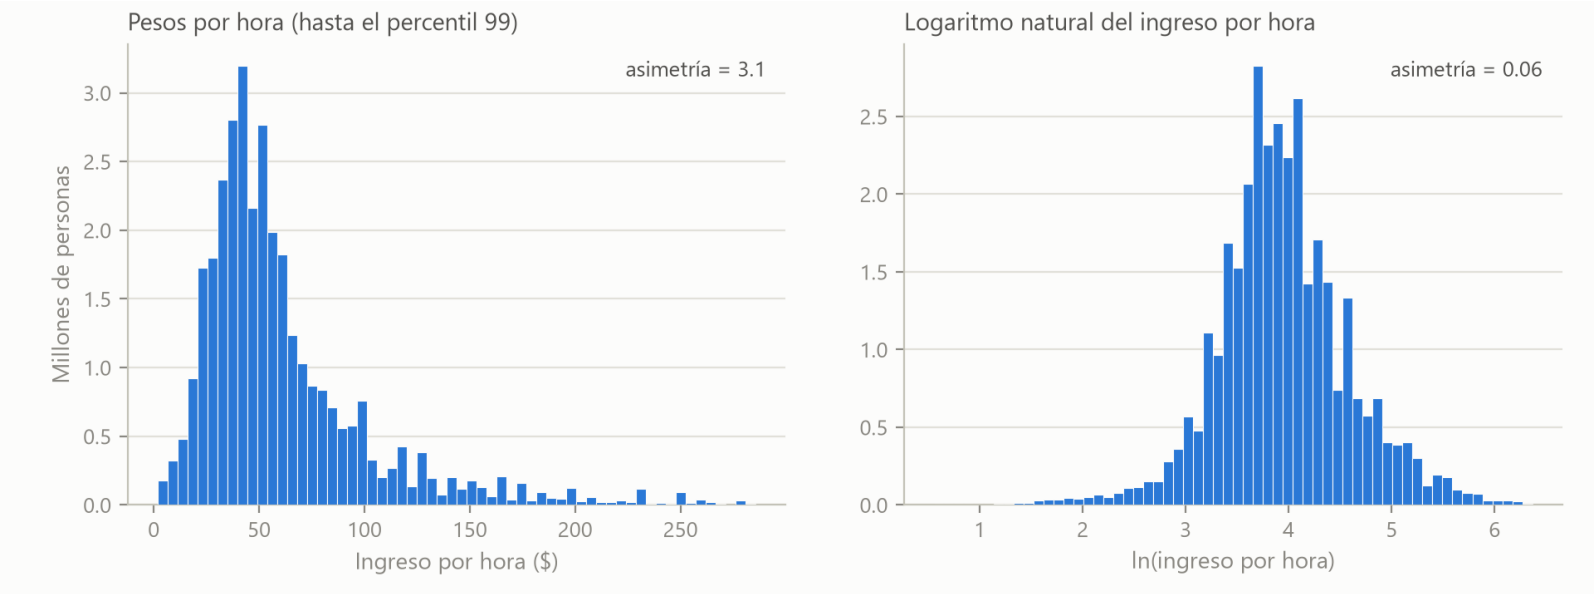
= $20,000 al mes

Sesga hacia cero

Mismo ingreso para hombres y mujeres del rango: solo sensibilidad (145,529 personas).

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Atípicos y logaritmo: domar la cola larga del ingreso



3.1 → 0.06
asimetría: en pesos → en logaritmo

1,133
atípicos (1.0 %) fuera de P0.5–P99.5 por entidad

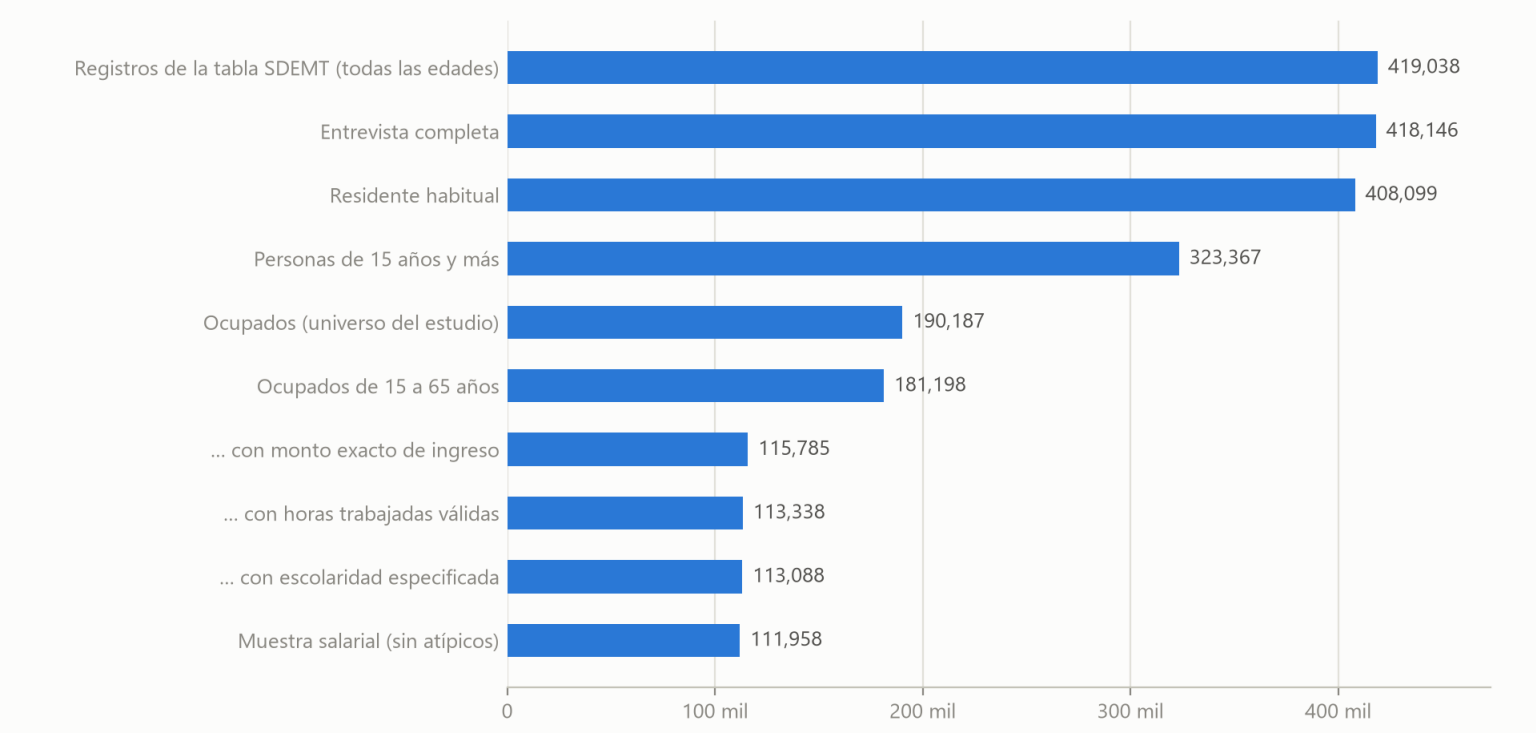
3.6 vs 3.7 %
brecha sin recorte vs. con recorte

Por qué el logaritmo: una diferencia de logaritmos es una diferencia porcentual: ln(110) − ln(100) = 0.095 ≈ 10 %.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

De 419 mil registros a 112 mil observaciones, paso a paso



- La cobertura elimina filas; todo lo demás crea banderas
- 610 escolaridades = 99 y 5,278 jornadas de 0 h recodificadas
- 1,133 ingresos por hora atípicos (P0.5–P99.5 por entidad)
- 15 de 15 expectativas de calidad cumplidas
- ETL idempotente: 10 s, una sola semilla y SHA-256 de cada archivo

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

15 pruebas automáticas de calidad: 15 de 15 cumplidas

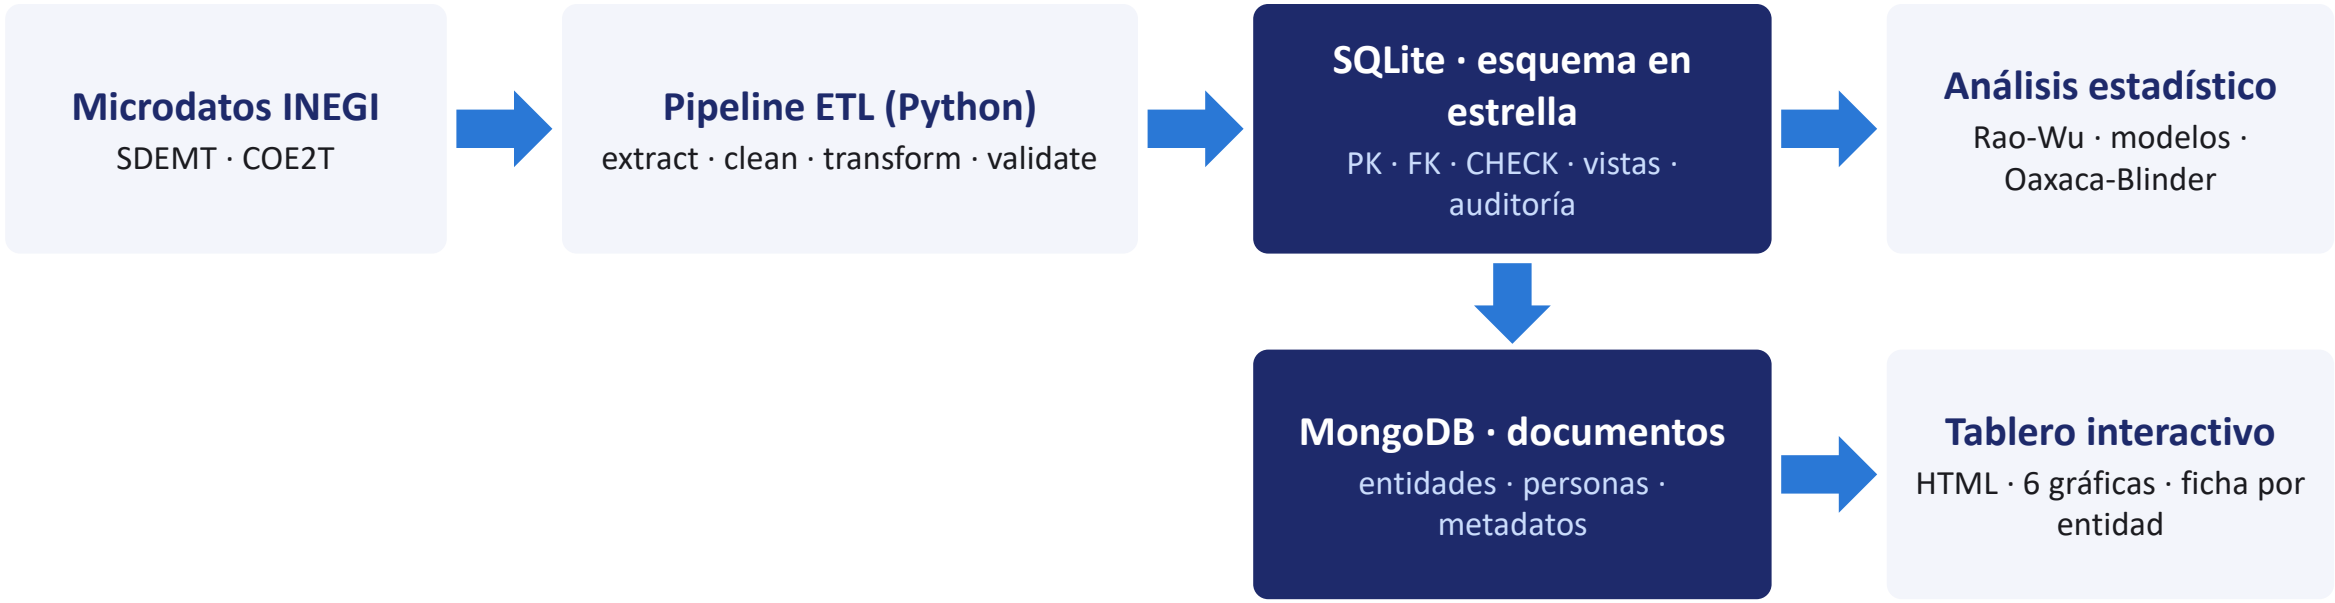
- ✓ persona_id único
- ✓ todos son ocupados
- ✓ niv_ins=4 implica >= 12 años de escolaridad
- ✓ 32 entidades presentes
- ✓ grupo de ingreso exhaustivo
- ✓ horas entre 0 y 168 (crudas)
- ✓ sexo en {1,2}
- ✓ ing7c consistente con ingocup / salario mínimo
- ✓ ingocup entre 0 y 1,000,000
- ✓ edad entre 15 y 98
- ✓ ing_x_hrs = ingocup / (hrsocup × 4.3)
- ✓ p6c (COE2T) reproduce ing7c (SDEMT)
- ✓ ponderador positivo
- ✓ niv_ins=1 implica <= 5 años de escolaridad
- ✓ ingocup = p6b2 (COE2T) en el grupo A

14 críticas + 1 informativa: si una crítica falla, el ETL se detiene en lugar de continuar con datos dudosos.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Arquitectura: SQLite para analizar, MongoDB para servir



Relacional (SQLite): analizar

Datos tabulares de esquema fijo · agregaciones ponderadas y JOIN · integridad por restricciones · fuente de verdad

Documental (MongoDB): servir

Una ficha por entidad (embedding) · el esquema crece sin migraciones · lectura por clave · vista que se regenera

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Esquema en estrella: una tabla de hechos y diez dimensiones



Qué garantiza

- fact_ocupado: 190,187 filas · 36 columnas
- Llaves primarias y foráneas (foreign_keys = ON)
- CHECK: fac_tri > 0, eda 15–98, emp_ppal ∈ {1, 2}
- 5 índices y 4 vistas (TIL1, escolaridad, calidad, muestra salarial)
- integrity_check = ok · 0 violaciones de FK

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La misma pregunta en SQL y en MongoDB

SQL · vista v_til_entidad

```
SELECT e.entidad,
  ROUND(100.0 *
    SUM(f.fac_tri * f.informal)
    / SUM(f.fac_tri), 2) AS til1_pct
FROM fact_ocupado f
JOIN dim_entidad e USING (cve_ent)
GROUP BY e.entidad
ORDER BY til1_pct DESC;
```

MongoDB · pipeline de agregación

```
db.personas.aggregate([
  {$group: {_id: "$cve_ent",
    ocupados: {$sum: "$fac_tri"},
    informales: {$sum: {$cond: [
      "$trabajo.informal",
      "$fac_tri", 0]}}}},
  {$project: {til1_pct: {$multiply: [
    100, {$divide: [
      "$informales", "$ocupados"]}]}}}
])
```

Ficha de una entidad: SQL necesita varias consultas con JOIN; MongoDB, una lectura por clave: `db.entidades.findOne({cve_ent: 20})`

0.005 pp

diferencia máxima entre ambas (redondeo del SQL)

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Reproducibilidad: una orden, una semilla, 41 pruebas

```
python scripts/run_all.py            # todo el proyecto, de principio a fin, en ≈ 10 minutos
```



20251231
semilla única para todo lo aleatorio

30 de 30
archivos de resultados idénticos en dos corridas

41
pruebas automáticas (limpieza, encuestas, modelos, capa documental, integración)

SHA-256
huella de cada archivo de origen (tabla etl_run)

Idempotente: la base se recrea desde cero. **Auditable:** bitácora de cada regla. **Transparente:** todas las decisiones viven en config.py.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Mapa del código: un módulo, una responsabilidad

config.py
Rutas, parámetros, catálogos y cifras de referencia: la única fuente de decisiones

extract.py · validacion.py
Lectura de los CSV (latin-1) con huella SHA-256; comparación con las cifras del INEGI

clean.py
Cobertura, faltantes, grupos de ingreso, atípicos, muestras y 15 expectativas

transform.py
Llave de persona, unión 1 a 1, variables derivadas e imputación

pipeline.py
Orquesta el ETL completo y escribe los metadatos y la bitácora

load_sqlite.py · load_mongo.py
Esquema en estrella con restricciones y documentos NoSQL

survey.py
Rao-Wu, Taylor, Spearman ponderado, WLS y logit con diseño, Holm

datos · estimadores · modelos · analisis
Todo el análisis estadístico: 30 tablas de resultados

viz · viz_diagramas · figuras
17 figuras de datos y 8 diagramas explicativos

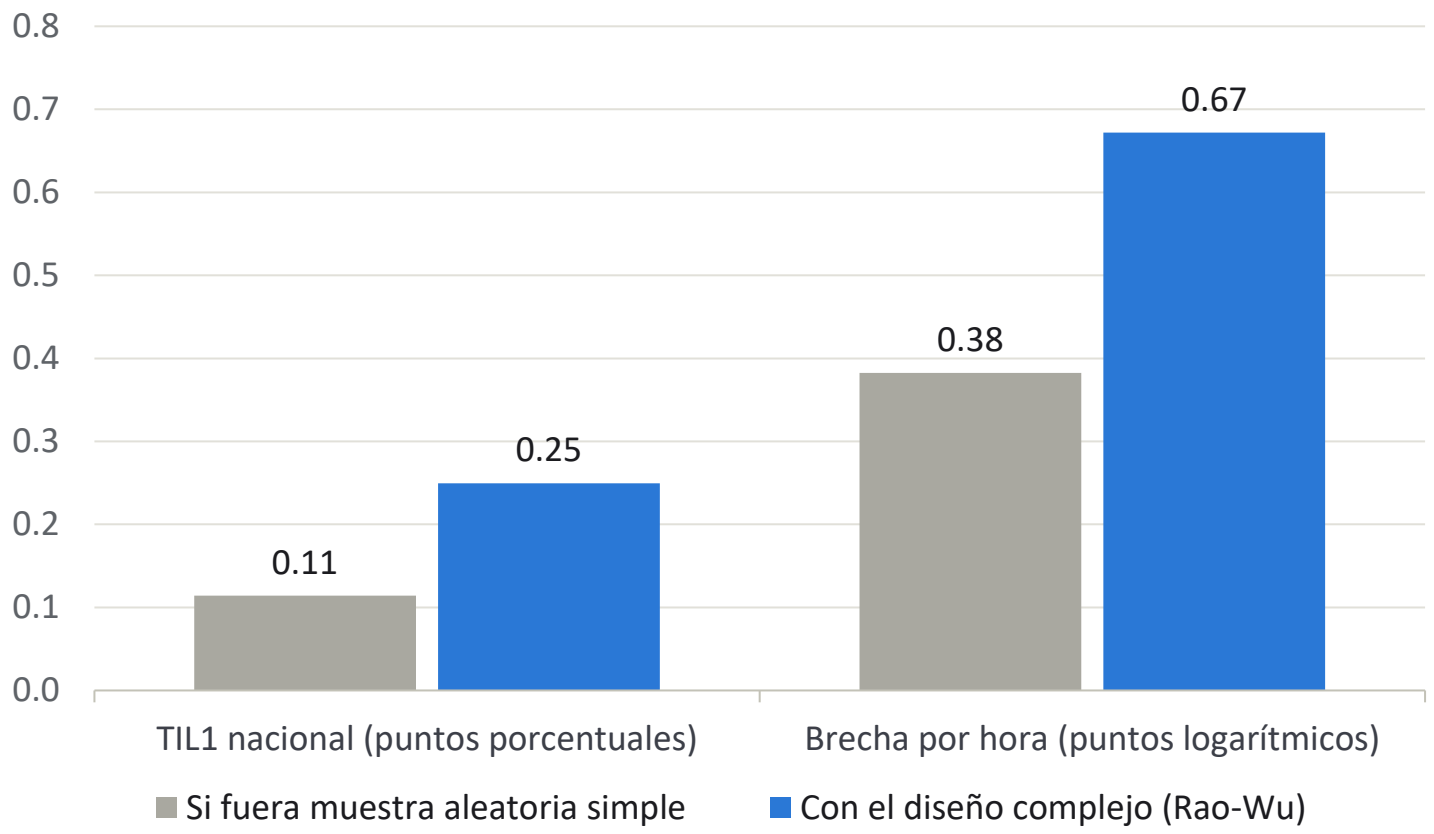
Paquete src/enoe/ (16 módulos) + scripts/ (ejecutables) + tests/ (41 pruebas).

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Ignorar el diseño muestral subestimaría el error a la mitad

Error estándar de dos estimaciones clave



×4.8

efecto de diseño en la informalidad

40 mil

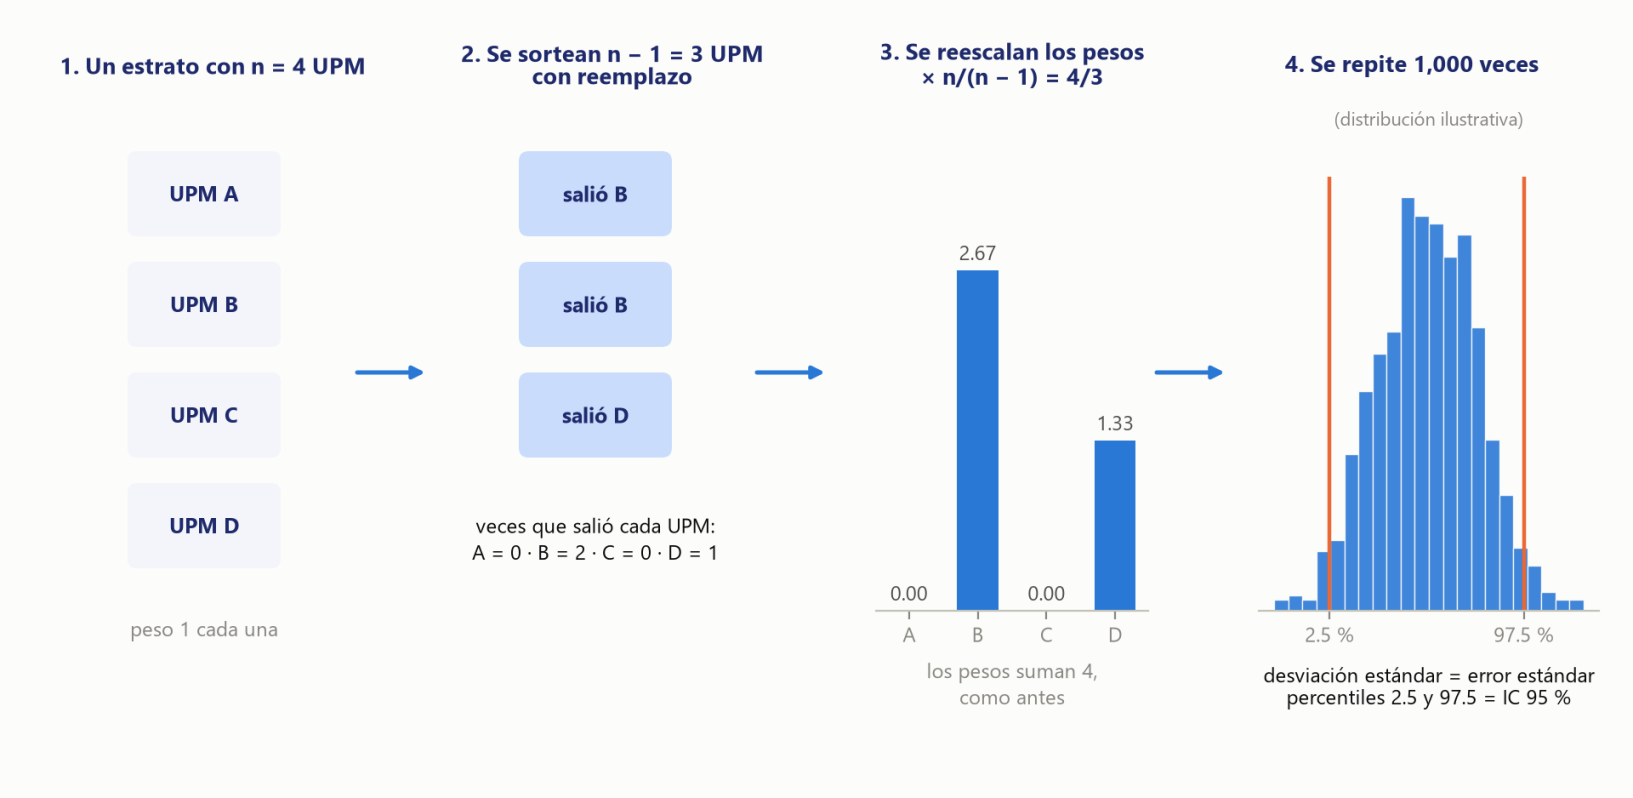
observaciones efectivas de 190 mil

1,000

réplicas de Rao-Wu · 713 estratos · 21,194 UPM

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

El bootstrap de Rao–Wu, paso a paso

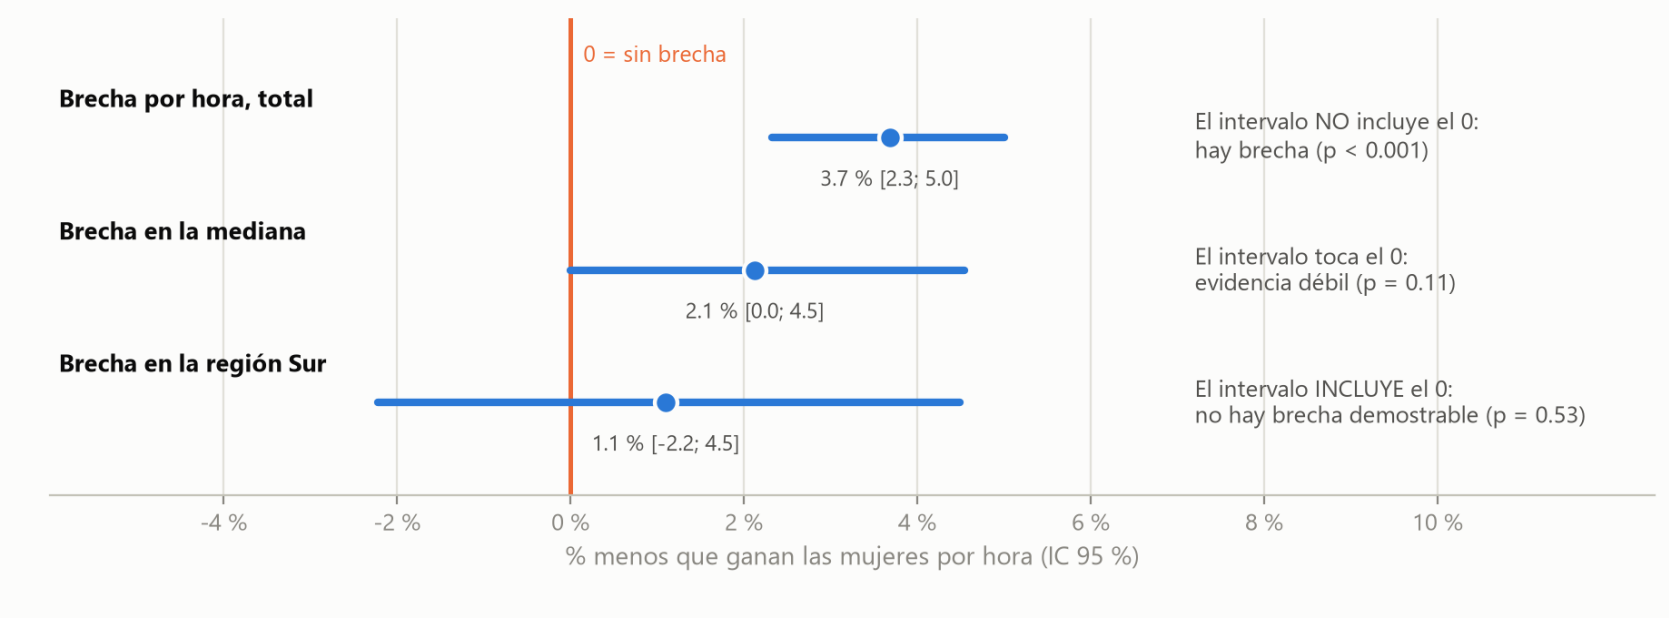


1. En cada estrato con n UPM se sortean n − 1 con reemplazo
2. Los pesos se reescalan: × n/(n − 1) × veces que salió la UPM
3. Se repite 1,000 veces con la misma semilla
4. Error estándar = desviación estándar; IC = percentiles 2.5 y 97.5

Verificado con pruebas: la varianza bootstrap coincide con la de linealización de Taylor (± 8 %).

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Cómo leer un intervalo de confianza y un valor p



IC 95 %: rango de valores plausibles; si no incluye el 0, la diferencia es significativa.

Valor p: probabilidad de ver una diferencia así si no hubiera brecha; p < 0.05 = significativa.

1

Excluye el 0

Brecha por hora total: 3.7 % (2.3 a 5.0). Hay brecha demostrable.

2

Toca el 0

Brecha en la mediana: 2.1 % (p = 0.11). Evidencia débil.

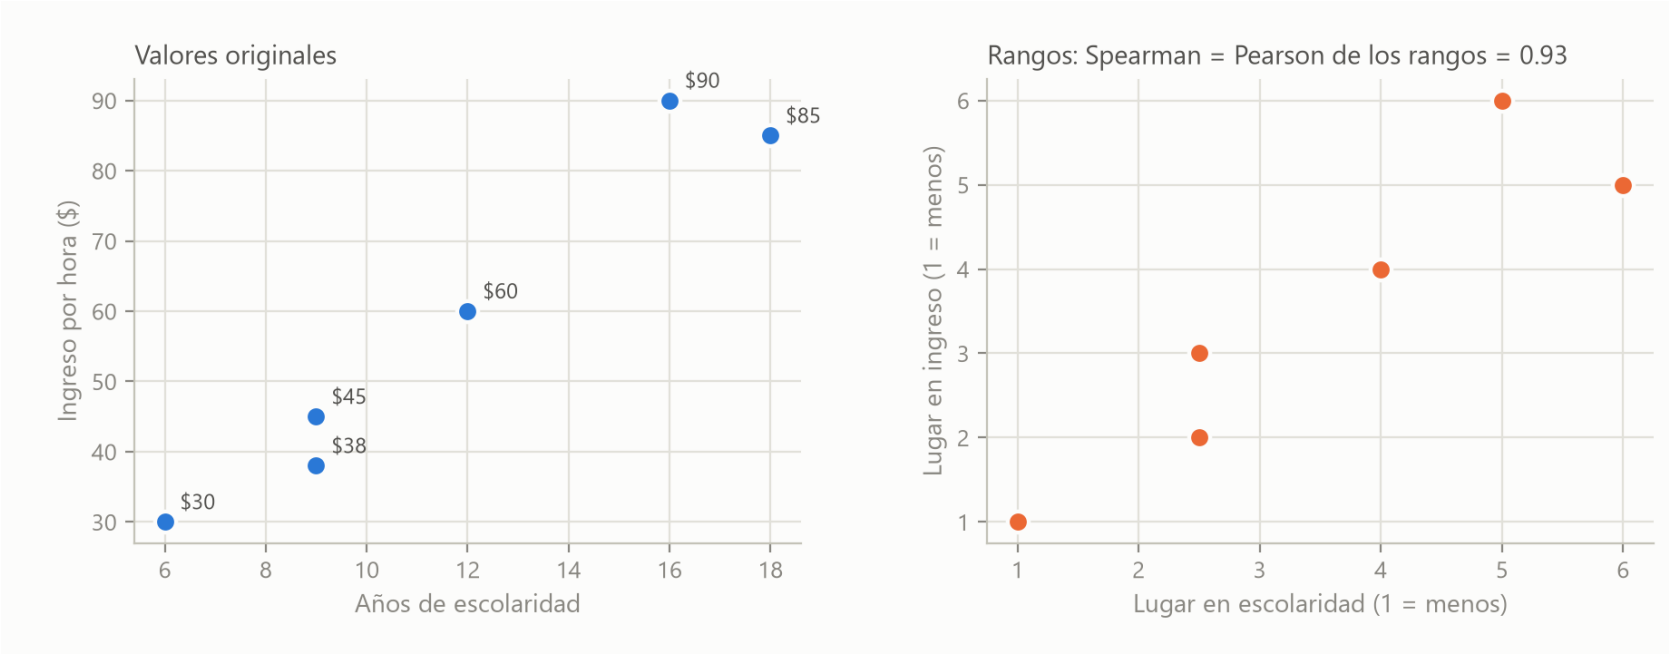
3

Incluye el 0

Brecha en la región Sur: 1.1 % (p = 0.53). No se puede afirmar.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Spearman: la correlación entre rangos



Cómo se calcula

1 Ordenar cada variable

2 Cambiar valores por rangos (empates: rango medio)

3 Pearson entre rangos, ponderado por fac_tri

≈ 0.1
débil

≈ 0.3
moderada

≈ 0.5
fuerte

0.34
escolaridad e ingreso por hora, nacional

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La ecuación de Mincer: cómo se lee el 5.1 %

$$\ln(\text{ingreso por hora}) = \alpha + \beta \cdot \text{escolaridad} + \gamma_1 \cdot \text{edad} + \gamma_2 \cdot \text{edad}^2 + \delta \cdot \text{mujer} + \text{efectos de entidad y de localidad} + \text{error}$$

β = aumento del logaritmo del ingreso por año de estudio → rendimiento (%) = 100 × (e^β − 1)

Modelo (controles acumulados)	β	Rendimiento por año (IC 95 %)
M1 Mincer simple	0.0561	5.77 % (5.57 a 5.97)
M2 + edad, edad² y sexo	0.0597	6.15 % (5.94 a 6.36)
M3 + entidad y localidad	**0.0501**	**5.14 % (4.96 a 5.32)**
M4 + posición, informalidad y rama	0.0375	3.82 % (3.64 a 4.00)

M3 (con entidad y localidad) es el resultado de referencia. M4 baja a 3.8 % porque parte del beneficio de estudiar actúa a través de conseguir un mejor empleo (formal, asalariado).

+5.1 %

por cada año de estudio (M3)

+10.5 %

dos años: $(1.051)^2 - 1$

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Tres herramientas para leer la brecha: porcentaje, tamaño del efecto y Holm

Brecha (%)

1 − (50.60 ÷ 52.53) = 3.7 %

Las mujeres ganan 3.7 % menos por hora, comparando medias geométricas.

d de Cohen

diferencia de medias ÷ desviación estándar

0.2 pequeño · 0.5 mediano · 0.8 grande. Aquí: 0.06 a 0.24.

Corrección de Holm

4 pruebas → p ordenados y umbrales crecientes

Controla el error del conjunto; las 4 brechas siguen siendo significativas.

Nivel de instrucción	Brecha	IC 95 %	d de Cohen	p (Holm)
Primaria incompleta	8.4 %	4.1 a 12.9	0.24	< 0.001
Primaria completa	10.1 %	7.3 a 12.9	0.20	< 0.001
Secundaria completa	7.6 %	5.9 a 9.3	0.15	< 0.001
Medio superior y superior	3.9 %	2.0 a 5.5	0.06	< 0.001
Total	**3.7 %**	**2.3 a 5.0**	**0.08**	**< 0.001**

Lectura

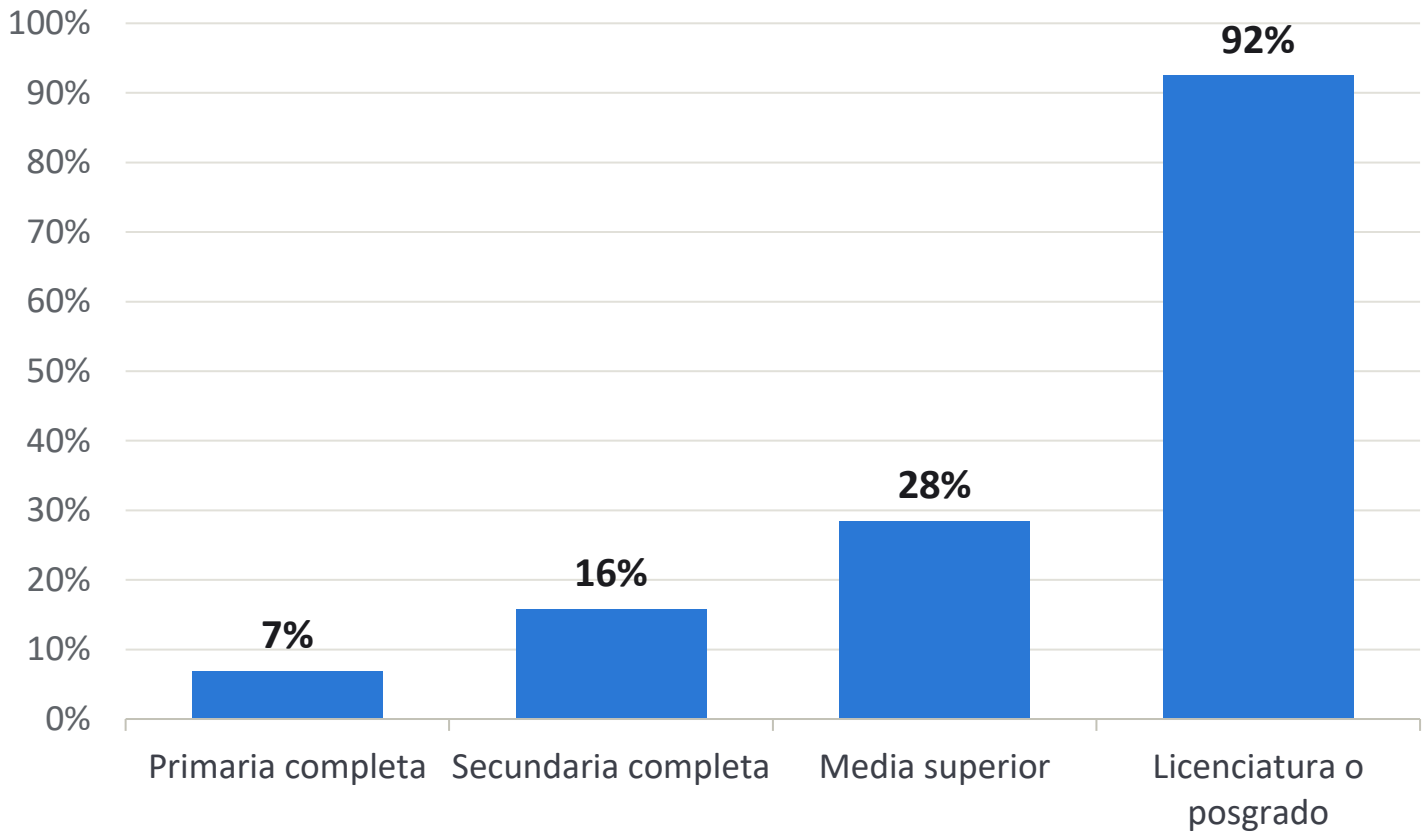
Hay brecha en los cuatro niveles, pero el efecto es pequeño: hombres y mujeres se traslapan mucho.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Cada año de estudio eleva el ingreso por hora 5.1 %, y la licenciatura casi lo duplica

Premio salarial frente a no terminar primaria (%, con IC en el cuaderno)



+5.1 %

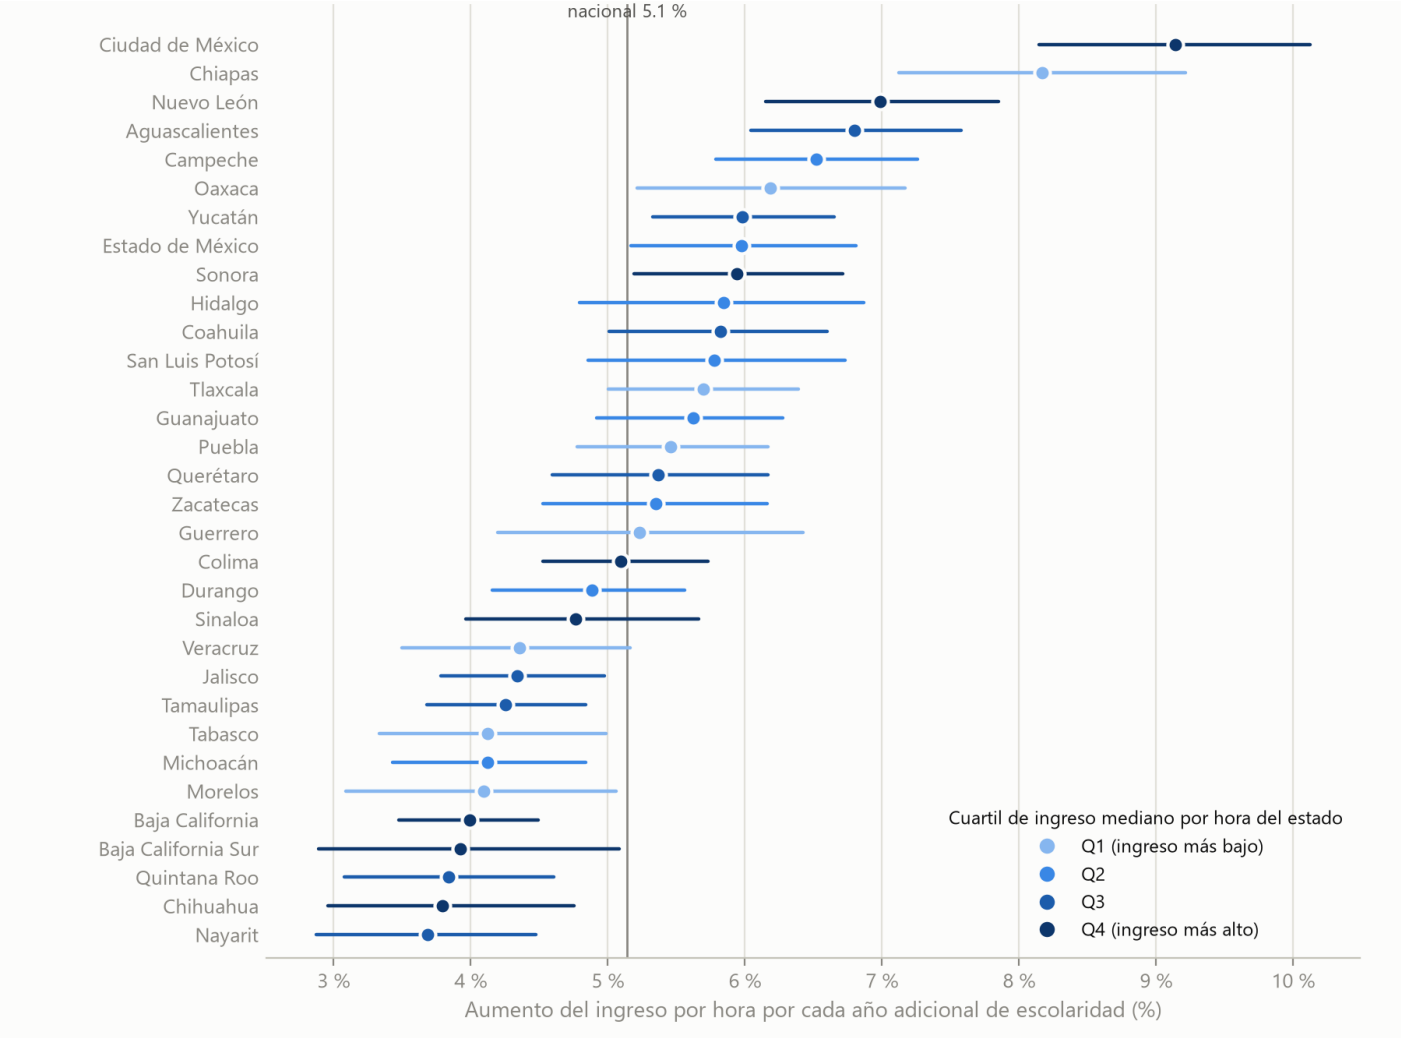
por año de escolaridad (IC 95 %: 5.0 a 5.3)

- Mujeres 5.9 % vs. hombres 4.6 % por año
- Robusto: 4.9 %–5.7 % en 7 especificaciones
- Spearman nacional ρ = 0.34

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Estudiar rinde parecido en estados ricos y pobres



≈ 0

diferencia de rendimiento entre estados ricos (Q4) y pobres (Q1): +0.000 log-puntos, p = 0.91

3.7–9.1 %

rango entre estados: de Nayarit a Ciudad de México

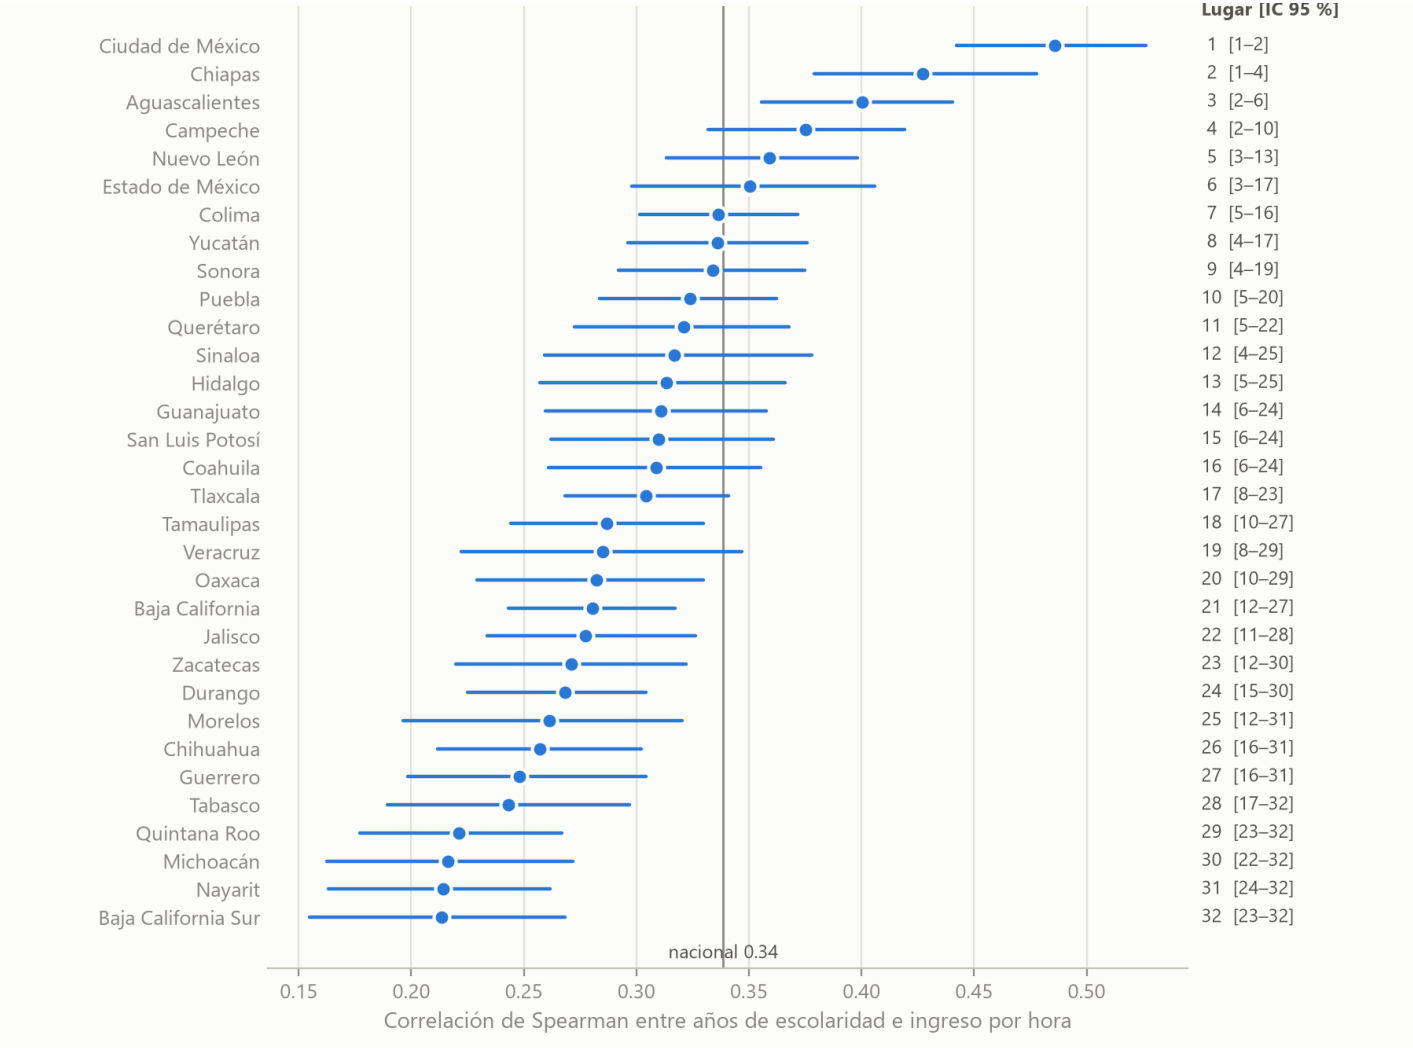
5.9 vs. 4.6 %

rendimiento por año de mujeres vs. hombres

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Un ranking defendible distingue solo los extremos



0.34

Spearman nacional: asociación positiva y moderada

0.49 → 0.21

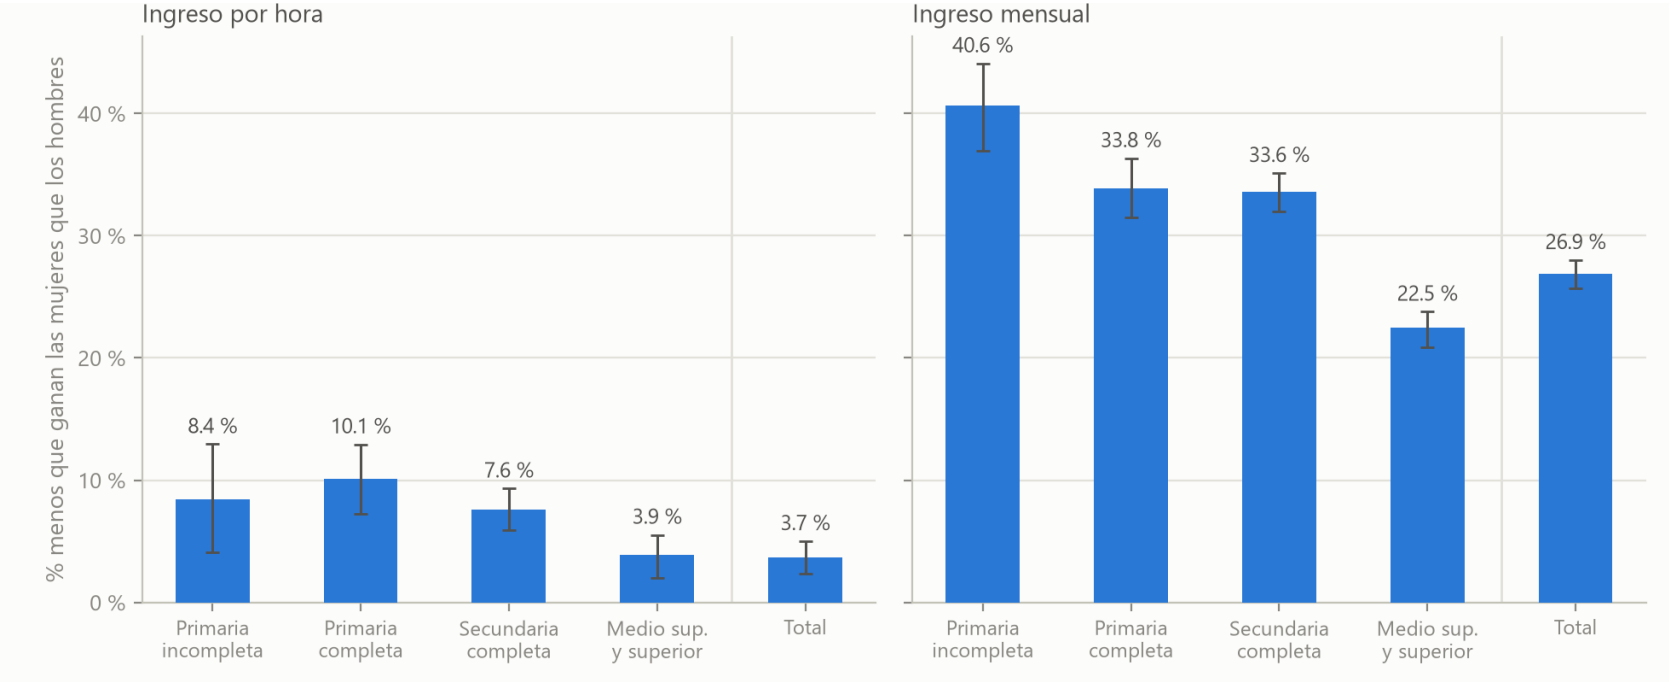
de Ciudad de México (lugar 1–2) a Baja California Sur (23–32)

Los lugares centrales abarcan 15 o más posiciones: no son estadísticamente distinguibles.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Por hora la brecha es de 3.7 %; por mes, de 26.9 %



3.7 %
por hora (IC 2.3–5.0)

26.9 %
por mes

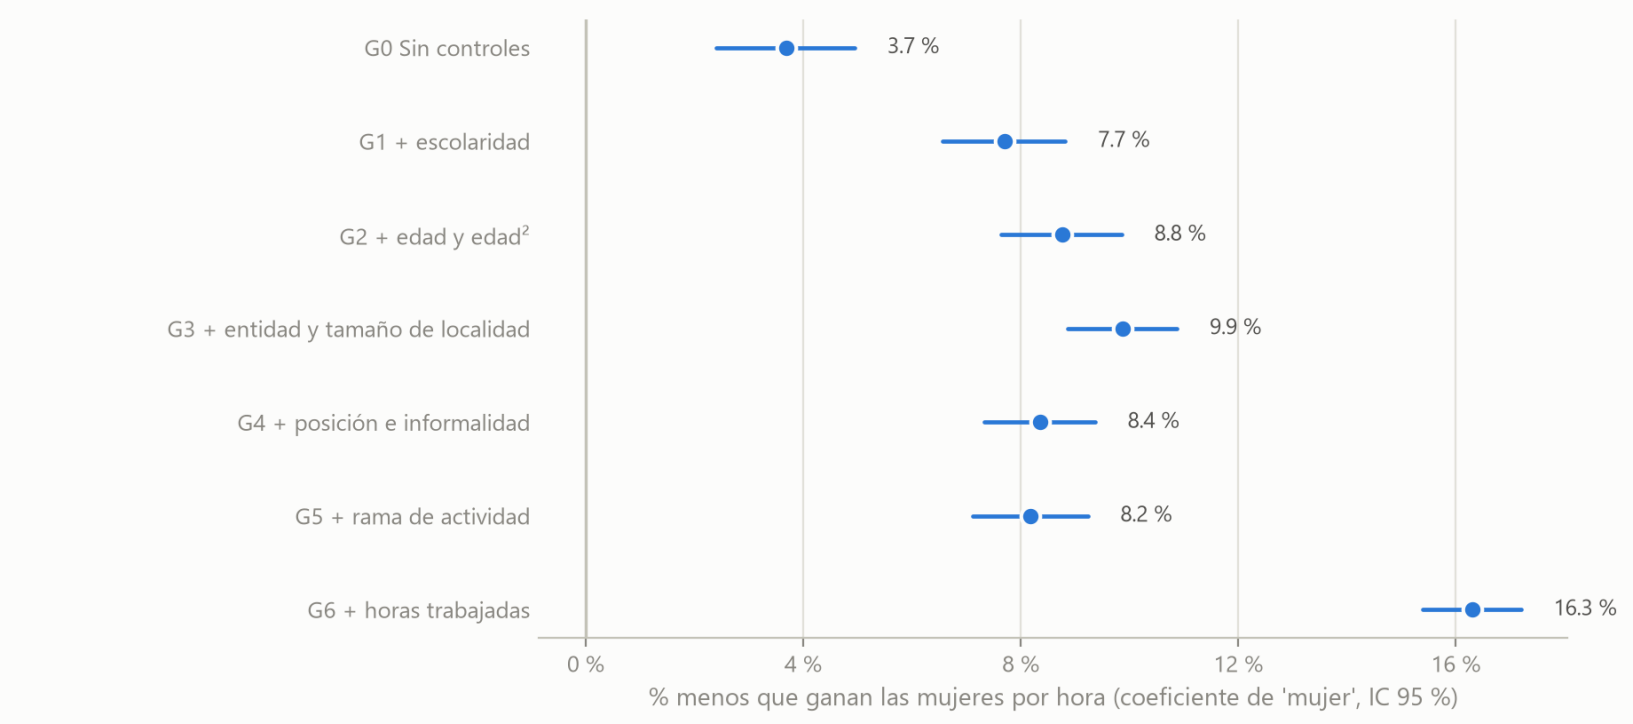
–24 %
horas pagadas: 37.5 vs. 45.7 h por semana

Brecha = 1 − (ingreso medio geométrico de las mujeres ÷ el de los hombres), con IC 95 %; misma escala en ambos paneles.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Entre personas comparables, la brecha por hora ronda 8 %



3.7 %
sin controles

8.2 %
con escolaridad, edad, lugar, empleo y rama

≈ 7 pts
parte no explicada (Oaxaca-Blinder)

Cada fila agrega controles al anterior; la última (horas) no se interpreta por el sesgo de división.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Oaxaca–Blinder: separar lo explicado de lo no explicado

+3.8
Brecha total por hora (hombres – mujeres)

=

-3.2
EXPLICADA por características (escolaridad, edad, lugar, empleo, rama)

Las mujeres tienen mejores características (sobre todo más escolaridad): eso favorecería su ingreso

+

+6.9
NO EXPLICADA (pago distinto a las mismas características)

A igualdad de características, a las mujeres se les paga menos: ≈ 7 puntos de más

Desglose de la parte explicada (puntos logarítmicos):

-2.8	-0.6	-1.7	+1.0	+0.9
escolaridad	edad	entidad y localidad	posición e informalidad	rama

Cómo leerla

Explicada: difieren las características (escolaridad, edad, lugar, empleo, rama).

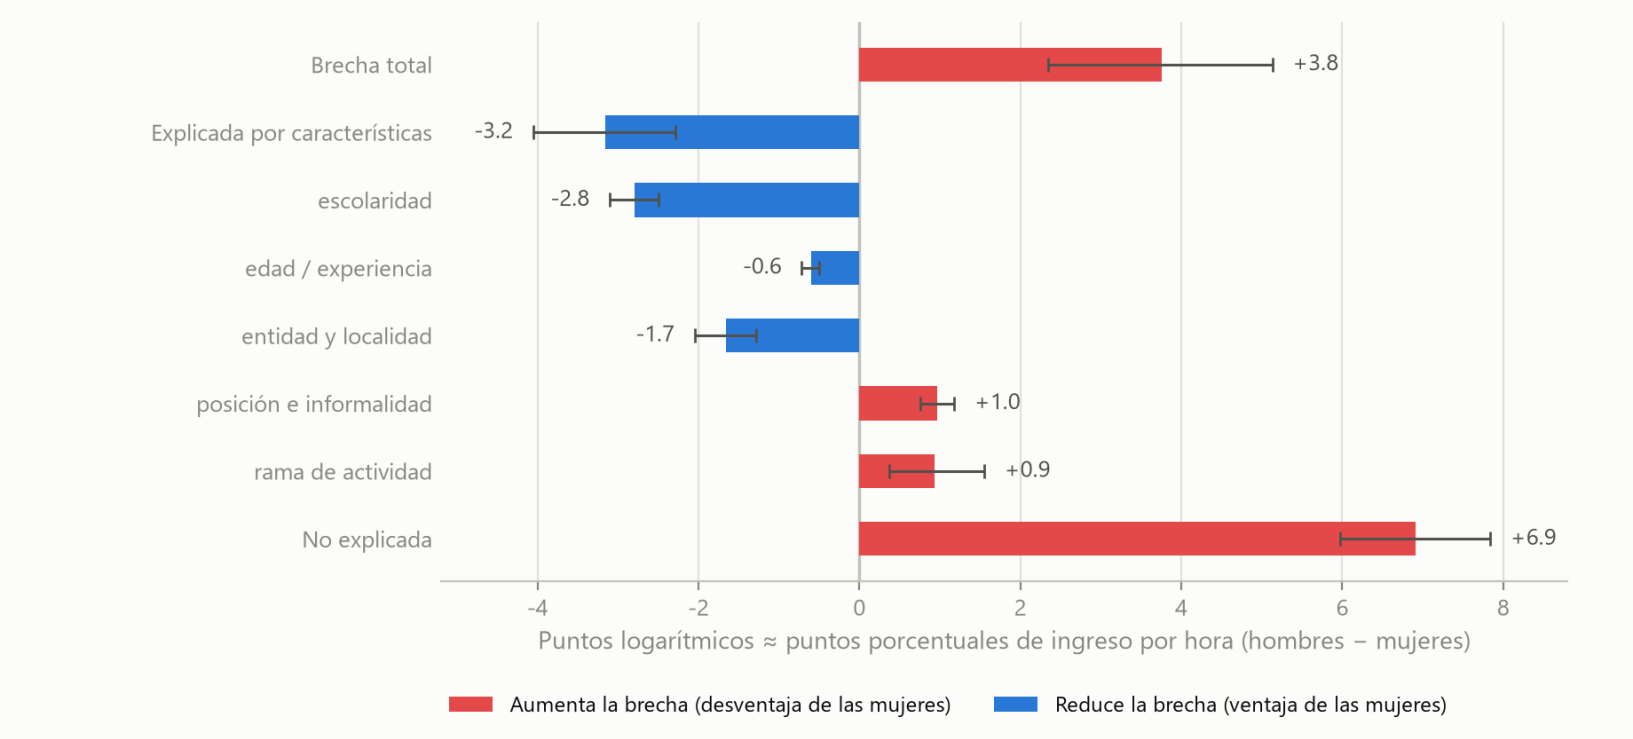
No explicada: a iguales características, distinto pago.

A iguales características, las mujeres reciben **6.9 puntos logarítmicos (≈ 6.7 %) menos.**

No prueba discriminación.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Oaxaca-Blinder: las mujeres tienen mejores características, pero un residuo desfavorable



Explicada: negativa; la mayor escolaridad de las mujeres favorecería su ingreso.

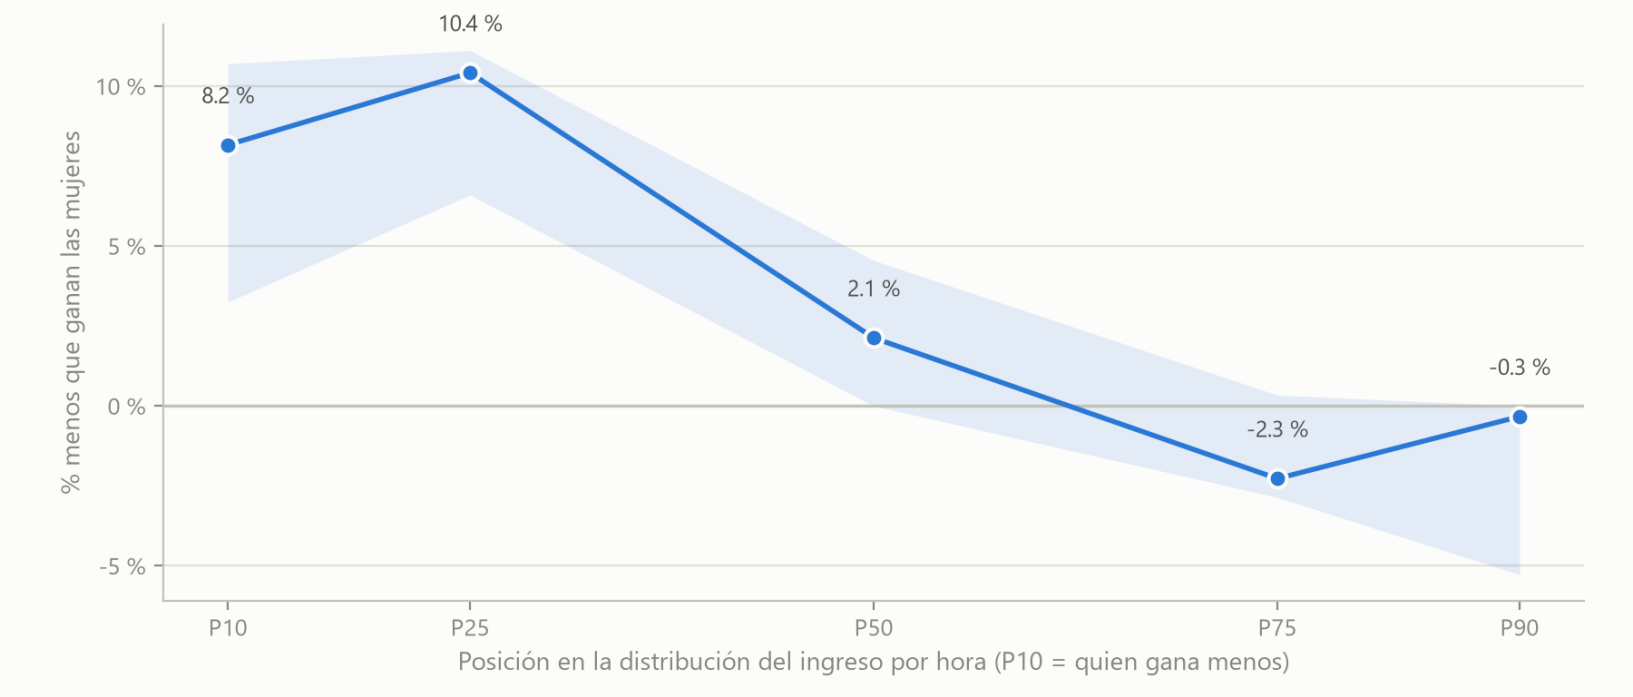
No explicada: ≈ 7 puntos; no prueba discriminación.

Con horas el residuo sube a 14 puntos por el sesgo de división.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

La brecha se concentra en la parte baja de la distribución



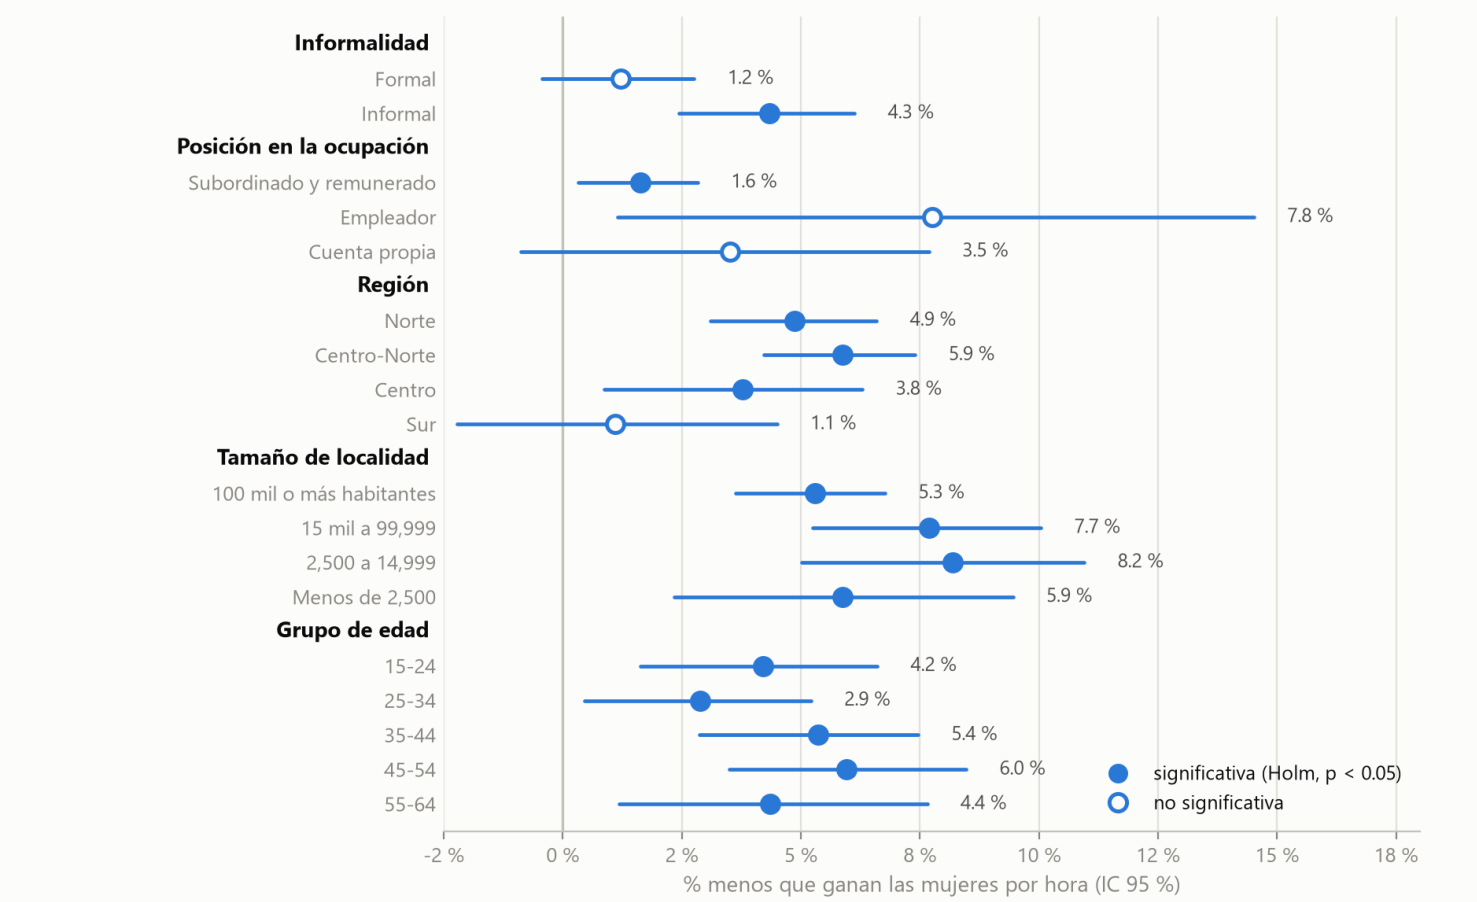
8–10 %
en el 10 %–25 % que menos gana

2.1 %
en la mediana (no significativa)

≈ 0
en el 25 % que más gana

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La brecha por hora varía por grupo: es mayor en el empleo informal



4.3 % vs 1.2 %

informales (significativa) vs. formales (no significativa)

1.1 → 5.9 %

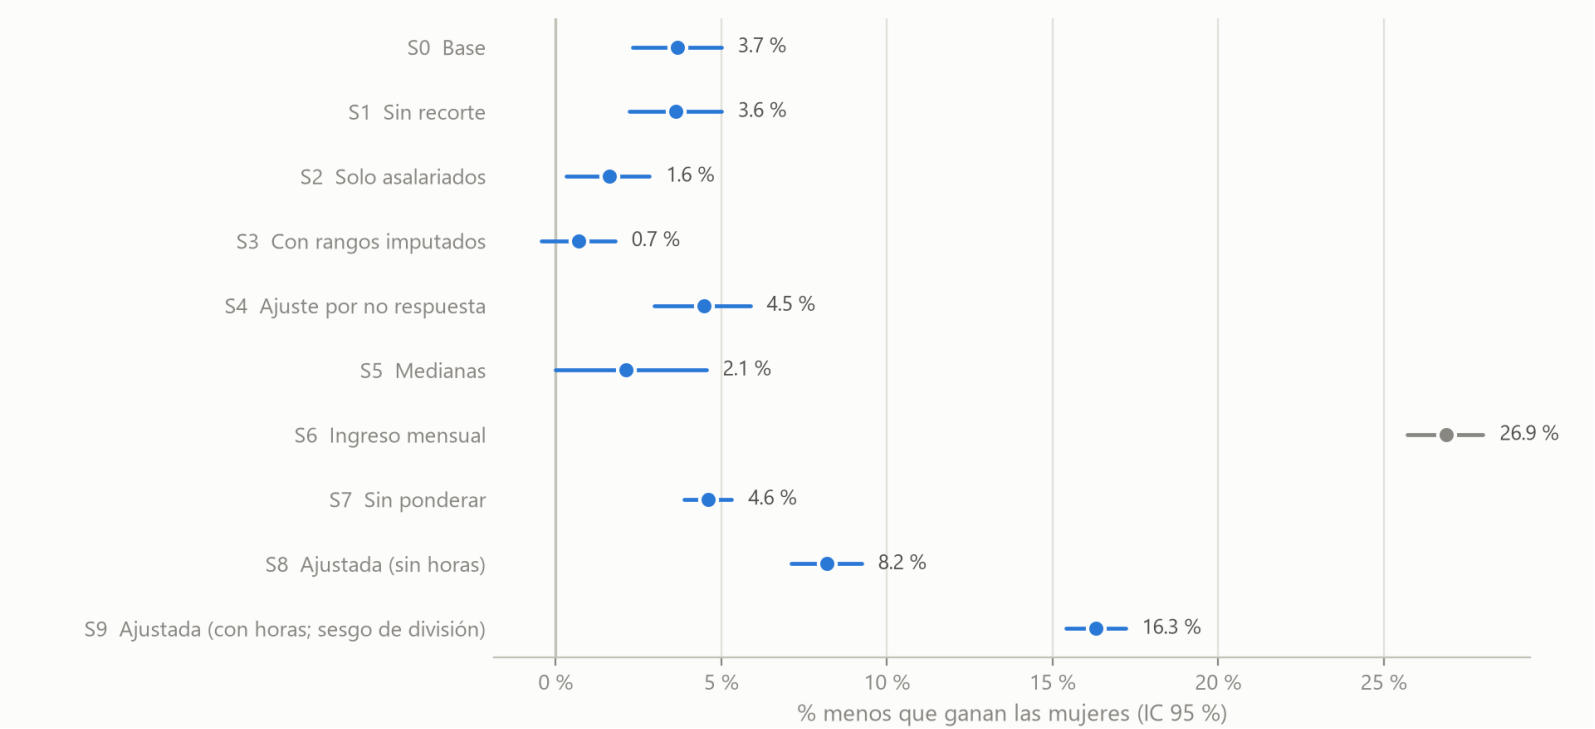
del Sur (no significativa) al Centro-Norte

25–64 años

significativa en todos los grupos de edad (2.9 % a 6.0 %)

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

La brecha por hora es positiva en todas las muestras, pero su tamaño va de 0.7 % a 4.6 %



S3 sesga hacia cero: imputar el rango asigna el mismo ingreso a hombres y mujeres.

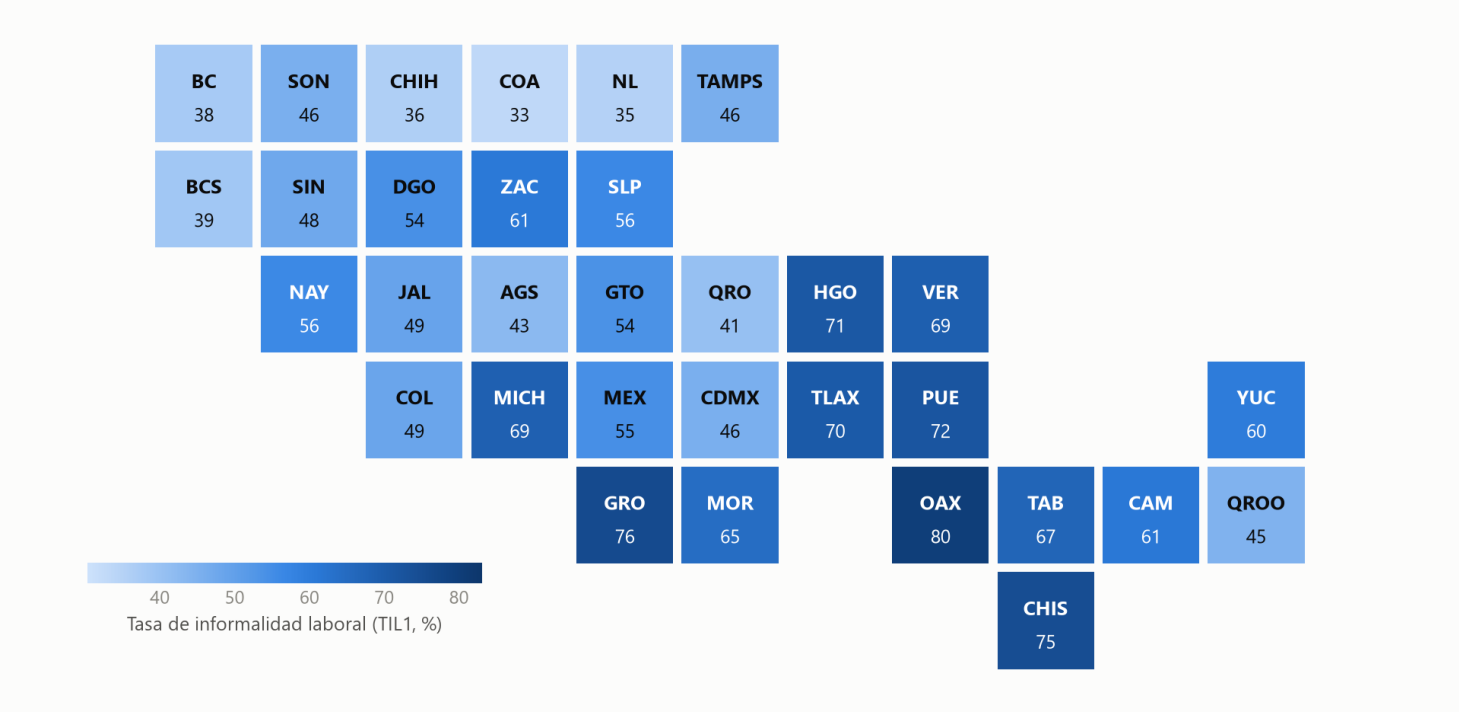
S4 (IPW) la sube a **4.5 %**.

Ajustada sin horas: 8.2 %. Con horas hay sesgo de división.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

La informalidad cae con la escolaridad: de 87 % a 38 %



55.0 %
informalidad nacional (TIL1)

33 → 80 %
de Coahuila a Oaxaca

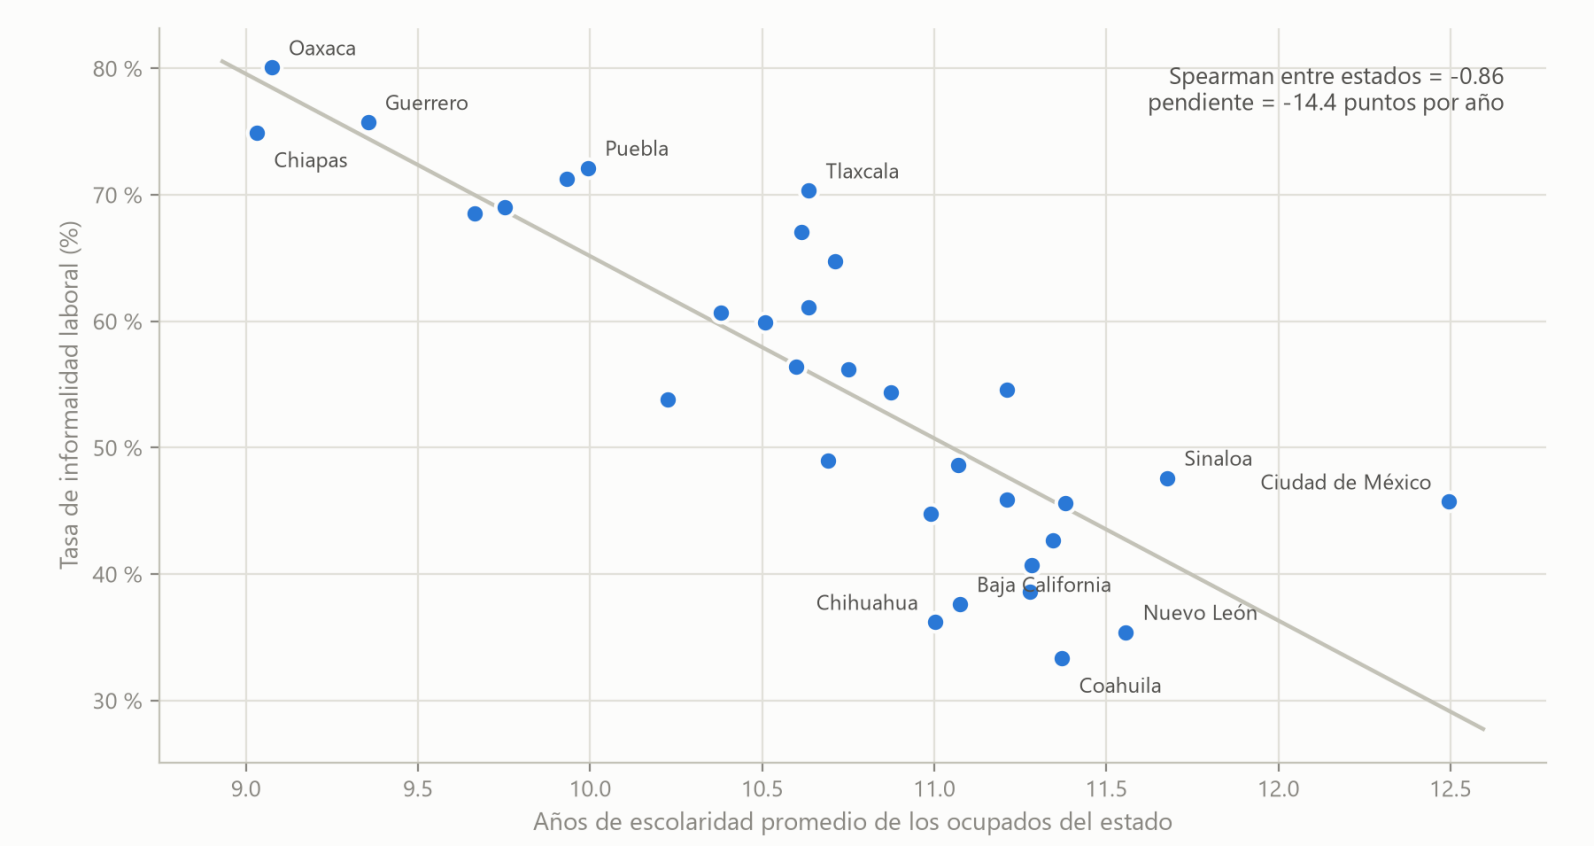
87 → 38 %
de primaria incompleta a media superior o más

-3.9 pp
por cada año de escolaridad (individual)

Entre estados, Spearman = -0.86. TIL1 = ocupados en empleo informal ÷ ocupados de 15+ (definición del INEGI); las mujeres suman +6 puntos a igual escolaridad, edad y lugar.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Donde se estudia más hay menos informalidad (relación entre estados)



-0.86

Spearman entre estados

-14.4

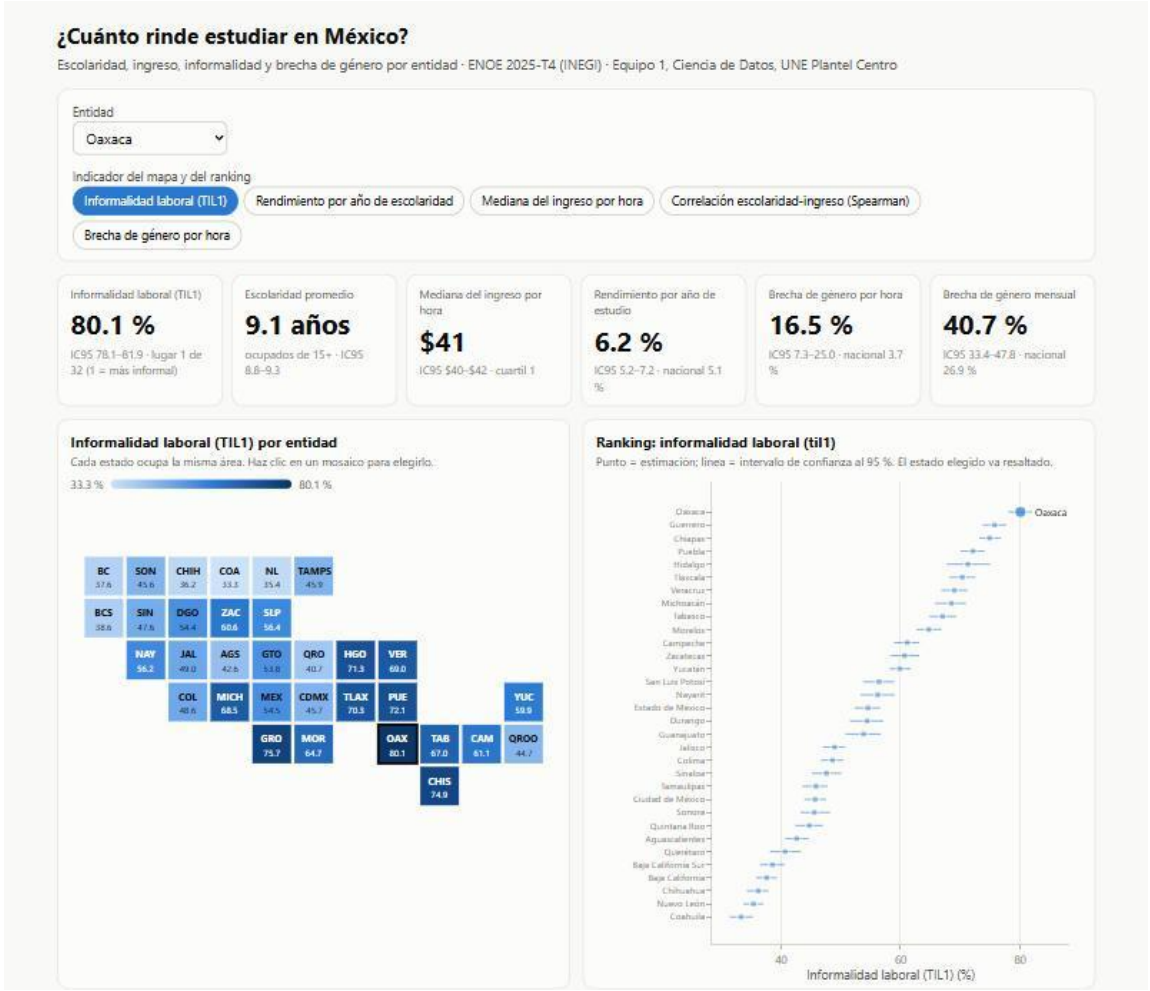
puntos porcentuales por año de escolaridad promedio

0.82

razón de momios individual por año de escolaridad

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Tablero interactivo: la ficha de cada entidad



Qué incluye

Selector de entidad e indicador

Mapa de mosaicos y ranking con IC

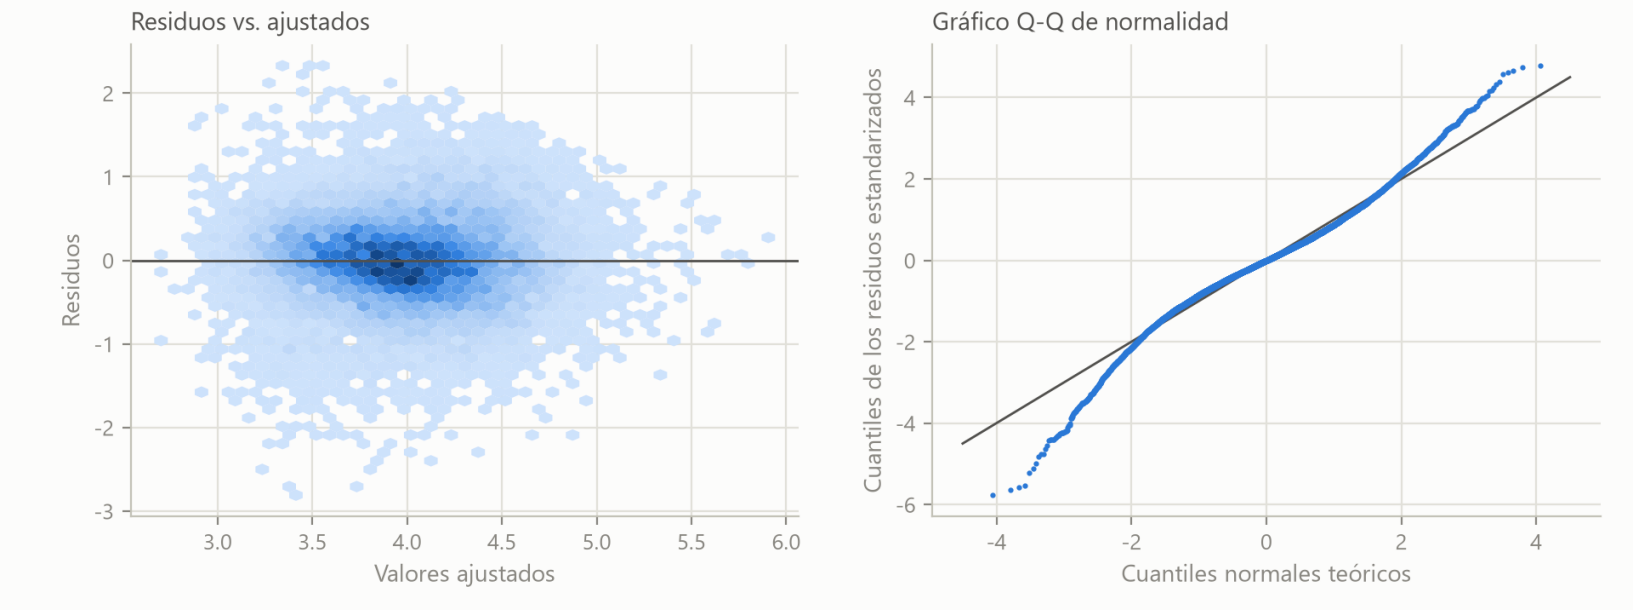
Dos dispersiones y brechas por nivel

Calidad del ingreso por entidad

Tabla accesible y documento JSON de la entidad

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Diagnóstico del modelo: varianza no constante y colas pesadas, por eso errores robustos



1.7

VIF máximo: sin multicolinealidad

0.0005

distancia de Cook máxima: sin influyentes

1.9

curtosis en exceso de los residuos

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Estudiar paga en todas partes; la brecha de género es de horas

Qué encontramos

Estudiar rinde ≈ 5.1 % por año y la licenciatura casi duplica el ingreso

El rendimiento es igual en estados ricos y pobres (p = 0.91)

Brecha de 3.7 % por hora y 26.9 % por mes: es de horas

Informalidad: 87 % → 38 % con la escolaridad

Qué recomendamos

Ampliar acceso y permanencia escolar, sobre todo en el Sur (informalidad 69 %)

Políticas de cuidados y horarios flexibles de tiempo completo para cerrar la brecha de horas

Atender el «piso pegajoso»: salario mínimo y formalización en los percentiles bajos

Publicar ingresos imputados por rango y corregir por no respuesta

M1 ✓ Brecha por nivel con IC y prueba: cumplida

M2 ✓ Spearman de 32 entidades con IC y ranking: cumplida

M3 ✓ Tablero ≥ 4 gráficas sobre base NoSQL: cumplida

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Métricas de éxito del protocolo: las tres se cumplen

	Qué pedía el protocolo	Evidencia	Estado
M1	Brecha salarial por nivel de instrucción, con IC 95 % y prueba de hipótesis	Brecha por hora y por mes en los 4 niveles; IC de Rao-Wu; p con Holm; Welch, Mann-Whitney y d de Cohen	Cumplida
M2	Spearman en las 32 entidades, con IC por bootstrap y ranking defendible	ρ de 32 entidades con IC y con el intervalo del lugar; el ranking solo distingue los extremos	Cumplida
M3	Tablero con ≥ 4 visualizaciones, alimentado por un pipeline a una base NoSQL consultable por entidad	Tablero HTML con 6 visualizaciones y ficha por entidad; documentos MongoDB y agregación verificada contra SQL	Cumplida*

*** Salvedad:** la carga a un servidor MongoDB real no se ejecutó (no hay servidor instalado); se probó con mongomock (simulador), los documentos están listos para mongoimport y la agregación equivalente está verificada.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Qué no podemos afirmar, y qué haríamos después

Límites

Asociación, no causalidad (habilidad no observada; falacia ecológica entre estados)

Solo vemos el ingreso de quien trabaja y lo declara (selección)

Ingreso autorreportado, con redondeo; horas de una sola semana

Un trimestre; 1,900–5,900 observaciones por estado

MongoDB: probado con mongomock; carga a servidor real pendiente

Con más tiempo

Varios trimestres (panel rotativo de la ENOE)

Corrección de selección (Heckman) para la participación laboral

Mapa geográfico real con el Marco Geoestadístico

Estimaciones para áreas pequeñas (municipios)

Contrastar los códigos de rangos con el cuestionario oficial

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

★ ruta corta

Gracias

¿Preguntas?

Carpeta Proyecto_ENOE: cuaderno (notebooks/) · tablero interactivo (tablero/) · código (src/ y scripts/) · documentación y guía de defensa (docs/) · pruebas (tests/)

Reproducir todo: python scripts/run_etl.py → run_analysis.py → make_figures.py → build_notebook.py

Glosario (1/2): encuesta e inferencia

ENOE
Encuesta Nacional de Ocupación y Empleo del INEGI: principal fuente del mercado laboral.

Factor de expansión (fac_tri)
A cuántas personas de la población representa cada persona de la muestra.

Estrato y UPM
Estrato: grupo de áreas parecidas. UPM: conjunto de viviendas que se sortea.

Efecto de diseño
Cuánto agranda la varianza el muestreo por conglomerados frente a una muestra simple.

Bootstrap de Rao–Wu
Remuestreo de UPM dentro de estratos con pesos reescalados para medir la incertidumbre.

Intervalo de confianza
Rango de valores plausibles; al 95 %, contiene el valor verdadero el 95 % de las veces.

Valor p
Probabilidad de ver una diferencia así si no hubiera efecto; < 0.05 = significativa.

Corrección de Holm
Ajusta los valores p cuando se hacen varias pruebas a la vez.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Glosario (2/2): modelos y variables

Spearman (ρ)
Correlación entre los rangos de dos variables; mide asociación monótona.

d de Cohen
Tamaño del efecto: 0.2 pequeño, 0.5 mediano, 0.8 grande.

Logaritmo natural
Transformación que acorta la cola larga; sus diferencias son diferencias porcentuales.

Oaxaca–Blinder
Divide la brecha en parte explicada por características y parte no explicada.

Ecuación de Mincer
Regresión del logaritmo del ingreso sobre escolaridad y experiencia.

IPW
Ponderación por la probabilidad inversa de responder para corregir la no respuesta.

Brecha salarial
Porcentaje menos que ganan las mujeres que los hombres (medias geométricas).

TIL1
Tasa de informalidad laboral: ocupados informales ÷ ocupados de 15 años y más.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo

Preguntas difíciles y respuestas cortas

¿Es causal?

No: son asociaciones. Hay habilidad no observada y selección, y las relaciones entre estados no se leen a nivel individual.

¿Por qué ponderan y usan Rao–Wu?

fac_tri representa personas y la encuesta es por conglomerados: los errores «normales» serían demasiado pequeños (efecto de diseño 4.8).

¿Hay brecha de género?

Sí, depende de qué se mida: 3.7 % por hora, 26.9 % por mes (horas: −24 %) y 8.2 % entre personas comparables.

¿Por qué no interpretan el modelo con horas?

Sesgo de división: un error en las horas crea una relación negativa mecánica y la brecha «sube» a 16 %.

¿Cargaron a un MongoDB real?

No hay servidor. La carga completa se probó con mongomock (simulador) y la agregación reproduce la vista SQL (0.005 pp); con un servidor, run_mongo.py --uri la repite.

¿Qué limita los resultados?

Un trimestre, ingreso autorreportado y con redondeo, selección en el empleo y entre 1,900 y 5,900 observaciones por estado.

Fuente: INEGI, ENOE 2025-T4 (SDEMT y COE2T) · cálculos del equipo